

# Tema 0: Prerrequisitos. Teoría de conjuntos y combinatoria

Parte 1: Probabilidad con R y python

octubre 2023

# Lección 1

## Antes de empezar

# Consideraciones

Para aprender cálculo de probabilidades son necesarios conocimientos de:

- 1 Cálculo: Derivadas, integrales, límites, sumas de series...
- 2 Geometría básica y álgebra lineal : rectas, hiperplanos, volúmenes... Matrices, valores propios...
- 3 Teoría de conjuntos y combinatoria.....

# Consideraciones

Por experiencia sabemos que la mayoría de estudiantes tienen más conocimientos de cálculo, geometría y matrices.

Pero muchos tienen una falta de conocimientos en teoría básica de conjuntos y combinatoria (matemática discreta).

# Teoría de conjuntos

## Definición de conjunto

La definición de conjunto es una **idea o noción primitiva**. Es decir es una idea básica del pensamiento humano: un conjunto es una colección de objetos: números, imágenes... cualquier cosa, jugadores de fútbol, palabras, colores ....

La teoría de conjuntos básicas es simple y natural y es la que necesitamos para este curso.

La teoría de conjuntos matemática es más compleja y presenta varias paradojas como la **paradoja de Russell**.

# Teoría de conjuntos

La idea o noción práctica de conjunto es la de una colección de objetos de un cierto tipo.

Estas colecciones o conjuntos se pueden definir por:

- **Comprensión**: reuniendo los objetos que cumplen una propiedad  $p$
- **Extensión**: dando una lista exhaustiva de los miembros del conjunto

# Conjuntos básicos

Los conjuntos suelen tener un conjunto madre como por ejemplo

- $\mathbb{N} = \{0, 1, 2, \dots\}$
- $\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\}$
- $\mathbb{Q} = \left\{ \frac{p}{q} \mid p, q \in \mathbb{Z} \text{ y } q \neq 0. \right\}$
- $\mathbb{R} = \{\text{Todos los puntos de una recta.}\}$

# Conjuntos básicos

- $\mathbb{C} = \{a + b \cdot i \mid a, b \in \mathbb{R}\}$  los números complejos  $a + b \cdot i$ .
- Alfabeto =  $\{a, b, c, \dots, A, B, C, \dots\}$ .
- Palabras =  $\{paz, guerra, amor, probabilidad, \dots\}$ .

Recordemos que  $i$  es la unidad imaginaria que cumple que  $i = \sqrt{-1}$ .



# Características y propiedades básicas de los conjuntos

- Si a cada objeto  $x$  de  $\Omega$  le llamaremos **elemento del conjunto**  $\Omega$  y diremos que  $x$  pertenece a  $\Omega$ . Lo denotaremos por  $x \in \Omega$ .
- Un **conjunto de un elemento**, por ejemplo  $\{1\}$  recibe el nombre de **conjunto elemental** (o **singleton** del inglés).
- Sea  $A$  otro conjunto diremos que  $A$  **es igual a**  $B$  si todos los elementos  $A$  están en  $B$  y todos los elementos de  $B$  están en  $A$ . Por ejemplo  $A = \{1, 2, 3\}$  es igual a  $B = \{3, 1, 2\}$ .

# Características y propiedades básicas de los conjuntos

- Si  $B$  es otro conjunto, tal que si  $x \in A$  entonces  $x \in B$  diremos que  $A$  es un subconjunto de o que está contenido en  $B$ . Lo denotaremos por  $A \subseteq B$ .
- El conjunto que no tiene elementos se denomina conjunto vacío y se denota por el símbolo  $\emptyset$ .
- Dado  $A$  un conjunto cualquiera obviamente  $\emptyset \subseteq A$ .

# Características y propiedades básicas de los conjuntos

Tomemos como conjunto base  $\Omega = \{1, 2, 3\}$

- $\Omega$  es un conjunto de cardinal 3, se denota por  $\#(\Omega) = 3$  o por  $|\Omega| = 3$
- El conjunto  $\Omega$  tiene  $2^3 = 8$  subconjuntos.
  - el vacío  $\emptyset$  y los elementales  $\{1\}, \{2\}, \{3\}$
  - los subconjuntos de dos elementos:  $\{1, 2\}, \{1, 3\}, \{2, 3\}$
  - el conjunto total de tres elementos  $\Omega = \{1, 2, 3\}$ .

# Características y propiedades básicas de los conjuntos

Dado un conjunto  $\Omega$  podemos construir el **conjunto de todas sus partes** (todos sus subconjuntos) al que denotamos por  $\mathcal{P}(\Omega)$ . También se denomina de forma directa partes de  $\Omega$ .

Cardinal de las partes de un conjunto

El **cardinal de la partes de un conjunto** es  $\#(\mathcal{P}(\Omega)) = 2^{\#(\Omega)}$ .

# Características y propiedades básicas de los conjuntos

Por ejemplo  $\#(\mathcal{P}(\{1, 2, 3\})) = 2^{\#(\{1, 2, 3\})} = 2^3 = 8$ .

Efectivamente

$$\mathcal{P}(\{1, 2, 3\}) = \{\emptyset, \{1\}, \{2\}, \{3\}, \{1, 2\}, \{1, 3\}, \{2, 3\}, \{1, 2, 3\}\}.$$

# Características y propiedades básicas de los conjuntos

Dado un subconjunto  $A$  de  $\Omega$  podemos construir la función característica de  $A$

$$\chi_A : \Omega \rightarrow \{0, 1\}$$

dado un  $\omega \in \Omega$

$$\chi_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases}$$

## Operaciones conjuntos: Intersección.

Sea  $\Omega$  un conjunto y  $A$  y  $B$  dos subconjuntos de  $\Omega$ .

El conjunto **intersección** de  $A$  y  $B$  es el formado por todos los elementos que perteneces a  $A$  **Y**  $B$ , se denota por  $A \cap B$ .

Más formalmente

$$A \cap B = \{x \in \Omega \mid x \in A \text{ y } x \in B\}.$$

## Operaciones conjuntos: Unión.

El conjunto **unión** de  $A$  y  $B$  es el formado por todos los elementos que perteneces a  $A$  **O** pertenecen a  $B$ , se denota por  $A \cup B$ .

Más formalmente

$$A \cup B = \{x \in \Omega \mid x \in A \text{ o } x \in B\}.$$



## Operaciones conjuntos: Diferencia.

El conjunto **diferencia** de  $A$  y  $B$  es el formado por todos los elementos que perteneces a  $A$  **Y NO** pertenecen a  $B$ , se denota por  $A - B = A - (A \cap B)$ .

Más formalmente

$$A - B = \{x \in \Omega \mid x \in A \text{ y } x \notin B\}.$$

# Operaciones conjuntos: Complementario

El **complementario** de un subconjunto  $A$  de  $\Omega$  es  $\Omega - A$  y se denota por  $A^c$  o  $\overline{A}$ .

Más formalmente

$$A^c = \{x \in \Omega \mid x \notin A\}.$$

## Más propiedades y definiciones

Sea  $\Omega$  un conjunto y  $A, B, C$  tres subconjuntos de  $\Omega$

- Se dice que dos conjuntos  $A$  y  $B$  **son disjuntos** si  $A \cap B = \emptyset$ .
- $\Omega^c = \emptyset$ .
- $\emptyset^c = \Omega$ .
- $A \cup B = B \cup A$ ,  $A \cap B = B \cap A$  conmutativas.
- $(A \cup B) \cup C = A \cup (B \cup C)$ ,  $(A \cap B) \cap C = A \cap (B \cap C)$  asociativas.
- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ ,  $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$  distributivas.
- $(A^c)^c = A$  doble complementario.
- $(A \cup B)^c = A^c \cap B^c$ ,  $(A \cap B)^c = A^c \cup B^c$  leyes de De Morgan.

## Con R, ejemplos.

Con R los conjuntos se pueden definir como vectores

```
Omega=c(1,2,3,4,5,6,7,8,9,10)
```

```
A=c(1,2,3,4,5)
```

```
B=c(1,4,5)
```

```
C=c(4,6,7,8)
```

```
Omega
```

```
[1] 1 2 3 4 5 6 7 8 9 10
```

# Con R, ejemplos.

A

```
[1] 1 2 3 4 5
```

B

```
[1] 1 4 5
```

C

```
[1] 4 6 7 8
```

## Con R, ejemplos.

 $A \cap B$ 

```
A
```

```
[1] 1 2 3 4 5
```

```
B
```

```
[1] 1 4 5
```

```
intersect(A,B)
```

```
[1] 1 4 5
```

## Con R, ejemplos.

 $A \cup B$ 

```
A
```

```
[1] 1 2 3 4 5
```

```
B
```

```
[1] 1 4 5
```

```
union(A,B)
```

```
[1] 1 2 3 4 5
```

## Con R, ejemplos.

 $B - C$ 

```
B
```

```
[1] 1 4 5
```

```
C
```

```
[1] 4 6 7 8
```

```
setdiff(B,C)
```

```
[1] 1 5
```



## Con R, ejemplos.

$$A^c = \Omega - A$$

```
Omega
```

```
[1] 1 2 3 4 5 6 7 8 9 10
```

```
A
```

```
[1] 1 2 3 4 5
```

```
setdiff(Omega,A)
```

```
[1] 6 7 8 9 10
```

# Con python

```
Omega=set([1,2,3,4,5,6,7,8,9,10])  
A=set([1,2,3,4,5])  
B=set([1,4,5])  
C=set([4,6,7,8])  
Omega
```

{1, 2, 3, 4, 5, 6, 7, 8, 9, 10}

# Con python

A

{1, 2, 3, 4, 5}

B

{1, 4, 5}

C

{8, 4, 6, 7}

# Con python

```
A & B    # intersección (&: and/y)
```

{1, 4, 5}

```
A | B    # unión (|: or/o)
```

{1, 2, 3, 4, 5}

# Con python

```
A - C    # diferencia
```

{1, 2, 3, 5}

```
Omega-C # complementario.
```

{1, 2, 3, 5, 9, 10}

## Lección 2

# Combinatoria

---

# Combinatoria. Introducción.

La combinatoria es una rama de la matemática discreta que entre otras cosas cuenta distintas configuraciones de objetos de un conjunto.

Por ejemplo si tenemos un equipo de baloncesto con 7 jugadores ¿cuántos equipos de 5 jugadores distintos podemos formar?

# Combinatoria. Número binomial.

## Número combinatorio o número binomial

Nos da el número de subconjuntos de tamaño  $k$  de un conjunto de tamaño  $n$ . Este número es

$$C_n^k = \binom{n}{k} = \frac{n!}{k! \cdot (n - k)!}.$$

Recordemos que

$$n! = 1 \cdot 2 \cdot 3 \cdots n.$$



## Combinatoria. Número binomial.

En nuestro caso con 7 jugadores  $n = 7$  el número de equipos distintos de  $k = 5$  es

$$\begin{aligned} C_7^5 &= \binom{7}{5} = \frac{7!}{5! \cdot (7-5)!} = \frac{7!}{5! \cdot 2!} \\ &= \frac{1 \cdot 2 \cdot 3 \cdot 4 \cdot 5 \cdot 6 \cdot 7}{1 \cdot 2 \cdot 3 \cdot 4 \cdot 5 \cdot 1 \cdot 2} = \frac{6 \cdot 7}{2} = \frac{42}{2} = 21. \end{aligned}$$

Puedo formar 21 equipos distintos.

### Ejercicio

Carga el paquete `gtools` de R y investiga la función `combinations(n, r, v, set, repeats.allowed)` para calcular todas las combinaciones anteriores.

## Combinatoria. Combinaciones con repetición

En combinatoria, las combinaciones con repetición de un conjunto son las distintas formas en que se puede hacer una selección de elementos de un conjunto dado, permitiendo que las selecciones puedan repetirse.

El número  $CR_n^k$  de multiconjuntos con  $k$  elementos escogidos de un conjunto con  $n$  elementos satisface:

- Es igual al número de combinaciones con repetición de  $k$  elementos escogidos de un conjunto con  $n$  elementos.
- Es igual al número de formas de repartir  $k$  objetos en  $n$  grupos.

$$CR_n^k = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}.$$

# Combinatoria. Combinaciones con repetición

## Ejemplo

Vamos a imaginar que vamos a repartir 12 caramelos entre Antonio, Beatriz, Carlos y Dionisio (que representaremos como A, B, C, D). Una posible forma de repartir los caramelos sería: dar 4 caramelos a Antonio, 3 a Beatriz, 2 a Carlos y 3 a Dionisio. Dado que no importa el orden en que se reparten, podemos representar esta selección como AAAABBBCCDDD.

Otra forma posible de repartir los caramelos podría ser: dar 1 caramelo a Antonio, ninguno a Beatriz y Carlos, los 11 restantes se los damos a Dionisio. Esta repartición la representamos como ADDDDDDDDDDDD

## Combinatoria. Combinaciones con repetición

Recíprocamente, cualquier serie de 12 letras A, B, C, D se corresponde a una forma de repartir los caramelos. Por ejemplo, la serie AAAABBBBBBDDDD corresponde a: Dar 4 caramelos a Antonio, 5 caramelos a Beatriz, ninguno a Carlos y 3 a Dionisio.

De esta forma, el número de formas de repartir los caramelos es:

$$CR_{n=4}^{k=12} = \binom{4 + 12 - 1}{12} = 455.$$

# Combinatoria. Variaciones.

## Variaciones

Con los número  $\{1, 2, 3\}$  ¿cuántos números de dos cifras distintas podemos formar sin repetir ninguna cifra?

La podemos escribir

12, 13, 21, 23, 31, 32

Luego hay seis casos

## Combinatoria. Variaciones (sin repetición).

Denotaremos las variaciones (sin repetición) de  $k$  elementos (de orden  $k$ ) de un conjunto de  $n$  elementos por  $V_n^k$  su valor es

$$V_n^k = \frac{n!}{(n-k)!} = (n-k+1) \cdot (n-k+2) \cdots n.$$

## Combinatoria. Variaciones.

En nuestro ejemplo con  $n = 3$  dígitos podemos escribir las siguientes variaciones de orden  $k = 2$

$$V_{n=3}^{k=2} = \frac{3!}{(3-2)!} = \frac{1 \cdot 2 \cdot 3}{1} = 6.$$

### Ejercicio

Carga el paquete `gtools` de R y investiga la función `permutations(n, r, v, set, repeats.allowed)` para calcular todas las variaciones anteriores.

# Combinatoria. Variaciones con repetición.

## Variaciones con repetición

¿Y repitiendo algún dígito?

$$VR_n^k = n^k$$

Efectivamente en nuestro caso

11, 12, 13, 21, 22, 23, 31, 32, 33

$$VR_{n=3}^{k=2} = n^k.$$



# Permutaciones

Las permutaciones de un conjunto de cardinal  $n$  son todas las variaciones de orden máximo  $n$ .  
Las denotamos y valen:

$$P_n = V_n^n = n!$$

# Permutaciones

Por ejemplo todos los números que se pueden escribir ordenando todos los dígitos  $\{1, 2, 3\}$  sin repetir ninguno

```
library(combinat)
for(permutacion in permn(3)) print(permutacion)
```

```
[1] 1 2 3
```

```
[1] 1 3 2
```

```
[1] 3 1 2
```

```
[1] 3 2 1
```

```
[1] 2 3 1
```

```
[1] 2 1 3
```

Efectivamente  $P_3 = 3! = 1 \cdot 2 \cdot 3$ .

# Permutaciones

## Ejercicio

Carga el paquete `combinat` de R e investiga la función `permn` para calcular todas las permutaciones anteriores.

## Ejercicio

Investiga el paquete `itertools` y la función `comb` de `scipy.misc` de Python e investiga sus funciones para todas las formas de contar que hemos visto en este tema.

## Ejercicio

La función gamma de Euler, cobrará mucha importancia en el curso de estadística. Comprueba que la función `gamma(x+1)` da el mismo valor que la función `factorial(x)` en R para todo  $x = \{1, 2, 3, \dots, 10\}$ .

## Números multinomiales. Permutaciones con repetición.

Consideremos un conjunto de elementos  $\{a_1, a_2, \dots, a_k\}$ .

Entonces, si cada uno de los objetos  $a_i$  de un conjunto, aparece repetido  $n_i$  veces para cada  $i$  desde 1 hasta  $k$ , entonces el número de permutaciones con elementos repetidos es:

$$PR_n^{n_1, n_2, \dots, n_k} = \binom{n}{n_1 \quad n_2 \quad \dots \quad n_k} = \frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!},$$

donde  $n = n_1 + n_2 + \dots + n_k$ .

# Números multinomiales. Permutaciones con repetición.

## Ejemplo

¿Cuántas palabras diferentes se pueden formar con las letras de la palabra PROBABILIDAD?

El conjunto de letras de la palabra considerada es el siguiente:  $\{A, B, D, I, L, O, P, R\}$  con las repeticiones siguientes: las letras A, B, D, e I, aparecen 2 veces cada una; y las letras L, O, P, R una vez cada una de ellas.

Por tanto, utilizando la fórmula anterior, tenemos que el número de palabras (permutaciones con elementos repetidos) que podemos formar es

$$PR_{12}^{2,2,2,2,1,1,1,1} = \frac{12!}{(2!)^4(1!)^4} = 29937600.$$

## Lección 3

Para acabar

# Principios básicos para contar cardinales de conjuntos

## El principio de la suma

Sean  $A_1, A_2, \dots, A_n$  conjuntos disjuntos dos a dos, es decir  $A_i \cap A_j = \emptyset$  para todo  $i \neq j$ ,  $i, j = 1, 2, \dots, n$ . Entonces

$$\#(\cup_{i=1}^n A_i) = \sum_{i=1}^n \#(A_i).$$

# Principios básicos para contar cardinales de conjuntos

## Principio de unión exclusión

Consideremos dos conjuntos cualesquiera  $A_1, A_2$  entonces el cardinal de su unión es

$$\#(A_1 \cup A_2) = \#(A_1) + \#(A_2) - \#(A_1 \cap A_2).$$



# Principios básicos para contar cardinales de conjuntos

## El principio del producto

Sean  $A_1, A_2, \dots, A_n$

$$\begin{aligned}\#(A_1 \times A_2 \times \dots \times A_n) &= \#(\{(a_1, a_2, \dots, a_n) \mid a_i \in A_i, i = 1, 2, \dots, n\}) \\ &= \prod_{i=1}^n \#(A_i).\end{aligned}$$

## Otros aspectos a tener en cuenta

Evidentemente nos hemos dejado muchas otras propiedades básicas de teoría de conjuntos y de combinatoria como:

- Propiedades de los números combinatorios.
- Binomio de Newton.
- Multinomio de Newton.

Si nos son necesarias las volveremos a repetir a lo largo del curso o bien daremos enlaces para que las podáis estudiar en paralelo.

# Tema 1: Probabilidad

Parte 1: Probabilidad con R y python

septiembre 2023

# Lección 1

## Probabilidades Básicas

## Definiciones básicas

Experimento aleatorio: experimento que repetido en las mismas condiciones puede dar resultados diferentes, pero que a largo plazo son predecibles

### Ejemplo

Tirar un dado de 6 caras y anotar el número de puntos de la cara superior.

Suceso elemental: cada uno de los posibles resultados del experimento aleatorio

### Ejemplo

Los sucesos elementales del ejemplo anterior son:



## Definiciones básicas

Espacio muestral: el conjunto  $\Omega$  formado por todos los sucesos elementales del experimento aleatorio

### Ejemplo

El espacio muestral del ejemplo anterior del dado es  $\Omega =$  las figuras de la caras anteriores



pero por comodidad, y en general pondremos

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

# Definiciones básicas

Suceso : Cualquier subconjunto del espacio muestral.

Alguno sucesos notables que merece la pena nombrar son:

- Suceso seguro o cierto:  $\Omega$
- Suceso imposible o vacío:  $\emptyset$
- Partes de un conjunto:  $\mathcal{P}(\Omega)$ : conjunto de todos los sucesos del experimento aleatorio (es decir, el conjunto de todos los subconjuntos de  $\Omega$ )

## Ejercicio

¿Cuántos elementos contiene el conjunto de partes de  $\Omega$  del experimento anterior?

## Ejemplo $n$ -grama

Se define un  $n$ -grama de una palabra como el conjunto de  $n$  letras consecutivas de la misma (contando los blancos de inicio y final de palabra que marcamos como “\_”).

### Ejemplo

Consideremos el experimento aleatorio que consiste en escoger al azar un 3-grama de la palabra “\_Baleares\_”. Vamos a escribir el espacio muestral y algunos sucesos elementales del mismo.

En este caso, si consideramos la palabra “\_Baleares\_”, el espacio muestral del experimento sería:

$$\Omega = \{\_Ba, Bal, ale, lea, ear, are, res, es\_ \}$$



## Ejemplo $n$ -grama

Algunos sucesos serían:

- 3-gramas que empiezan por  $a$ :  $\{ale, are\}$ .
- 3-gramas de inicio y final de palabra:  $\{\_Ba, es\_ \}$ .
- 3-gramas que contengan una  $l$ :  $\{Bal, ale, lea\}$ .

# Operaciones con sucesos

Si tenemos dos sucesos  $A, B \subseteq \Omega$ , podemos definir:

- $\Omega$ : *suceso total o seguro*.
- $\emptyset$ : *suceso vacío o imposible*.
- $A \cup B$ : *suceso unión*; el que ocurre si sucede  $A$  o  $B$ .
- $A \cap B$ : *suceso intersección*; el que ocurre si sucede  $A$  y  $B$ .
- $A^c$ : *suceso complementario* el que sucede si NO sucede  $A$ .
- $A - B = A \cap B^c$ : *suceso diferencia*, que acontece si sucede  $A$  y NO sucede  $B$ .

Sucesos incompatibles:  $A$  y  $B$  son *incompatibles* (o *disjuntos*) cuando  $A \cap B = \emptyset$ .

## Ejemplo género

### Ejemplo

Supongamos que el sexo se divide entre Mujeres y Hombres. Vamos a definir el espacio muestral, los sucesos elementales y a realizar algunas operaciones entre ellos.

- Estudiantes de esta clase:  $\Omega$ .
- Mujeres de esta clase:  $A$ .
- Estudiantes que son zurdos  $B$ .

Algunas operaciones entre los conjuntos:

- $A \cup B$ : Est. que son mujeres o que son zurdos.
- $A \cap B$ : Mujeres de esta clase que son zurdas.
- $A^c$ : Hombres de esta clase.
- $A - B$ : Mujeres de la clases que NO son zurdas.
- $B - A$ : Hombres de la clase que son zurdos.
- ¡Cuidado! No son incompatibles.

# Propiedades

Conmutativas:

$$A \cup B = B \cup A, \quad A \cap B = B \cap A$$




Asociativas:

$$A \cup (B \cup C) = (A \cup B) \cup C, \quad A \cap (B \cap C) = (A \cap B) \cap C$$

Distributivas:


$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C), \quad A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

# Propiedades


 $A$  $B \cap C$  $A \cup (B \cap C)$ 

# Propiedades


$$A \cup B$$



$$A \cup C$$






$$(A \cup B) \cap (A \cup C)$$



# Propiedades

Complementario del complementario

$$(A^c)^c = A$$


 $A$  $A^c$  $(A^c)^c$ 

# Propiedades


## Leyes de De Morgan

$$(A \cup B)^c = A^c \cap B^c$$

$A \cup B$



$(A \cup B)^c$








# Propiedades

## Leyes de De Morgan



$$(A \cup B)^c = A^c \cap B^c$$

 $A^c$  $B^c$  $A^c \cap B^c$ 

# Propiedades

## Leyes de De Morgan




$$(A \cap B)^c = A^c \cup B^c$$

 $A \cap B$  $(A \cap B)^c$ 

# Propiedades

## Leyes de De Morgan

$$(A \cap B)^c = A^c \cup B^c$$

 $A^c$  $B^c$  $A^c \cup B^c$ 

# Definición de probabilidad

La probabilidad de un suceso es una puntuación (*score*) numérico entre 0 y 1 que mide la verosimilitud de que este evento se produzca.

Esta verosimilitud puede estar justificada por:

- Estimación personal
- Estimación de expertos
- La frecuencia con la que se da
- Cálculo formal

# Definición de probabilidad

## Definición formal de probabilidad

Sea  $\Omega$  el espacio muestral de un experimento aleatorio. Supongamos que el número de posibles resultados, por el momento, es finito.

Una probabilidad sobre  $\Omega$  es una aplicación  $P : \mathcal{P}(\Omega) \rightarrow [0, 1]$  con las siguientes propiedades:

- 1  $0 \leq P(A) \leq 1$ , para todo suceso  $A$ .
- 2  $P(\Omega) = 1$ .
- 3 Si  $\{A_1, A_2, \dots, A_n\}$  son sucesos disjuntos dos a dos, entonces

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + P(A_2) + \dots + P(A_n)$$

Si  $a \in \Omega$  es un suceso elemental cometeremos el abuso de notación de poner  $P(a)$  en lugar de  $P(\{a\})$ .

## Ejemplo: grupos sanguíneos

### Ejemplo

En la página de la [Fundación Banco de Sangre y Tejidos de las Islas Baleares \(17-08-2023\)](#) podemos encontrar información sobre los porcentajes de tipos de sangre de los donantes de las Islas Baleares:

$$A : 46\%; \quad B : 7.5\%; \quad AB : 3.5\%; \quad O : 43\%.$$

¿Cuál es la probabilidad de que un balear donante de sangre no sea del tipo O?

## Ejemplo: grupos sanguíneos

**Experimento aleatorio:** tipo de sangre de un paciente humano:

$$\Omega = \{A, B, AB, O\}$$

**Probabilidad** de un suceso: se asimila al porcentaje observado de individuos.


**Suceso:**  $\{O\}^c = \{A, B, AB\}$ .

$$P(\{O\}^c) = P(\{A, B, AB\}) = P(A) + P(B) + P(AB) = 0.57.$$

# Propiedades

## Propiedades básicas de la probabilidad

- $P(\emptyset) = 0$ .
- $P(A - B) = P(A) - P(A \cap B)$  porque  $P(A) = P(A - B) + P(A \cap B)$ .




- Si  $B \subseteq A$ , entonces  $0 \leq P(B) \leq P(A)$ .
- $P(A^c) = 1 - P(A)$ .



# Propiedades

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$



# Propiedades

... de forma analítica


$$\begin{aligned}P(A) + P(B) - P(A \cap B) &= P(A - B) + P(A \cap B) \\&\quad + P(B - A) + P(A \cap B) - P(A \cap B) \\&= P(A - B) + P(A \cap B) + P(B - A) \\&= P(A \cup B).\end{aligned}$$

# Propiedades

Para la unión de tres conjuntos

i

$$P(A \cup B \cup C)$$



# Propiedades

... analíticamente

$$\begin{aligned} P(A \cup B \cup C) = & P(A) + P(B) + P(C) - P(A \cap B) \\ & - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C). \end{aligned}$$

Efectivamente tenemos que:

$$P(A \cup B \cup C) = P(1) + P(2) + P(3) + P(4) + P(5) + P(6) + P(7).$$

# Propiedades

- Si  $A = \{a_1, a_2, \dots, a_k\}$ , entonces

$$P(A) = P(a_1) + P(a_2) + \dots + P(a_k).$$

- Si todos los sucesos elementales tienen la misma probabilidad,

$$P(A) = \frac{|A|}{|\Omega|} \left( = \frac{\text{casos favorables}}{\text{casos posibles}} \right).$$

## Ejemplo: Frecuencia de vocales

### Ejemplo

Los porcentajes de vocales de un determinado idioma (de alfabeto latino) según la [Wikipedia](#) son:

$$A : 18.7\%; \quad E : 26.1\%; \quad I : 25.7\%; \quad O : 24.4\%; \quad U : 5.1\%.$$

¿Cuál es la probabilidad que una vocal escogida al azar de este idioma sea una E o una O?

El espacio muestral del experimento es  $\Omega = \{A, E, I, O, U\}$ .

El suceso que deseamos analizar es  $\{E, O\}$ .

Y su probabilidad es

$$P(\{E, O\}) = P(E) + P(O) = 0.261 + 0.244 = 0.505.$$

## Ejemplo: Consumo de drogas

Segun un artículo de [El País](#), en un control especial de la policía el 0.1% de todos los conductores analizados en un control de tráfico dan positivo en un el test en cocaína, y el 1% da positivo en cannabis. Un 1.05% da positivo en alguno de los dos test.

¿Cuál es la probabilidad que un individuo analizado en el control de drogas escogido al azar no de positivo en ninguno de lo dos test?

Los sucesos elementales del enunciado del problema son:

- $A$ : dar positivo en cocaína;  $P(A) = 0.001$ .
- $B$ : dar positivo en cannabis;  $P(B) = 0.01$ .

En este caso nos interesa estudiar los sucesos:

- $A \cup B$ : dar positivo en alguno de los dos test;  $P(A \cup B) = 0.0105$ .
- $(A \cup B)^c$ : no dar positivo en ninguno de los test,por tanto:

$$P((A \cup B)^c) = 1 - P(A \cup B) = 1 - 0.0105 = 0.9895.$$

## Ejemplo: Consumo de drogas

### Ejemplo

En un control especial de la policía el 0.1% de todos los conductores analizados en un control de tráfico dan positivo en un el test en cocaína, y el 1% da positivo en cannabis. Un 1.05% da positivo en alguno de los dos test.

¿Cuál es la probabilidad que un analizado al azar de positivo en los dos test en cocaína y cannabis?



## Ejemplo: Consumo de drogas

Los sucesos elementales son:

- $A$ : dar positivo en cocaína;  $P(A) = 0.001$ .
- $B$ : dar positivo en cannabis;  $P(B) = 0.01$ .

En este caso nos interesa estudiar los sucesos:

- $A \cup B$ : dar positivo en algún de los dos test;  $P(A \cup B) = 0.0105$ .
- $A \cap B$ : dar positivo en los dos test

## Ejemplo: Consumo de drogas

de donde, por tanto:

$$\begin{aligned}P(A \cap B) &= P(A) + P(B) - P(A \cup B) \\&= 0.001 + 0.01 - 0.0105 = 0.0005.\end{aligned}$$

## Ejemplo: Control de drogas

### Ejemplo

En un control especial de la policía el 0.1% de todos los conductores analizados en un control de tráfico dan positivo en un el test en cocaína, y el 1% da positivo en cannabis. Un 1.05% da positivo en alguno de los dos test.

¿Cuál es la probabilidad de que un conductor analizado de positivo en cocaína pero no en cannabis?

## Ejemplo: Consumo de drogas

Los sucesos elementales son:

- $A$ : dar positivo en cocaína;  $P(A) = 0.001$ .
- $B$ : dar positivo en cannabis;  $P(B) = 0.01$ .

En este caso nos interesa estudiar los sucesos:

- $A \cap B$ : dar positivo en los dos test;  $P(A \cap B) = 0.0005$ .
- $A - B$ : dar positivo en cocaína pero no en cannabis, por lo tanto tenemos que :

$$P(A - B) = P(A) - P(A \cap B) = 0.001 - 0.0005 = 0.0005.$$

## Lección 2

### Probabilidad condicionada

# Probabilidad condicionada

Probabilidad condicionada: Dados dos sucesos  $A$  y  $B$ , con  $P(A) > 0$ , la probabilidad  $P(B|A)$  de  $B$  condicionado a  $A$  es la probabilidad

- de que suceda  $B$  suponiendo que pasa  $A$ ,
- de que si pasa  $A$ , entonces suceda  $B$ ,
- de que un resultado de  $A$  también pertenezca a  $B$ .

Se calcula a través de la definición:

$$P(B|A) = \frac{P(A \cap B)}{P(A)}.$$

## Ejemplo: frecuencia género y gafas

### Ejemplo

En una clase de 20 hombres y 30 mujeres, 15 hombres y 18 mujeres llevan gafas. Contestemos las siguientes preguntas:

- ¿Cuál es la probabilidad de que un alumno lleve gafas?

$$\frac{33}{50}$$

- ¿Cuál es la probabilidad de que un alumno sea mujer y lleve gafas?

$$\frac{18}{50}$$

## Ejemplo: sexo y gafas

### Ejemplo

En una clase de 20 hombres y 30 mujeres, 15 hombres y 18 mujeres llevan gafas. Contestemos las siguientes preguntas:

- ¿Cuál es la probabilidad de que un chica lleve gafas?

$$\frac{18}{30} = \frac{18/50}{30/50} = \frac{P(\text{mujer y gafas})}{P(\text{mujer})}.$$

- Si escogemos un estudiante al azar ¿Cuál es la probabilidad que si es mujer, entonces lleve gafas?

$$\frac{18}{30}.$$



# Ejemplo

## Ejemplo

En una clase de 20 hombres y 30 mujeres, 15 hombres y 18 mujeres llevan gafas. Contestemos las siguientes preguntas:

- ¿Cuál es la probabilidad de que un alumno que lleve gafas sea mujer?

$$\frac{18}{33} = \frac{18/50}{33/50} = \frac{P(\text{mujer y gafas})}{P(\text{gafas})}.$$

- Si escogemos un estudiante al azar ¿Cuál es la probabilidad de que si lleva gafas, entonces sea mujer?

$$\frac{18}{33}$$

# ¡Atención!

Hay que distinguir bien entre

- $P(A \cap B)$ : probabilidad de  $A$  y  $B$ .

*Probabilidad de que sea mujer y lleve gafas.*

- $P(A|B)$ : probabilidad de que si pasa  $B$ , entonces pase  $A$ .

*Probabilidad de que, si es mujer, lleve gafas.*

Cuando utilizamos probabilidad condicional  $P(A|B)$  estamos restringiendo el espacio muestral a  $B$ .

## Probabilidad condicionada. Propiedades

La probabilidad condicionada es una probabilidad

Proposición

Sea  $A \subseteq \Omega$  un suceso tal que  $P(A) > 0$ , entonces

$$\begin{aligned} P(-|A) : \mathcal{P}(\Omega) &\rightarrow [0, 1] \\ B &\mapsto P(B|A). \end{aligned}$$

satisface las propiedades de las probabilidades, como por ejemplo:

$$\begin{aligned} P(B^c|A) &= 1 - P(B|A), \\ P(B_1 \cup B_2|A) &= P(B_1|A) + P(B_2|A) - P(B_1 \cap B_2|A). \end{aligned}$$

### Ejercicio

Escribid el resto de propiedades que cumpliría una probabilidad condicionada al evento  $A$ .

# Ejemplo

## Ejemplo

Un 15% de los adultos son hipertensos, un 25% de los adultos creen que son hipertensos, y un 9% de los adultos son hipertensos y creen que lo son.

Si un adulto cree que es hipertenso, ¿cuál es la probabilidad que lo sea?

## Ejemplo

Sean los sucesos

- $A$ : ser hipertenso,  $P(A) = 0.15$  ,
- $B$ : creer ser hipertenso,  $P(B) = 0.25$ ,

entonces podemos definir el suceso:

- $A \cap B$ : ser hipertenso y creerlo,  $P(A \cap B) = 0.09$ .

## Ejemplo

de donde, la probabilidad condicionada de ser hipertenso creyéndonos que lo somos es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0.09}{0.25} = 0.36.$$

## Ejemplo

### Ejemplo

Un 15% de los adultos son hipertensos, un 25% de los adultos creen que son hipertensos, y un 9% de los adultos son hipertensos y creen que lo son.

Si un adulto es hipertenso, ¿cuál es la probabilidad que crea que lo es?

Si tenemos los sucesos:

- $A$ : ser hipertenso,
- $B$ : creer ser hipertenso

entonces buscamos la probabilidad  $P(B|A)$ :

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{0.09}{0.15} = 0.6$$

## Ejemplos: dígitos de control

### Ejemplo

Un dígito de control de error toma el valor 0 en el 99% de los casos en que hay un error. Si la probabilidad de error en un mensaje es del 0.5%. ¿cuál es la probabilidad de que el mensaje sea erróneo y el código de error tenga valor 0?

- $B$ : mensaje con error;  $P(B) = 0.005$ ,
- $A$ : código de error vale 0,
- $P(A|B) = 0.99$ ,

entonces:

$$P(A \cap B) = P(B) \cdot P(A|B) = 0.005 \cdot 0.99 = 0.00495.$$



# Ejemplos

## Ejemplo: SPAM

Un 50% de correos recibidos en un servidor llevan adjuntos y un 65% son publicidad no deseada (SPAM). Sólo un 15% de estos correos no llevan adjuntos y no son SPAM.

- ¿Cuál es la probabilidad que un correo lleve adjunto si es SPAM?
- ¿Cuál es la probabilidad que un correo **no** tenga adjuntos si **no** es SPAM?

# Ejemplos

## Ejemplo

Un 50% de correos recibidos en un servidor llevan adjuntos y un 65% son publicidad no deseada (SPAM). Sólo un 15% de estos correos no llevan adjuntos y no son SPAM.

- ¿Cuál es la probabilidad que un correo lleve adjunto si es SPAM?
- $A$ : llevar adjuntos;  $P(A) = 0.5$ ,
- $S$ : SPAM;  $P(S) = 0.65$ ,
- $A^c \cap S^c = (A \cup S)^c$ : no llevar adjunto y no ser SPAM;  $P((A \cup S)^c) = 0.15$ ,

$$P(A|S) = \frac{P(A \cap S)}{P(S)} = ?$$

# Ejemplos

## Ejemplo

Un 50% de correos recibidos en un servidor llevan adjuntos y un 65% son publicidad no deseada (SPAM). Sólo un 15% de estos correos no llevan adjuntos y no son SPAM.

- ¿Cuál es la probabilidad que un correo lleve adjunto si es SPAM?
- $P(A) = 0.5, P(S) = 0.65, P(A^c \cap S^c) = P((A \cup S)^c) = 0.15,$
- $P(A \cup S) = 1 - P((A \cup S)^c) = 0.85,$
- $P(A \cap S) = P(A) + P(S) - P(A \cup S) = 0.3,$

$$P(A|S) = \frac{P(A \cap S)}{P(S)} = \frac{0.3}{0.65} \approx 0.46.$$

## Ejemplos SPAM continuación

### Ejemplo

Un 50% de correos recibidos en un servidor llevan adjuntos y un 65% son publicidad no deseada (SPAM). Sólo un 15% de estos correos no llevan adjuntos y no son SPAM.

- ¿Cuál es la probabilidad de que un correo no lleve adjuntos si no es SPAM?
- $P(A) = 0.5, P(S) = 0.65, P(A^c \cap S^c) = P((A \cup S)^c) = 0.15$ .

$$P(A^c|S^c) = \frac{P(A^c \cap S^c)}{P(S^c)} = \frac{P(A^c \cap S^c)}{1 - P(S)} = \frac{0.15}{0.35} \approx 0.43.$$

# Teorema de la probabilidad total

Teorema de la probabilidad total

Dados dos sucesos  $A$  y  $B$  se tiene que

$$\begin{aligned}P(B) &= P(B \cap A) + P(B \cap A^c) \\ &= P(A) \cdot P(B|A) + P(A^c) \cdot P(B|A^c).\end{aligned}$$

## Teorema de la probabilidad total

### Partición del espacio muestral

Los sucesos  $A_1, A_2, \dots, A_n$  son una **partición** del espacio muestral  $\Omega$  de un determinado experimento aleatorio, si cumplen las condiciones siguientes:

- ①  $A_1 \cup A_2 \cup \dots \cup A_n = \Omega$ ,
- ②  $A_1, A_2, \dots, A_n$  son incompatibles dos a dos ( $A_i \cap A_j = \emptyset$ ).

### Teorema de la probabilidad total

Sea  $A_1, A_2, \dots, A_n$  una partición de  $\Omega$ . Sea  $B$  un suceso cualquiera. Entonces

$$\begin{aligned} P(B) &= P(B \cap A_1) + \dots + P(B \cap A_n) \\ &= P(A_1) \cdot P(B|A_1) + \dots + P(A_n) \cdot P(B|A_n). \end{aligned}$$

# Ejemplos

## Ejemplo

Un dígito de control de error toma el valor 0 en un 99% de los casos en que hay un error y en un 5% de los mensajes sin error. La probabilidad de error en un mensaje es del 0.5%.

¿Cuál es la probabilidad de que un mensaje escogido al azar tenga el dígito de control a 0?

## Ejemplo

Sean los sucesos del enunciado:

- $B$ : mensaje con error;  $P(B) = 0.005$ ,
- $A$ : código de error vale 0,

entonces obtenemos las probabilidades a partir del enunciado:

- $P(A|B) = 0.99$ ,
- $P(A|B^c) = 0.05$



## Ejemplo

y por tanto,

$$\begin{aligned} P(A) &= P(B) \cdot P(A|B) + P(B^c) \cdot P(A|B^c) \\ &= 0.005 \cdot 0.99 + 0.995 \cdot 0.05 = 0.0547. \end{aligned}$$

# Clasificación o Diagnósticos

Consideremos alguna de las siguientes situaciones:

- Un algoritmo detecta si una transacción con tarjeta de crédito es fraude o no.
- Un algoritmo detecta si tiene o no que mostrar un anuncio en una web.
- Un prueba de embarazo.
- Una prueba médica para una enfermedad concreta.

Nos ceñiremos a la casuística más elemental el algoritmo de clasificación o la diagnosis solo da dos resultado **Positivo** (sí tienes la enfermedad, sí es un fraude) o **Negativo** (en caso contrario).

## Clasificación o Diagnósticos

En todas estas situaciones podemos calcular lo que se llama **matriz de confusión** que representa todas las situaciones posibles. En el caso de estudiar una condición de tipo binario,

	El Test da Positivo	El Test da Negativo
Condición Positiva	Correcto	Error
Condición Negativa	Error	Correcto

# Clasificación o Diagnósticos

En general los modelos y algoritmos de clasificación suelen aportar puntuaciones (*scores*) que determinan el grado de pertenencia a una clase, o que miden si dos objetos están en la misma clase.

Así el resultado del clasificador o del diagnóstico puede ser:

- **un número real**, en cuyo caso debe clasificarse entre cada clase debe determinarse por un valor umbral (*threshold*) por ejemplo para determinar si una persona está estresado podemos dar un *scores* entre 0 y 1 (1 máximo estrés 0 estrés nulo),
- **un resultado discreto** que indica directamente una de las clases (esto es necesario si es un algoritmo que debe decidir qué hacer con el objeto).

# Clasificación o Diagnósticos

Positivos y Negativos Consideremos un problema de predicción de clases binario, en la que los resultados se etiquetan positivos (P) o negativos (N). Hay cuatro posibles resultados a partir de un clasificador binario como el propuesto.

- Si el resultado de una exploración es P y el valor dado es también P, entonces se conoce como un Verdadero Positivo (VP).
- Sin embargo si el valor real es N entonces se conoce como un Falso Positivo (FP).
- De igual modo, tenemos un Verdadero Negativo (VN) cuando tanto la exploración como el valor dado son N.
- Un Falso Negativo (FN) cuando el resultado de la predicción es N pero el valor real es P.

# Clasificación o Diagnósticos

Un ejemplo aproximado de un problema real es el siguiente: consideremos una prueba diagnóstica que persiga determinar si una persona tiene una cierta enfermedad.

- Un falso positivo en este caso ocurre cuando la prueba predice que el resultado es positivo, cuando la persona no tiene realmente la enfermedad.
- Un falso negativo, por el contrario, ocurre cuando el resultado de la prueba es negativo, sugiriendo que no tiene la enfermedad cuando realmente sí la tiene.

# Clasificación o Diagnósticos

En un diagnósticos de una cierta condición (por ejemplo, test embarazo, test de enfermedad), tenemos dos tipos de sucesos:

- $T$ : el test da positivo,
- $M$ : el sujeto satisface la condición.

## Falsos Positivos y Falsos Negativos

- **Falsos positivos**  $T \cap M^c$ : El test da positivo, pero la condición no se da,
- **Coeficiente de falsos positivos**  $P(T|M^c)$ ,
- **Falsos negativos**  $T^c \cap M$ : El test da negativo, pero la condición sí que se da,
- **Coeficiente de falsos negativos**:  $P(T^c|M)$ .

# Clasificación o Diagnósticos

## Ejemplo

Un test diseñado para diagnosticar una determinada enfermedad tiene un coeficiente de falsos negativos de 0.06, y un coeficiente de falsos positivos de 0.04. En un estudio masivo se observa que un 15% de la población da positivo al test.

¿Cuál es la probabilidad que una persona escogida aleatoriamente tenga esta enfermedad?

Los datos del problema son:

- $T$ : dar positivo al test;  $P(T) = 0.15$ ,
- $M$ : tener la enfermedad,
- $P(T) = 0.15$ ,  $P(T^c|M) = 0.06$ ,  $P(T|M^c) = 0.04$ ,
- ¿ $P(M)$ ?



## Ejemplos

- $P(T) = 0.15$ ,  $P(T^c|M) = 0.06$ ,  $P(T|M^c) = 0.04$ .

$$P(T) = P(M) \cdot P(T|M) + P(M^c) \cdot P(T|M^c).$$

donde

$$\begin{aligned} P(T|M) &= 1 - P(T^c|M) = 0.94 \\ P(M^c) &= 1 - P(M). \end{aligned}$$

Por lo tanto

$$\begin{aligned} 0.15 &= P(M) \cdot 0.94 + (1 - P(M)) \cdot 0.04 \\ &= 0.04 + 0.9 \cdot P(M) \\ P(M) &= \frac{0.11}{0.9} \approx 0.1222. \end{aligned}$$

## Lección 3

### Bayes

# Fórmula de Bayes

## Teorema de Bayes

Sean  $A$  y  $B$  dos sucesos. Si  $P(B) > 0$ , entonces

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)} = \frac{P(A) \cdot P(B|A)}{P(A) \cdot P(B|A) + P(A^c) \cdot P(B|A^c)}.$$

## Ejercicio

Demostrar el teorema de Bayes utilizando que

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \dots$$

# Fórmula de Bayes

## Teorema de Bayes

Sea  $A_1, A_2, \dots, A_n$  una partición de  $\Omega$ . Sea  $B$  un suceso tal que  $P(B) > 0$ . entonces(para cualquier  $i = 1, 2, \dots, n$ ):

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i) \cdot P(B|A_i)}{P(B)} \\ &= \frac{P(A_i) \cdot P(B|A_i)}{P(A_1) \cdot P(B|A_1) + \dots + P(A_n) \cdot P(B|A_n)}, \end{aligned}$$

## Ejercicio

Demostrar el teorema de Bayes utilizando que

$$P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \dots$$

# Ejemplos

## Ejemplo

Un test para detección de VIH da positivo un 99% de los casos en los que está presente y en un 5% de los casos en los que el virus está ausente. En una población con un 0.5% de infectados por VIH, ¿cuál es la probabilidad que un individuo que haya dado positivo en el test esté infectado?

Los sucesos del ejemplo son:

- $A$ : individuo infectado,
- $B$ : el test da positivo,

de donde podemos calcular:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B|A) \cdot P(A) + P(B|A^c) \cdot P(A^c)} = \frac{0.99 \cdot 0.005}{0.005 \cdot 0.99 + 0.995 \cdot 0.05} = 0.09.$$

# Ejemplos

## Ejemplo

Un test para detección de VIH da positivo un 99% de los casos en los que está presente y en un 5% de los casos en los que el virus está ausente. En una población con un 0.5% de infectados por VIH, ¿cuál es la probabilidad de que un individuo que haya dado **negativo** en el test **no** esté infectado?

Los sucesos del ejemplo son:

- $A$ : individuo infectado,
- $B$ : el test da positivo,

de donde podemos calcular:

$$P(A^c|B^c) = \frac{P(B^c|A^c) \cdot P(A^c)}{P(B^c|A) \cdot P(A) + P(B^c|A^c) \cdot P(A^c)} = \frac{0.95 \cdot 0.995}{0.01 \cdot 0.005 + 0.95 \cdot 0.995} = 0.999947.$$

# Ejemplos

## Ejercicio

Se ha observado que los clientes de una empresa de ventas por internet son de tres tipos, A, B y C, disjuntos dos a dos. La probabilidad que ser de cualquiera de cada uno de los tipos es  $1/3$ , pero la probabilidad de compra de cada tipo es diferente: si es de tipo A compra un 50% de las veces, si de tipo B, un 75% de las veces, y de tipo C, un 60%.

Supongamos que llega un cliente ¿cuál es la probabilidad de que si ha comprado sea del tipo B?

- Los sucesos del ejercicio son  $A$ : el cliente es de tipo A,  $B$ : el cliente es de tipo B,  $C$ : el cliente es de tipo C y

$$P(A) = P(B) = P(C) = 1/3.$$

Buscamos estudiar el suceso  $E$ : el cliente compra, se tiene que:

# Ejemplos

## Ejercicio

Un test de detección precoz de abandono de clientes de una empresa de telefonía da positivo el 97.5% de las ocasiones en las que, posteriormente, el cliente se da de baja, y un 12% de las veces en que no se dio de baja. La probabilidad que un cliente escogido al azar se dé de baja es de un 2%.

- ¿Cuál es la probabilidad que un individuo escogido al azar de positivo en el test?
- ¿Cuál es la probabilidad que un individuo escogido al azar se de de baja y dé positivo en el test?
- ¿Cuál es la probabilidad que un individuo que dé negativo en el test se dé de baja?

Definimos los sucesos y datos del ejercicio:

- $T$ : Dar positivo al test,
- $B$ : darse de baja;  $P(B) = 0.02$ ,
- $P(T|B) = 0.975, P(T|B^c) = 0.12$ .



## Ejemplos

$$P(B) = 0.02, P(T|B) = 0.975, P(T|B^c) = 0.12.$$

- ¿Cuál es la probabilidad que un individuo escogido al azar de positivo en el test?

$$\begin{aligned} P(T) &= P(B) \cdot P(T|B) + P(B^c) \cdot P(T|B^c) \\ &= 0.02 \cdot 0.975 + 0.98 \cdot 0.12 = 0.1371. \end{aligned}$$

- ¿Cuál es la probabilidad que un individuo escogido al azar se de de baja y dé positivo en el test?

$$P(B \cap T) = P(B) \cdot P(T|B) = 0.02 \cdot 0.975 = 0.0195.$$

# Ejemplos

$$P(B) = 0.02, P(T|B) = 0.975, P(T|B^c) = 0.12.$$

- ¿Cuál es la probabilidad que un individuo que dé negativo en el test se dé de baja?

$$\begin{aligned} P(B|T^c) &= \frac{P(B \cap T^c)}{P(T^c)} = \frac{P(B) - P(B \cap T)}{1 - P(T)} \\ &= \frac{0.02 - 0.0195}{1 - 0.1371} \approx 0.00058 \end{aligned}$$

- O también se obtiene así

$$P(B|T^c) = \frac{P(T^c|B) \cdot P(B)}{P(T^c|B) \cdot P(B) + P(T^c|B^c) \cdot P(B^c)},$$

donde  $P(T^c|B) = 1 - P(T|B) = 0.025$  y  $P(T^c|B^c) = 1 - P(T|B^c) = 0.88$ .

## Lección 4

# Independencia de sucesos

---

# Sucesos independientes

## Sucesos Independientes

Diremos que los sucesos  $A$  y  $B$  son **independientes** si  $P(A \cap B) = P(A) \cdot P(B)$ .

$A_1, \dots, A_n$  son sucesos **independientes** cuando, para toda subfamilia  $A_{i_1}, \dots, A_{i_k}$ ,

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \dots P(A_{i_k}).$$

# Sucesos independientes

## Proposición

Dados dos sucesos  $A$  y  $B$  con  $P(A), P(B) > 0$ , las siguientes afirmaciones son equivalentes:

- 1  $A$  y  $B$  son independientes.
- 2  $P(A|B) = P(A)$ .
- 3  $P(B|A) = P(B)$ .

# Sucesos independientes

## Proposición

Las siguientes afirmaciones son equivalentes:

- 1  $A$  y  $B$  son independientes
- 2  $A^c$  y  $B$  son independientes.
- 3  $A$  y  $B^c$  son independientes.
- 4  $A^c$  y  $B^c$  son independientes.

## Ejemplo billete avión

### Ejemplo

En la web de viajes WEBTravel, el 55% de los clientes compra billete de avión, el 20% alojamiento en hotel, y el 60% billete de avión o alojamiento en hotel. ¿Son los sucesos comprar billete de avión y comprar alojamiento en hotel independientes?

Los sucesos y datos del ejemplo son:

- $A$ : comprar billete de avión;  $P(A) = 0.55$ ,
- $B$ : comprar alojamiento;  $P(B) = 0.2$ ,

por tanto, podemos calcular las probabilidades siguientes

$$P(A \cap B) = P(A) + P(B) - P(A \cup B) = 0.55 + 0.2 - 0.6 = 0.15 \text{ y}$$
$$P(A) \cdot P(B) = 0.55 \cdot 0.2 = 0.11.$$

Concluimos que son dependientes, ya que  $P(A \cap B) \neq P(A) \cdot P(B)$ .

# Sucesos independientes vs disjuntos

## Ejercicio

- 1 Dos sucesos  $A$  y  $B$  disjuntos, ¿son necesariamente independientes?
- 2 Dos sucesos  $A$  y  $B$  independientes, ¿son necesariamente disjuntos?
- 3  $\emptyset$  y un suceso cualquiera  $A$ , ¿son necesariamente independientes?
- 4  $\Omega$  y un suceso cualquiera  $A$ , ¿son necesariamente independientes?
- 5 ¿Qué condiciones se tienen que dar para que un suceso  $A$  sea independiente de si mismo?



## Tema 2: Variables aleatoria

Parte 1: Probabilidad con R y python

septiembre 2023

# Lección 1

## Introducción a las variables aleatorias

# Introducción

- Hasta ahora nuestros sucesos han sido de varios tipos:  $\{C, +\}$  en la moneda, nombres de periódicos, ángulos en una ruleta, número de veces que sale cara en el lanzamiento de una moneda etc....
- Necesitamos estandarizar de alguna manera todos estos sucesos. Una solución es asignar a cada suceso un cierto conjunto de números reales, es decir, convertir todos los sucesos en *sucesos de números reales* para trabajar con ellos de forma unificada.
- Para conseguirlo utilizaremos unas funciones que transformen los elementos del espacio muestral en números; estas funciones son las variables aleatorias.

# Definición de variable aleatoria

Comenzaremos dando una definición poco rigurosa, pero suficiente, de variable aleatoria.

Variable Aleatoria (definición práctica)

Una variable aleatoria (v.a.) es una aplicación que toma valores numéricos determinados por el resultado de un experimento aleatorio

**Notación:**

- Normalmente representaremos las v.a. por letras mayúsculas  $X, Y, Z \dots$
- Los valores que “*toman*” las v.a. los representaremos por letras minúsculas (las mismas en principio)  $x, y, z \dots$

# Ejemplo

## Ejemplo

Lanzamos un dado convencional de parchís el espacio muestral del experimento es

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Una v.a  $X : \Omega \rightarrow \mathbb{R}$  sobre este espacio queda definida por

$$X(1) = 1, X(2) = 2, X(3) = 3, X(4) = 4, X(5) = 5, X(6) = 6.$$

- Ahora el suceso  $A = \{2, 4, 6\}$ , es decir “salir número par”, es equivalente a  $\{X = 2, X = 4, X = 6\}$ .
- El suceso  $B = \{1, 2, 3\}$ , es decir “salir un número inferior o igual a 3” es en términos de la v.a.  $\{X = 1, X = 2, X = 3\}$  o también  $\{X \leq 3\}$ .

# Ejemplo

## Ejemplo

Consideremos el experimento lanzar una anilla al cuello de una botella. Si acertamos a ensartar la anilla en la botella el resultado del experimento es **éxito** y **fracaso** en caso contrario.

El espacio muestral asociado a este experimento será  $\Omega = \{\text{éxito}, \text{fracaso}\}$ . Construyamos la siguiente variable aleatoria:

$$X : \{\text{éxito}, \text{fracaso}\} \rightarrow \mathbb{R}$$

definida por

$$X(\text{éxito}) = 1 \text{ y } X(\text{fracaso}) = 0.$$

# Tipos de variables aleatorias

Hay dos tipos fundamentales de variables aleatorias, las discretas y las continuas.

Damos a continuación una definición informal.

## Variables Aleatorias Discretas y Continuas

- Una variable aleatoria es **discreta** si sólo puede tomar una cantidad numerable de valores con probabilidad positiva.
- Las variables aleatorias **continuas** toman valores en intervalos.
- También existen las variables aleatorias **mixtas**; con una parte discreta y otra continua.

# Ejemplo

## Ejemplo

Son variables *aleatorias discretas*:

- Número de artículos defectuosos en un cargamento.
- Número de clientes que llegan a una ventanilla de un banco en una hora.
- Número de errores detectados en las cuentas de una compañía.
- Número de reclamaciones de una póliza de un seguro médico.

Son variables *aleatorias continuas*:

- Renta anual de una familia.
- Cantidad de petróleo importado por un país.
- Variación del precio de las acciones de una compañía de telecomunicaciones.
- Porcentaje de impurezas en un lote de productos químicos.



## Lección 2

### Variables aleatorias discretas

## Distribuciones de probabilidad para v.a. discretas.

- Pasamos ahora a describir el comportamiento de la v.a. Para ello utilizaremos distintas funciones que nos darán algunas probabilidades de la variable aleatoria.
- En el caso discreto estas funciones son la de probabilidad, y la función de distribución o de probabilidad acumulada.
- En el caso discreto la función de probabilidad es la que nos da las probabilidades de los sucesos elementales de la v.a. que definimos a continuación.

# Función de probabilidad para variables discretas

## Función de Probabilidad

La **función de probabilidad** (*probability mass function* o incluso abusando de notación *probability density function*) de una variable aleatoria discreta  $X$  a la que denotaremos por  $P_X(x)$  está definida por

$$P_X(x) = P(X = x),$$

es decir la probabilidad de que  $X$  tome el valor  $x$ .

Si  $X$  no asume ese valor  $x$ , entonces  $P_X(x) = 0$ .

# Función de probabilidad discreta

## Dominio de una variable aleatoria discreta

El conjunto

$$D_X = \{x \in \mathbb{R} \mid P_X(x) > 0\}$$

recibe el nombre de **dominio** de la v.a. y son los valores posibles de esta variable.

En el caso discreto lo más habitual es que  $X(\Omega) = D_X$ .

## Ejemplo

### Ejemplo: parchís

Lanzamos un dado de parchís una vez, en esta ocasión representaremos los sucesos elementales por el número de puntos de la cara obtenida, tenemos que

$$\Omega = \{1\text{-puntos}, 2\text{-puntos}, 3\text{-puntos}, 4\text{-puntos}, 5\text{-puntos}, 6\text{-puntos}\}$$

y la variable aleatoria  $X : \Omega \rightarrow \mathbb{R}$  viene definida por

$$X(i\text{-puntos}) = i \text{ para } i = 1, 2, 3, 4, 5, 6.$$

Supongamos que el dado está bien balanceado. Entonces

$$P_X(1) = P_X(2) = P_X(3) = P_X(4) = P_X(5) = P_X(6) = \frac{1}{6}; \text{ concretamente.}$$

$$P_X(x) = \begin{cases} \frac{1}{6}, & \text{si } x = 1, 2, 3, 4, 5, 6. \\ 0 & \text{en otro caso.} \end{cases}$$

## Ejemplo

### Ejemplo: lanzamiento moneda

Sea  $X$  la v.a. asociada al lanzamiento de una moneda. Su espacio muestral es  $\Omega = \{c, +\}$ , la v.a. queda definida por:

$$X(\omega) = \begin{cases} 1 & \text{si } \omega = c \\ 0 & \text{si } \omega = + \end{cases}$$

Su función de probabilidad es:

$$P_X(x) = P(X = x) = \begin{cases} \frac{1}{2}, & \text{si } x = 0, 1, \\ 0, & \text{en otro caso.} \end{cases}$$

Finalmente su dominio es  $D_X = \{0, 1\}$ .

# Ejemplo

## Ejemplo urna con bolas

Tenemos una urna con tres bolas rojas, una negra y dos blancas. Realizamos una extracción y observamos el color de la bola entonces un espacio muestral es

$$\Omega = \{roja, blanca, negra\}.$$

Una variable aleatoria asociada al experimento es:

$$X(\omega) = \begin{cases} 1, & \text{si } \omega = roja, \\ 2, & \text{si } \omega = negra, \\ 3, & \text{si } \omega = blanca. \end{cases}$$

## Ejemplo

La función de probabilidad es

$$P_X(x) = \begin{cases} \frac{3}{6}, & \text{si } x = 1, \\ \frac{1}{6}, & \text{si } x = 2, \\ \frac{2}{6}, & \text{si } x = 3, \\ 0 & \text{en otro caso.} \end{cases}$$

El dominio de la v.a.  $X$  es  $D_X = \{1, 2, 3\}$ .



# Propiedades de la función de probabilidad.

## Propiedades básicas de la función de probabilidad

Sea  $X$  una v.a. discreta  $X : \Omega \rightarrow \mathbb{R}$  con dominio  $D_X$ . Su función de probabilidad  $P_X$  verifica las siguientes propiedades:

- $0 \leq P_X(x) \leq 1$  para todo  $x \in \mathbb{R}$ ,
- $\sum_{x \in D_X} P_X(x) = 1$ .

## Ejemplo

### Ejemplo: Lanzamiento moneda

Lanzamos al aire tres veces, de forma independiente, una moneda perfecta. El espacio muestral de este experimento es

$$\Omega = \{ccc, cc+, c+c, +cc, c++, +c+, ++c, +++\}$$

(expresados en orden de aparición).

Este espacio tiene todos los sucesos elementales equiprobables.

Consideremos la variable aleatoria asociada a este experimento:

$$X = \text{número de caras en los tres lanzamientos.}$$

## Ejemplo

Su función de probabilidad es:

$$\begin{aligned}P(X = 0) &= P(\{+++ \}) = \frac{1}{8}, \\P(X = 1) &= P(\{c++ , +c+ , ++c \}) = \frac{3}{8}, \\P(X = 2) &= P(\{cc+ , c+c , +cc \}) = \frac{3}{8}, \\P(X = 3) &= P(\{ccc \}) = \frac{1}{8}.\end{aligned}$$

## Ejemplo

Podemos reescribir la función de probabilidad de  $X$  de forma simplificada:

$$P_X(x) = \begin{cases} \frac{1}{8}, & \text{si } x = 0, 3, \\ \frac{3}{8}, & \text{si } x = 1, 2, \\ 0, & \text{en otro caso.} \end{cases}$$

Efectivamente los valores de la función de distribución suman 1:

$$\sum_{x=0}^3 P_X(x) = \frac{1}{8} + \frac{3}{8} + \frac{3}{8} + \frac{1}{8} = 1.$$

# Función de distribución de variables aleatorias

## Distribución de Probabilidad

La función de *distribución de probabilidad* (acumulada) de la v.a.  $X$  (de cualquier tipo; discreta o continua)  $F_X(x)$  representa la probabilidad de que  $X$  tome un menor o igual que  $x$ , es decir,

$$F_X(x) = P(X \leq x).$$

Esta función también se denomina función de **distribución de probabilidad o simplemente función de distribución** de una v.a., y en inglés *cumulative distribution function* por lo que se abrevia con el acrónimo cdf.

# Propiedades

## Propiedades de la Función de Distribución

Sea  $X$  una v.a. y  $F_X$  su función de distribución:

- ①  $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$ .
- ② Sea  $a$  y  $b$  tales que  $a < b$ ,  $P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$ .

# Propiedades

## Demostración:

Tenemos que el complementario de  $X$  mayor que  $x$  es:  $\overline{\{X > x\}} = \{X > x\}^c = \{X \leq x\}$ .  
Además,

$$P(X > x) = 1 - P(\overline{\{X > x\}}) = 1 - P(X \leq x) = 1 - F_X(x),$$

lo que demuestra la primera propiedad.

Por otro lado, si  $X$  se encuentra entre dos valores  $a$  y  $b$   
 $\{a < X \leq b\} = \{X \leq b\} - \{X \leq a\}$ . Ahora podemos hacer

$$\begin{aligned} P(a < X \leq b) &= P(\{X \leq b\} - \{X \leq a\}) \\ &= P(\{X \leq b\}) - P(\{X \leq a\}) \\ &= F_X(b) - F_X(a). \end{aligned}$$

# Propiedades

## Propiedades de la Función de Distribución

Sea  $F_X$  la función de distribución de una v.a.  $X$  entonces:

- $0 \leq F_X(x) \leq 1$ .
- La función  $F_X$  es no decreciente.
- La función  $F_X$  es continua por la derecha.
- Si denotamos por  $F_X(x_0^-) = \lim_{x \rightarrow x_0^-} F(x)$ , entonces se cumple que  $P(X < x_0) = F_X(x_0^-)$  y que  $P(X = x_0) = F_X(x_0) - F_X(x_0^-)$ .



# Propiedades

## Propiedades de la Función de Distribución

- Se cumple que  $\lim_{x \rightarrow \infty} F_X(x) = 1$ ;  $\lim_{x \rightarrow -\infty} F_X(x) = 0$ .
- Toda función  $F$  verificando las propiedades anteriores es función de distribución de alguna v.a.  $X$ .

## Advertencia desigualdades estrictas

En las propiedades anteriores no se pueden cambiar en general las desigualdades de estrictas o no estrictas.

Veamos que propiedades tenemos cuando se cambian estas desigualdades.

Dada una  $F_X$  una función de distribución de la v.a.  $X$  y denotamos por

$$F_X(x_0^-) = \lim_{x \rightarrow x_0^-} F_X(x),$$

,

entonces se cumplen las siguientes igualdades...

# Advertencia desigualdades estrictas

## Propiedades

- $P(X = x) = F_X(x) - F_X(x^-)$ .
- $P(a < X < b) = F_X(b^-) - F_X(a)$ .
- $P(a \leq X < b) = F_X(b^-) - F_X(a^-)$ .
- $P(X < a) = F_X(a^-)$ ,
- $P(a \leq X \leq b) = F_X(b) - F_X(a^-)$ .
- $P(X \geq a) = 1 - F_X(a^-)$ .

# Propiedades

Más propiedades de la función de distribución

- Si  $F_X$  es continua en  $x$  se tiene que  $P(X = x) = 0$ . Así que si la v.a. es continua  $P(X \leq a) = P(X < a) + P(X = a) = P(X < a)$  y propiedades similares.
- Sea  $X$  una variable aleatoria discreta que con dominio  $D_X$  y que tiene por función de probabilidad  $P_X(x)$  entonces su función de distribución  $F_X(x_0)$  es

$$F_X(x_0) = \sum_{x \leq x_0} P_X(x),$$

donde  $\sum_{x \leq x_0}$  indica que sumamos todos los  $x \in D_X$  tales que  $x \leq x_0$ .

# Propiedades

## Demostración:

Si  $X$  es continua,

$$P(X = a) = F(a) - F(a^-) = F(a) - F(a) = 0$$

por lo tanto

$$P(X \leq a) = P(X < a) + P(X = a) = P(X < a) + 0 = P(X < a),$$

lo que demuestra la primera propiedad.

Para demostrar la segunda basta hacer

$$F_X(x_0) = P(X \leq x_0) = P\left(\bigcup_{x \leq x_0; x \in D_X} \{x\}\right) = \sum_{x \leq x_0} P(X = x) = \sum_{x \leq x_0} P_X(x).$$

# Ejemplo

## Ejemplo: dado (continuación)

En el experimento del dado se tiene que:

$$P_X(x) = \begin{cases} \frac{1}{6}, & \text{si } x = 1, 2, 3, 4, 5, 6 \\ 0, & \text{en el resto de casos.} \end{cases}$$

por lo tanto

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 1, \\ \frac{1}{6}, & \text{si } 1 \leq x < 2, \\ \frac{2}{6}, & \text{si } 2 \leq x < 3, \\ \frac{3}{6}, & \text{si } 3 \leq x < 4, \\ \frac{4}{6}, & \text{si } 4 \leq x < 5, \\ \frac{5}{6}, & \text{si } 5 \leq x < 6, \\ 1, & \text{si } 6 \leq x. \end{cases}$$

## Ejemplo

Calculemos más detalladamente algún valor de  $F_X$ , por ejemplo:

$$\begin{aligned} F_X(3.5) &= P(X \leq 3.5) = P(\{X = 1\} \cup \{X = 2\} \cup \{X = 3\}) \\ &= P(\{X = 1\}) + P(\{X = 2\}) + P(\{X = 3\}) \\ &= \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2}, \end{aligned}$$

o de otra forma

$$F_X(3.5) = \sum_{x \leq 3.5} P_X(x) = \sum_{x=1}^3 P(X = x) = \sum_{x=1}^3 \frac{1}{6} = 3 \cdot \frac{1}{6} = \frac{1}{2}.$$

# Propiedades de la función de distribución

## Propiedad

Sea  $X$  una variable con función de distribución  $F_X$  entonces:

- $0 \leq F_X(x) \leq 1$  para todo  $x$ ,
- Si  $x < x'$ , entonces

$$F_X(x) \leq F_X(x').$$

Es una función creciente, es decir, no necesariamente estrictamente creciente.

- $\lim_{x \rightarrow -\infty} F_X(x) = 0$  y  $\lim_{x \rightarrow +\infty} F_X(x) = 1$ .
- Es continua por la derecha  $\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0)$ .



## Lección 3

### Valores esperados o esperanza

---

## Momentos de variables aleatorias discretas

- Al igual que en la estadística descriptiva se utilizan distintas medidas para resumir los valores centrales y para medir la dispersión de una muestra, podemos definir las correspondiente medidas para variables aleatorias.
- A estas medidas se les suele añadir el adjetivo **poblacionales** mientras que a las que provienen de la muestra se las adjetiva como **muestrales**.

Por ejemplo podemos buscar un valor que resuma toda la variable. Este valor es el que “*esperamos*” que se resuma la v.a. o esperamos que las realizaciones de la v.a. queden cerca de él. Demos su definición formal.

# Esperanza de un variable aleatoria discreta

## Esperanza de una variable aleatoria discreta

El valor **esperado o esperanza** (*expected value* en inglés)  $E(X)$  de una v.a. discreta  $X$ , se define como

$$E(X) = \sum_{x \in X(\Omega)} x \cdot P_X(x).$$

En ocasiones se denomina **media** (*mean* en inglés, *mitjana* en catalán) poblacional o simplemente media y muy frecuentemente se la denota  $\mu_X = E(X)$  o simplemente  $\mu = E(X)$ .

# Interpretación de la media aritmética para v.a. discretas

## Ejemplo: lanzamiento de un dado $n$ veces

Supongamos que lanzamos un dado  $n$  veces y obtenemos unas frecuencias absolutas  $n_i$  para el resultado  $i$  con  $i = 1, \dots, 6$ . Sea  $X$  la v.a. que nos representa el valor de una tirada del dado.

Calculemos la media aritmética (o media muestral) de los datos

$$\bar{x} = \frac{1 \cdot n_1 + 2 \cdot n_2 + 3 \cdot n_3 + 4 \cdot n_4 + 5 \cdot n_5 + 6 \cdot n_6}{n} = \sum_{x=1}^6 x \cdot \frac{n_x}{n}.$$

Si  $n \rightarrow \infty$  se tiene que  $\lim_{n \rightarrow \infty} \frac{n_x}{n} = P_X(x)$ .

Por lo tanto  $E(X) = \lim_{n \rightarrow \infty} \sum_{x=1}^6 x \cdot \frac{n_x}{n}$ .

Entonces el valor esperado en una v.a. discreta puede entenderse como el valor promedio que

## Ejemplo

### Ejemplo: Erratas en un texto

Sea  $X$  = número de erratas en una página de un texto con dominio  $D_X = \{0, 1, 2\}$ .

Resulta que

$$P(X = 0) = 0.42, \quad P(X = 1) = 0.4, \quad P(X = 2) = 0.18.$$

entonces

$$E(X) = 0 \cdot 0.42 + 1 \cdot 0.4 + 2 \cdot 0.18 = 0.76.$$

Elegida una página del texto al azar esperamos encontrar 0.76 errores por página.

Supongamos que el editor nos paga 2 euros por cada página que encontremos con 1 error y 3 euros por cada página con dos errores (y nada por las páginas correctas) ¿Cuánto *esperamos* cobrar si analizamos una página?

# Esperanzas de funciones de variables aleatorias discretas

## Esperanzas de funciones de variables aleatorias discretas

Sea  $X$  una v.a. discreta con función de probabilidad  $P_X$  y de distribución  $F_X$ . Entonces el *valor esperado de una función  $g(x)$*  es:

$$E(g(X)) = \sum_x g(x) \cdot P_X(x).$$

# Propiedades de los valores esperados

## Propiedades

- $E(k) = k$  para cualquier constante  $k$ .
- Si  $a \leq X \leq b$  entonces  $a \leq E(X) \leq b$ .
- Si  $X$  es una v.a. discreta que toma valores enteros no negativos entonces
$$E(X) = \sum_{x=0}^{+\infty} (1 - F_X(x)).$$

## Ejercicio

La demostración de las propiedades anteriores se deja como ejercicio.

## Ejemplo

### Ejemplo: paleta de colores aleatoria

Supongamos que estamos sentados delante de nuestro ordenador con un amigo y le decimos que en dos minutos podemos programar una paleta para poner colores a unos gráficos.

Queremos que la paleta tenga dos botones con las opciones color rojo y color azul. Como hemos programado a gran velocidad resulta que el programa tiene un error; cada vez que se abre la paleta los colores se colocan al azar (con igual probabilidad) en cada botón, así que no sabemos en qué color hemos de pinchar.

Además, como nos sobraron 15 segundos para hacer el programa y pensando en la comodidad del usuario, la paleta se cierra después de haber seleccionado un color y hay que volverla a abrir de nuevo.

La pregunta es ¿cuál es el valor esperado del número de veces que hemos pinchar el botón de color azul antes de obtener este color?



## Ejemplo

Llamemos  $X$  al número de veces que pinchamos en el botón azul (y nos sale rojo) hasta obtener el primer azul. La variable  $X$  toma valores en los enteros no negativos. Su función de probabilidad queda determinada por

$$P_X(x) = P(X = x) = P(\overbrace{\text{rojo}, \text{rojo}, \dots, \text{rojo}}^{x \text{ veces}}, \text{azul}) = \left(\frac{1}{2}\right)^{x+1}.$$

# Series geométricas

## Series geométricas

- Una **progresión geométrica** de razón  $r$  es una sucesión de la forma

$$r^0, r^1, \dots, r^n, \dots$$

- La serie geométrica es la suma de todos los valores de la progresión geométrica  $\sum_{k=0}^{+\infty} r^k$ .
- Las sumas parciales desde el término  $n_0$  al  $n$  de una progresión geométrica valen

$$\sum_{k=n_0}^n r^k = \frac{r^{n_0} - r^{n+1}}{1 - r}.$$

# Propiedades de las series geométricas

## Propiedades

- Si  $|r| < 1$  la serie geométrica es convergente y

$$\sum_{k=0}^{+\infty} r^k = \frac{1}{1-r}$$

- En el caso en que se comience en  $n_0$  se tiene que

$$\sum_{k=n_0}^{+\infty} r^k = \frac{r^{n_0}}{1-r}.$$

# Propiedades de las series geométricas

## Propiedades

- Si  $|r| < 1$  también son convergentes las derivadas, respecto de  $r$ , de la serie geométrica y convergen a la derivada correspondiente. Así tenemos que

$$\left( \sum_{k=0}^{+\infty} r^k \right)' = \sum_{k=1}^{+\infty} k r^{k-1}; \quad \left( \frac{1}{1-r} \right)' = \frac{1}{(1-r)^2}$$

$$\left( \sum_{k=0}^{+\infty} r^k \right)'' = \sum_{k=2}^{+\infty} k(k-1) r^{k-2}; \quad \left( \frac{1}{1-r} \right)'' = \frac{2}{(1-r)^3}$$

## Ejemplo

### Ejemplo: paleta de colores (continuación)

Si seguimos con el ejemplo de la paleta de colores, su esperanza es:

$$E(X) = \sum_{x=0}^{+\infty} x \cdot P(X = x) = \sum_{x=0}^{+\infty} x \cdot \left(\frac{1}{2}\right)^{x+1} = \left(\frac{1}{2}\right)^2 \sum_{x=1}^{+\infty} x \cdot \left(\frac{1}{2}\right)^{x-1} = \left(\frac{1}{2}\right)^2 \cdot \frac{1}{\left(1 - \frac{1}{2}\right)^2} = 1.$$

Ahora calculemos su función de distribución

$$F_X(x) = P(X \leq x) = \sum_{k=0}^x P(X = k) = \sum_{k=0}^x \left(\frac{1}{2}\right)^{k+1} = \frac{\frac{1}{2} - \frac{1}{2}^{x+1}}{1 - \frac{1}{2}} \cdot \frac{1}{2} = 1 - \left(\frac{1}{2}\right)^{x+1}.$$

## Ejemplo

Como la variable toma valores enteros positivos, podemos calcular su valor esperado de esta otra manera

$$E(X) = \sum_{x=0}^{+\infty} (1 - F_X(x)) = \sum_{x=0}^{+\infty} \left(\frac{1}{2}\right)^{x+1} = \frac{1}{2} \cdot \frac{1}{1 - \frac{1}{2}} = 1.$$

## Ejercicio

Calculad el valor esperado de la variable

$Y$  = número de intentos para conseguir el color azul.

# Momentos de una variable aleatoria

Momentos de orden  $m$

Llamaremos **momento de orden**  $m$  respecto al punto  $C$  a

$$E((X - C)^m).$$

- Cuando  $C = 0$  los momentos reciben el nombre de **momentos respecto al origen**.
- Cuando  $C = E(X)$  reciben el nombre de **momentos centrales o respecto de la media**. Luego la esperanza es el momento de orden 1 respecto al origen. Estos momentos son la versión poblacional de los momentos que vimos en el curso de estadística descriptiva, recibiendo estos último el nombre de momentos muestrales.

## Resumen de conceptos

- Hemos descrito el comportamiento aleatorio de una v.a. discreta mediante sus funciones de probabilidad  $P_X$  y de distribución  $F_X$ .
- También tenemos un valor central; el valor esperado  $E(X)$ .
- Como medida básica nos queda definir una medida de lo lejos que están los datos del valor central  $E(X)$  una de estas medidas es la varianza de  $X$ .



## Lección 4

### Medidas de la variabilidad

## Medidas de la variabilidad

### Varianza

Sea  $X$  una v.a. Llamaremos **varianza** de  $X$  a

$$Var(X) = E((X - E(X))^2).$$

Por lo tanto, la varianza es el momento central de orden 2.

De forma frecuente se utiliza la notación

$$\sigma_X^2 = Var(X).$$

A la raíz cuadrada positiva de la varianza

$$\sigma_X = +\sqrt{Var(X)}.$$

se la denomina desviación típica o estándar de  $X$ .

# Propiedades de la varianza

## Propiedad

- Si  $X$  es una v.a. discreta con función de probabilidad  $P_X$  su varianza es

$$\sigma_X^2 = Var(X) = E((X - E(X))^2) = \sum_x (x - E(X))^2 \cdot P_X(x).$$

- Sea  $X$  una v.a.

$$Var(X) = E(X^2) - (E(X))^2 = \sum_x x^2 \cdot P_X(X) - (E(X))^2$$

# Demostración

## Demostración de b)

$$\begin{aligned} \text{Var}(X) &= \sum_x (x - E(X))^2 P_X(x) = \sum_x (x^2 - 2 \cdot x \cdot E(X) + (E(X))^2) \cdot P_X(x) \\ &= \sum_x x^2 \cdot P_X(x) - E(X) \sum_x 2 \cdot x \cdot P_X(x) + (E(X))^2 \cdot \sum_x P_X(x) \\ &= E(X^2) - 2E(X) \cdot E(X) + (E(X))^2 = E(X^2) - (E(X))^2. \end{aligned}$$

## Ejemplo

### Ejemplo: número de errores (continuación)

Calculemos en el ejemplo anterior la varianza del número de errores.

Recordemos que:

$$P(X = 0) = 0.42, \quad P(X = 1) = 0.4, \quad P(X = 2) = 0.18,$$

y que

$$E(X) = 0.76.$$

Entonces:

$$Var(X) = E(X^2) - (E(X))^2 = E(X^2) - (0.76)^2.$$

## Ejemplo

Ahora necesitamos calcular

$$E(X^2) = 0^2(0.41) + 1^2(0.4) + 2^2(0.18) = 0.4 + 0.72 = 1.12$$

y por lo tanto

$$Var(X) = E(X^2) - (0.76)^2 = 1.12 - 0.5776 = 0.542$$

y

$$\sqrt{Var(X)} = \sqrt{0.542}$$

En resumen  $\sigma_X^2 = 0.542$  y  $\sigma_X = \sqrt{0.542}$

# Propiedades de la varianza

## Propiedades de la varianza

- $Var(X) \geq 0$ .
- $Var(cte) = E(cte^2) - (E(cte))^2 = cte^2 - cte^2 = 0$ .
- El mínimo de  $E((X - C)^2)$  se alcanza cuando  $C = E(X)$  y es  $Var(X)$ . Esta propiedad es una de las que hace útil a la varianza como medida de dispersión.

## Ejercicio

Se deja como ejercicio la demostración de estas propiedades.

## Lección 5

### Esperanza y varianza de transformaciones lineales.



# Transformaciones lineales.

## Transformación lineal

Un **cambio de variable lineal** o **transformación lineal** de una v.a.  $X$  es otra v.a.  $Y = a + b \cdot X$  donde  $a, b \in \mathbb{R}$ .

## Esperanza de una transformación lineal

Sea  $X$  una v.a. con  $E(X) = \mu_X$  y  $Var(X) = \sigma_X^2$  y  $a, b \in \mathbb{R}$ . Entonces si  $Y = a + b \cdot X$ :

- $E(Y) = E(a + bX) = a + bE(X) = a + b \cdot \mu_X$ .
- $Var(Y) = Var(a + bX) = b^2 Var(X) = b^2 \cdot \sigma_X^2$ -
- $\sigma_Y = \sqrt{Var(Y)} = \sqrt{b^2 Var(X)} = |b| \cdot \sigma_X$ -

# Demostración

## Demostración:

$$\begin{aligned} E(Y) &= E(a + bX) = \sum_x (a + b \cdot x) \cdot P_X(x) \\ &= a \sum_x P_X(x) + b \sum_x x \cdot P_X(x) \\ &= a + b \cdot E(X) = a + b \cdot \mu_X. \end{aligned}$$

## Ejercicio

Las demostración de las demás propiedades se dejan como ejercicio.

## Lección 6

### Variables aleatorias continuas

---

## Variables aleatorias continuas definición.

- Como ya hemos dicho las variables aleatorias continuas toman valores en intervalos o áreas.
- Lo más habitual es que estas variables tengan función de distribución continua y derivable (salvo a los más en una cantidad finita o numerable de puntos:-)).
- En lo que sigue supondremos que la función de distribución de variables aleatorias continuas cumplen estas propiedades.
- Notemos que si  $X$  es una v.a. con función de distribución continua se tiene que  $P(X = x_0) = F_X(x_0) - F(x_0^-) = 0$ . Por lo que no tiene sentido definir *función de probabilidad*.

# Variables aleatorias continuas

- En general tendremos que  $P(X < x_0) = P(X \leq x_0)$ .
- Por otra parte podemos utilizar una regla parecida del cociente entre casos favorables y casos posibles de Laplace pero en este caso el conteo se hace por la *medida* de los casos posibles partida por la *medida* de los casos favorables.
- Veamos un ejemplo de v.a. continua, que ampliaremos en el tema siguiente, en el que se utilizan todos estos conceptos.

## Ejemplo: Distribución uniforme en $[0, 1]$ .

### Ejemplo: distancia dardo centro de la diana

Supongamos que lanzamos un dardo a una diana de radio 1, de forma que sea *equiprobable* cualquier distancia al centro (¡Cuidado! esto no es equivalente que cualquier punto de la diana sea *equiprobable*).

Consideremos la v.a. continua  $X =$  distancia al centro de la diana.

Su función de distribución es

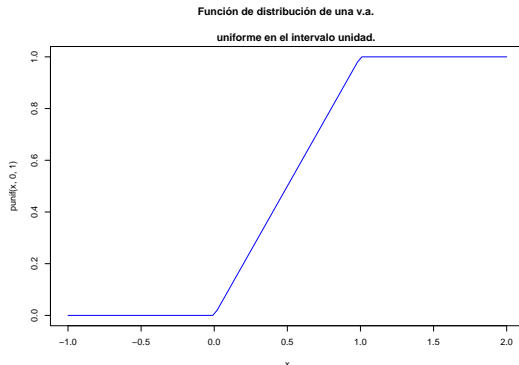
$$F_X(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ x, & \text{si } 0 < x < 1, \\ 1, & \text{si } x \geq 1. \end{cases}$$

consideremos

- C.F. *longitud favorable* que es  $x - 0$ ,
- C.P. *longitud posible* que es  $1 - 0$

# Gráfica de la función de distribución uniforme

```
curve(punif(x,0,1),xlim=c(-1,2),col="blue",  
      main="Función de distribución de una v.a. \n  
      uniforme en el intervalo unidad.")
```



# Propiedades

En las variables continuas los sucesos del tipo  $\{X \leq x\}$  y  $\{X < x\}$  tendrán la misma probabilidad, y otros tipos de sucesos similares también, algunas de estas propiedades se explicitan en la siguiente proposición.

## Propiedades

Dada una v.a. continua  $X$  se tiene que:

- $P(X \leq b) = P(X < b).$
- $P(X < b) = P(X < a) + P(a < X < b).$
- $P(a < X < b) = P(X < b) - P(X < a).$



# Demostración

## Demostración:

La primera es evidente  $P(X \leq b) = P(X < b) + P(X = b) = P(X < b)$ .

Para demostrar la segunda, tenemos

$$\{X \leq a\} \cap \{a < X < b\} = \emptyset$$

$$\{X \leq a\} \cup \{a < X < b\} = \{X < b\},$$

entonces

$$P(X < b) = P(\{X \leq a\} \cup \{a < X < b\}) = P(X \leq a) + P(a < X < b) = P(X < a) + P(a < X < b).$$

La demostración de la tercera propiedad es similar a la segunda pero aplicando la primera. La dejamos como ejercicio.

## Propiedades de la función de distribución

Las propiedades anteriores y combinaciones de ellas se pueden escribir utilizando la función de distribución de  $X$ :

### Propiedades de la Función de Distribución

Dada una variable aleatoria continua se tiene que:

- $F_X(b) = F_X(a) + P(a < X < b)$ .
- $P(a < X < b) = F_X(b) - F_X(a)$ .
- $P(a \leq X \leq b) = F_X(b) - F_X(a)$ .

### Ejercicio

Se deja la demostración como ejercicio

## Ejemplo

### Ejemplo: diana (continuación)

En el ejemplo de la diana:

$$P(0.25 < X < 0.3) = F_X(0.3) - F_X(0.25) = 0.3 - 0.25 = 0.05.$$

# Función de densidad

## Función de densidad

Una función  $f : \mathbb{R} \rightarrow \mathbb{R}$  es una función de densidad sobre  $\mathbb{R}$  si cumple que

- $f_X(x) \geq 0$  para todo  $x \in \mathbb{R}$ .
- $f$  es continua salvo a lo más en una cantidad finita de puntos sobre cada intervalo acotado de  $\mathbb{R}$ .
- $\int_{-\infty}^{+\infty} f_X(x) dx = 1$ .

# Función de distribución de una variable aleatoria.

## Función de distribución de una variable aleatoria

Sea  $X$  una v.a. con función de distribución  $F_X$ . Sea  $f : \mathbb{R} \rightarrow \mathbb{R}$  una función de densidad tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt. \text{ para todo } x \in \mathbb{R},$$

Entonces  $X$  es una variable aleatoria continua y  $f_X$  es la densidad de la v.a.  $X$ .

## Dominio de una variable aleatoria continua

El conjunto  $D_X = \{x \in \mathbb{R} | f_x(x) > 0\}$  recibe el nombre de soporte o dominio de la variable aleatoria continua y se interpreta como su conjunto de resultados posibles.

### Ejemplo: diana (continuación)

En nuestra ejemplo de la diana, la función  $f$  es una densidad

$$f_X(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ 1, & \text{si } 0 < x < 1, \\ 0, & \text{si } 1 \leq x. \end{cases}$$

que es la densidad de  $X$ , en efecto:

## Densidad diana

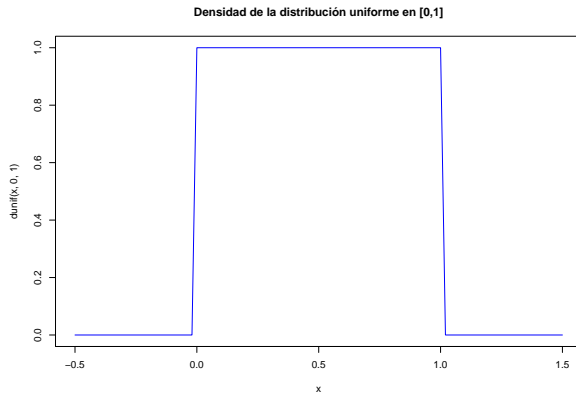
$$f_X(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ 1, & \text{si } 0 < x < 1, \\ 0, & \text{si } 1 \leq x. \end{cases}$$

- Si  $x \leq 0$  entonces  $\int_{-\infty}^x f_X(t)dt = 0$ .
- Si  $0 \leq x \leq 1$  entonces  $\int_{-\infty}^x f_X(t)dt = \int_0^x 1dt = x$ .
- Si  $x \geq 1$  entonces  $\int_{-\infty}^x f_X(t)dt = \int_0^1 1dt = 1$ .

Por lo tanto,  $F_X(x) = \int_{-\infty}^x f_X(t)dt$  para todo  $x \in \mathbb{R}$ .

# Densidad diana

```
curve(dunif(x,0,1),xlim=c(-0.5,1.5),col="blue",  
      main="Densidad de la distribución uniforme en [0,1]")
```





## Utilidad de la función de densidad

La función de densidad nos permite calcular diversas probabilidades.

Propiedades de la función de densidad

- Sea  $X$  una v.a. continua con función de distribución  $F_X$  y de densidad  $f_X$ , entonces

$$\begin{aligned}P(a < X < b) &= P(a < X \leq b) = P(a \leq X < b) = \\P(a \leq X \leq b) &= \int_a^b f_X(x)dx.\end{aligned}$$

- Si  $A$  es un subconjunto adecuado de  $\mathbb{R}$  entonces

$$P(X \in A) = \int_A f(x)dx = \int_{A \cap D_X} f(x)dx.$$

# Utilidad de la función de densidad

## Propiedades de la función de densidad

Sea  $X$  una v.a. continua con función de distribución  $F_X$  y de densidad  $f_X$ , entonces:

- Si  $f_x$  es continua en un punto  $x$ ,  $F_X$  es derivable en ese punto y  $F'_X(x) = f_X(x)$ .
- $P(X = x) = 0$  para todo  $x \in \mathbb{R}$ .

## Ejercicio

Comprobar estas propiedades en el ejemplo de la diana.

## Ejemplo tiempo ejecución de un proceso

### Ejemplo: tiempo ejecución de un proceso.

Sea  $X$  = tiempo de ejecución de un proceso. Se supone que  $X$  sigue una distribución uniforme en dos unidades de tiempo, si tarda más el proceso se cancela.

Calculemos la función de densidad y de distribución de la v.a  $X$ .

Entonces

$$F_X(x) = P(X \leq x) = \frac{CF}{CP} = \frac{x}{2}.$$

Luego su función de distribución es:

$$F_X(x) = \begin{cases} 0, & \text{si } x \leq 0, \\ \frac{x}{2} & \text{si } 0 < x < 2, \\ 1, & \text{si } 2 \leq x. \end{cases}$$

## Ejemplo tiempo ejecución de un proceso

Su función de densidad por su lado es:

$$f_X(x) = F'_X(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \frac{1}{2} & \text{si } 0 < x \leq 2 \\ 0 & \text{si } 2 \leq x \end{cases}$$

Efectivamente

- $f_X(x) \geq 0$ , y tiene un conjunto finito de discontinuidades: en 0 y en 2
- $F_X(x) = \int_{-\infty}^x f_X(t)dt$ , para todo  $x \in \mathbb{R}$  (Ejercicio: resolverlo gráficamente.)
- $\int_{-\infty}^{+\infty} f_X(x)dx = \int_0^2 \frac{1}{2}dx = \left[\frac{x}{2}\right]_0^2 = \frac{2}{2} - \frac{0}{2} = 1.$

## Ejemplo tiempo ejecución de un proceso

### Ejercicio: Tiempo de un proceso:

Calcular la probabilidad de que uno de nuestros procesos tarde más de una unidad de tiempo en ser procesado. Calcular también la probabilidad de que dure entre 0.5 y 1.5 unidades de tiempo.

## Lección 7

# Esperanza y varianza para variables aleatorias continuas

# Esperanza y varianza para variables aleatorias continuas

Los mismos comentarios y definiciones que se dieron en la sección correspondiente del tema de estadística descriptiva son aplicables aquí.

Así que sólo daremos las definiciones, la forma de cálculo y algunos ejemplos.

En lo que sigue, salvo que indiquemos lo contrario,  $X$  es una v.a. continua con función de densidad  $f_X(x)$

# Esperanza y varianza para variables aleatorias continuas

## Esperanza v.a. continuas

- Su esperanza es:

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx.$$

- Si  $g(x)$  es una función de la variable  $X$  entonces:

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) dx.$$



# Esperanza y varianza para variables aleatorias continuas

## Varianza v.a. continuas

- Su varianza es:

$$Var(X) = \sigma_X^2 = E((X - \mu_X)^2) = \int_{-\infty}^{+\infty} (x - \mu_X)^2 \cdot f_X(x) dx.$$

- Su desviación típica es:

$$\sigma_X = \sqrt{\sigma_X^2}.$$

# Propiedades

## Propiedades

- $\sigma_X^2 \geq 0$ .
- $Var(cte) = E(cte^2) - (E(cte))^2 = cte^2 - cte^2 = 0$ .
- $Var(x) = E(X^2) - \mu_X^2 = \int_{-\infty}^{+\infty} x^2 \cdot f_X(x) dx - \mu_X^2$ .
- El mínimo de  $E((X - C)^2)$  se alcanza cuando  $C = E(X)$  y es  $Var(X)$ .

## Ejemplo

### Ejemplo: diana (continuación)

Calcular  $\mu_X$  y  $\sigma_X^2$  en el ejemplo de la diana

Resultado

$$\mu_X = \frac{1}{2},$$

$$E(X^2) = \frac{1}{3},$$

$$Var(X) = \frac{1}{12}.$$

# Esperanza de trans. lineales de v.a. continuas

## Proposición

Sea  $X$  una v.a. continua con  $E(X) = \mu_X$  y  $Var(X) = \sigma_X^2$  sea  $Y = a + bX$ , donde  $a, b \in \mathbb{R}$ , es una nueva v.a. continua obtenida mediante una transformación lineal de  $X$ . Se verifican las mismas propiedades que en el caso discreto:

- $E(Y) = E(a + b \cdot X) = a + b \cdot E(X)$ .
- $Var(Y) = Var(a + b \cdot X) = b^2 \cdot Var(X)$ .
- $\sigma_Y = |b| \cdot \sigma_X$ .
- $Z = \frac{X - \mu_X}{\sigma_X}$  es una transformación lineal de  $X$  de forma que

$$E(Z) = 0 \text{ y } Var(Z) = 1$$

## Ejemplo

### Ejemplo

En una empresa de venta de vinos por internet, sea  $X$  = número de litros de vino del país vendidos en un año. Supongamos que sabemos que  $E(X) = 10000$  y que  $Var(X) = 100$ . Supongamos que los gastos fijos de distribución son 50.000 € y el beneficio por litro es de 10 € por botella. Definimos  $T = 10 \cdot X - 50000$ , que será el beneficio después de gastos.

Entonces la esperanza del beneficio es

$$E(T) = 10E(X) - 50000 = 50000,$$

y

$$Var(T) = 10^2 Var(X) = 10000.$$

## Lección 8

# Transformaciones de variables aleatorias

# Transformaciones de variables aleatorias

Muchas variables aleatorias son funciones de otras v.a. En lo que sigue resumiremos diversas técnicas para dada una v.a.  $X$  y una transformación  $Y = h(X)$  encontrar  $F_Y$  a partir de  $F_X$ .

# Propiedad

## Transformaciones de v.a. discretas

Sea  $X$  una v.a. discreta con  $X(\Omega) = \{x_1, x_2, \dots, x_n, \dots\}$  y sea  $h : \mathbb{R} \rightarrow \mathbb{R}$  una aplicación. Entonces  $Y = h(X)$  es también una v.a. discreta. Además si  $P_X$  y  $F_X$  son las funciones de probabilidad y de distribución de  $X$  entonces

- $P_Y(y) = \sum_{x_i | h(x_i)=y} P_X(x_i).$
- $F_Y(y) = \sum_{x_i | h(x_i) \leq y} P_X(x_i).$



# Propiedades

Desafortunadamente para variables no discretas el resultado no es tan sencillo como el anterior, pues la transformación de, por ejemplo, una v.a. continua puede ser continua, discreta, mixta,...

Transformación de v.a. continuas en continuas

Sea  $X$  una v.a. continua cuya función de densidad es  $f_X$ . Sea  $h : \mathbb{R} \rightarrow \mathbb{R}$ , una aplicación estrictamente monótona y derivable, por lo tanto  $h'(x) \neq 0$  para todo  $x \in \mathbb{R}$ . Sea  $Y = h(X)$  la transformación de  $X$  por  $h$ . Entonces  $Y$  es una v.a. continua con función de densidad

$$f_Y(y) = \frac{f_X(x)}{|h'(x)|} \Big|_{x=h^{-1}(y)}$$

# Propiedades

Densidad de una transformación de una v.a. continua

Sea  $X$  una v.a. continua cuya función de densidad es  $f_X$ . Sea

$$h : \mathbb{R} \rightarrow \mathbb{R}$$

una aplicación, no necesariamente monótona tal que :

- sea derivable con derivada no nula
- la ecuación  $h(x) = y$  tiene un número finito de soluciones  $x_1, x_2, \dots, x_n$

entonces:

$$f_Y(y) = \sum_{k=1}^n \frac{f_X(x)}{|h'(x)|} \Bigg|_{x=x_k} .$$

## Método general de transformación de v.a.

Cuando no podamos aplicar las propiedades anteriores intentaremos calcular primero la función de distribución de la transformación y luego su densidad.

Notemos que en general si  $Y = g(X)$  es una v.a. transformación de la v.a.  $X$  entonces

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y).$$

# Método general del transformación de variables aleatorias

Por ejemplo, si  $g$  es estrictamente creciente y continua,

$$F_Y(y) = P(g(X) \leq y) = P(X \leq g^{-1}(y)) = F_X(g^{-1}(y)),$$

y si  $g$  es estrictamente decreciente y continua,

$$F_Y(y) = P(g(X) \leq y) = P(X \geq g^{-1}(y)) = 1 - F_X(g^{-1}(y)).$$

## Lección 9

### Desigualdades básicas: Markov y Chebychev

# Desigualdades de Markov y de Chebychev

- En esta sección distintas desigualdades que acotan determinadas probabilidades de una variable aleatoria.
- Estas desigualdades sirven en algunos casos para acotar probabilidades de determinados sucesos.
- También son útiles desde el punto de vista teórico, por ejemplo para justificar que la varianza es una medida de la dispersión de los datos.

# Desigualdad de Markov

## Desigualdad de Markov

Sea  $X$  una v.a. positiva con  $E(X)$  finita. Entonces

$$P(X \geq a) \leq \frac{E(X)}{a} \text{ para todo } a > 0.$$

## Demostración:

Si  $X$  es continua y solo toma valores positivos

$$\begin{aligned} E(X) &= \int_{-\infty}^{+\infty} x \cdot f_X(x) dx = \int_0^{+\infty} x \cdot f_X(x) dx = \int_0^a x \cdot f_X(x) dx + \int_a^{+\infty} x \cdot f_X(x) dx \\ &\geq \int_a^{+\infty} x \cdot f_X(x) dx \geq a \int_a^{+\infty} f_X(x) dx = a \cdot P(X \geq a), \end{aligned}$$

# Desigualdad de Markov

## Corolario

Sea  $X$  una v.a. con  $E(X)$  finita entonces para todo  $a > 0$

$$P(|X| \geq a) \leq \frac{E(|X|)}{a}.$$

## Ejercicio

Demuestra el corolario anterior a partir de la desigualdad de Markov.



# Desigualdad de Chebychev

La **desigualdad de Chebychev** también se denomina de Chebyshev y en inglés *Chebyshev*.

Desigualdad de Chebychev

Sea  $X$  una v.a. con  $E(X) = \mu$  y  $Var(X) = \sigma^2$  entonces para todo  $a > 0$ ,

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}.$$

# Demostración desigualdad de Chebychev

## Demostración

Apliquemos la consecuencia de la desigualdad de Markov a la v.a. no negativa

$$Y^2 = (X - \mu)^2$$

entonces

$$P(Y^2 \geq a^2) \leq \frac{E(Y^2)}{a^2} = \frac{E((X - \mu)^2)}{a^2} = \frac{Var(X)}{a^2} = \frac{\sigma^2}{a^2}.$$

Por otra parte

$$P(Y^2 \geq a^2) = P(|Y| \geq a) = P(|X - \mu| \geq a),$$

hecho que, junto con la desigualdad anterior, demuestra el resultado.

## Uso de la desigualdad de Chebychev

### Utilidad básica de la desigualdad de Chebychev

Supongamos que  $X$  es una v.a. con  $Var(X) = 0$ , entonces, aplicando la desigualdad anterior

$$P(|X - E(X)| \geq a) = 0 \text{ para todo } a > 0,$$

lo que implica que

$$P(X = E(X)) = 1,$$

Por lo que la probabilidad de que  $X$  sea constantemente  $E(X)$  es 1, hecho que nos confirma la utilidad de la varianza como una medida de la dispersión de los datos.

## Ejemplo

### Ejemplo: tiempo de respuesta

Se sabe que el tiempo de respuesta medio y la desviación típica de un sistema multiusuario son 15 y 3 unidades de tiempo respectivamente. Entonces:

$$P(|X - 15| \geq 5) \leq \frac{9}{25} = 0.36.$$

Si sustituimos  $a$  por  $a \cdot \sigma$  en la desigualdad de Chebychev, nos queda:

$$P(|X - \mu| \geq a \cdot \sigma) \leq \frac{\sigma^2}{(a \cdot \sigma)^2} = \frac{1}{a^2},$$

que es otra manera de expresar la desigualdad de Chebychev.

## Más formas de la desigualdad de Chebychev

La desigualdad de Chebychev también se puede escribir de al menos dos maneras más:

$$P(\mu - a \leq X \leq \mu + a) \geq 1 - \frac{\sigma^2}{a^2},$$

y tomado como  $a = k \cdot \sigma$ ,

$$P(\mu - k \cdot \sigma \leq X \leq \mu + k \cdot \sigma) \geq 1 - \frac{1}{k^2}.$$

## La varianza como medida de dispersión

Tomando la segunda expresión que hemos visto para la desigualdad de Chebychev para distintos valores de  $k > 0$  obtenemos la siguiente tabla:

$k$	$P( X - E(X)  \geq k \cdot \sigma)$
1	$\leq 1$
2	$\leq 0.25$
3	$\leq 0.111$
4	$\leq 0.0025$

# Interpretación de la desigualdad

- Por ejemplo para  $k = 2$ , esta desigualdad se puede interpretar como que, dada una v.a.  $X$  con cualquier distribución que tenga  $E(X)$  y  $Var(X)$  finitos, *la probabilidad de que un valor se aleje de la media  $\mu$  más de  $a = 2$  desviaciones típicas es menor o igual que 0.25.*
- Es decir sólo el 25% de los valores estarán alejados de la media más de  $2 \cdot \sigma$

¡Sea cual sea la distribución de la v.a.!

## Tema 3 Parte I: Distribuciones Notables Discretas

octubre 2023



# Lección 1

## Distribuciones Notables I

# Introducción

- En este tema estudiaremos diversos tipos de experimentos que son muy frecuentes y algunas de las variables aleatorias asociadas a ellos.
- Estas variables reciben distintos nombres que aplicaremos sin distinción al tipo de población del experimento a la variable o a su función de probabilidad, densidad o distribución.
- Empezaremos con las variables aleatorias discretas que se presentan con frecuencia ya que están relacionadas con situaciones muy comunes como el número de caras en varios lanzamientos de una moneda, el número de veces que una máquina funciona hasta que se estropea, el número de clientes en una cola,...

## Lección 2

### Distribución Bernoulli

# Distribución Bernoulli

## Distribución Bernoulli

- Consideremos un experimento con dos resultados posibles éxito (E) y fracaso (F). El espacio de sucesos será  $\Omega = \{E, F\}$ .
- Supongamos que la probabilidad de éxito es  $P(E) = p$ , y naturalmente  $P(F) = 1 - p = q$  con  $0 < p < 1$ .
- Consideremos la aplicación

$$X : \Omega = \{E, F\} \rightarrow \mathbb{R}$$

definida por

$$X(E) = 1, X(F) = 0.$$

# Distribución Bernoulli

Su función de probabilidad es

$$P_X(x) = \begin{cases} 1 - p = q & \text{si } x = 0 \\ p & \text{si } x = 1 \\ 0 & \text{en cualquier otro caso} \end{cases} .$$

Su función de distribución es

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - p = q & \text{si } 0 \leq x < 1 \\ 1 & \text{si } 1 \leq x \end{cases} .$$

# Distribución Bernoulli

- Bajo estas condiciones diremos que  $X$  es una v.a. **Bernoulli** o que sigue una ley de **distribución de probabilidad Bernoulli** de parámetro  $p$ .
- Lo denotaremos por

$$X \equiv Ber(p) \text{ o también } X \equiv B(1, p).$$

- A este tipo de experimentos (éxito/fracaso) se les denomina experimentos Bernoulli.
- Fue su descubridor un científico suizo **Jacob Bernoulli**, uno más de la conocida familia de científicos suizos Bernoulli.

## Esperanza de una v.a. $X \text{ Ber}(p)$

Su **valor esperado** es

$$E(X) = \sum_{x=0}^1 x \cdot P(X = x) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Calculemos también  $E(X^2)$

$$E(X^2) = \sum_{x=0}^1 x^2 \cdot P(X = x) = 0^2 \cdot (1 - p) + 1^2 \cdot p = p.$$

## Varianza de una v.a. $X \text{ Ber}(p)$

Su **varianza** es

$$\text{Var}(X) = E(X^2) - (E(X))^2 = p - p^2 = p \cdot (1 - p) = p \cdot q.$$

Su desviación típica es

$$\sqrt{\text{Var}(X)} = \sqrt{p \cdot (1 - p)}.$$



## Resumen v.a con distribución Bernoulli

$X$ Bernoulli: $Ber(p)$
$D_X = \{0, 1\}$
$P_X(x) = P(X = x) = \begin{cases} 1 - p = q & \text{si } x = 0 \\ p & \text{si } x = 1 \\ 0 & \text{en otro caso.} \end{cases}$
$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ (1 - p) & \text{si } 0 \leq x < 1 \\ 1 & \text{si } x \geq 1 \end{cases} .$
$E(X) = p; \text{ Var}(X) = p \cdot (1 - p)$

## Distribución Bernoulli. Ejemplo

Veamos los cálculos básicos  $Ber(p = 0.25)$  en R.

```
dbinom(0,size=1,prob=0.25)
```

```
[1] 0.75
```

```
dbinom(1,size=1,prob=0.25)
```

```
[1] 0.25
```

```
rbinom(n=20,size = 1,prob=0.25)
```



```
[1] 0 0 1 0 0 1 0 0 0 0 0 0 0 1 0 0 1 0 0 1
```

## Distribución Bernoulli. Ejemplo

El siguiente código dibuja las función de probabilidad y la de distribución de una  $Ber(p = 0.25)$

```
par(mfrow=c(1,2))
plot(x=c(0,1),y=dbinom(c(0,1),size=1,prob=0.25),
     ylim=c(0,1),xlim=c(-1,2),xlab="x",
     main="Función de probabilidad\n Ber(p=0.25)")
lines(x=c(0,0,1,1),y=c(0,0.75,0,0.25), type = "h", lty = 2,col="blue")
curve(pbinom(x,size=1,prob=0.25),
      xlim=c(-1,2),col="blue",
      main="Función de distribución\n Ber(p=0.25)")
par(mfrow=c(1,1))
```

# Distribución Bernoulli. Ejemplo



## Lección 3

### Distribución binomial

---

# Distribución binomial

## Distribución binomial

Si repetimos  $n$  veces de forma independiente un experimento Bernoulli de parámetro  $p$ .

El espacio muestral  $\Omega$  estará formado por cadenas de  $E$ 's y  $F$ 's de longitud  $n$ . Consideremos la v.a.

$$X(\overbrace{EFFF \dots EEF}^n) = \text{número de éxitos en la cadena.}$$

A la variable aleatoria anterior se le conoce como distribución binomial de parámetros  $n$  y  $p$ , y lo denotaremos por  $X \equiv B(n, p)$ .

# Función de probabilidad de una binomial

Entonces su **función de probabilidad** es

$$P_X(x) = \begin{cases} \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x} & \text{si } x = 0, 1, \dots, n \\ 0 & \text{en otro caso} \end{cases} .$$

## Función de distribución de binomial

Su **función de distribución** no tiene una fórmula cerrada. Hay que acumular la función de probabilidad:

$$\begin{aligned}
 F_X(x) = P(X \leq x) &= \sum_{i=0}^x P_X(i) \\
 &= \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i} & \text{si } \begin{cases} k \leq x < k+1 \\ k = 0, 1, \dots, n. \end{cases} \\ 1 & \text{si } n \leq x \end{cases}
 \end{aligned}$$



## Números binomiales con R

Los números binomiales calculan el número de equipos de baloncesto distintos que ( $k = 5$  jugadores) se pueden hacer con 6 jugadores ( $n = 6$ ).

Es decir cuántas maneras distintas hay para elegir (*choose*) 5 jugadores en un conjunto de 6 jugadores. Todo el mundo diría ¡¡¡6!!!. Efectivamente con R es

```
choose(6,5)
```

```
[1] 6
```

## Números binomiales con R

Con 10 jugadores el número de equipos de 5 distintos es bastante más grande

```
choose(10,5)
```

```
[1] 252
```

Y, por ejemplo, con un equipo de fútbol profesional que tiene en plantilla 22 jugadores (quitando los guardametas) se pueden formar ¡¡nada menos que!!

```
choose(22,10)
```

```
[1] 646646
```

un bonito número capicúa que nos da el número de equipos distintos que se pueden formar.

# Distribución Binomial

Obviamente se tiene que una v.a. Bernoulli es una binomial con  $n = 1$

$$B(1, p) = Ber(p).$$

## Ejercicio

Calculad las funciones de distribución de una binomial  $B(n = 1, p = 0.3)$  y comprobar que coinciden con las distribuciones de una  $Ber(p = 0.3)$ .

# Observaciones sobre la distribución binomial

- La probabilidad de fracaso se suele denotar con  $q = 1 - p$ , **sin ningún aviso adicional**, con el fin de acortar y agilizar la escritura de las fórmulas.
- Su **función de distribución no tienen una formula general**, hay que calcularla con una función de R o python... En el siglo pasado se tabulaban en los libros de papel :-).
- En el material adicional os pondremos unas tablas de esta distribución para distintos valores de  $n$  y  $p$  para que disfrutéis de tan ancestral método de cálculo.
- Cualquier paquete estadístico, hoja de cálculo dispone de funciones para el cálculo de estas probabilidades, así que el **uso de las tablas** queda **totalmente anticuado**.

## Esperanza de una $B(n, p)$

Su **esperanza** es

$$E(X) = \sum_{k=0}^n k \cdot \binom{n}{k} \cdot p^k \cdot q^{n-k} = n \cdot p.$$

La esperanza de  $X^2$  es

$$\begin{aligned} E(X^2) &= \sum_{k=0}^n k^2 \cdot \binom{n}{k} \cdot p^k \cdot q^{n-k} \\ &= n \cdot p \cdot q + (n \cdot p)^2. \end{aligned}$$

## Varianza de una $B(n, p)$

Su **varianza** es

$$Var(X) = E(X^2) - (E(X))^2 = n \cdot p \cdot q = n \cdot p \cdot (1 - p).$$

Su desviación típica es

$$\sqrt{n \cdot p \cdot q} = \sqrt{n \cdot p \cdot (1 - p)}.$$

En temas posteriores veremos una forma sencilla del cálculo de la esperanza y varianza de una  $B(n, p)$  como la suma de  $n$  v.a.  $Ber(p)$  independientes.

### Ejercicio

Justificar de forma intuitiva que si  $X_i$  con  $i = 1, 2, \dots, n$  son v.a.  $Ber(p)$  independientes

entonces  $X = \sum_{i=1}^n X_i$  sigue una distribución  $B(n, p)$ .

# Resumen v.a con distribución binomial $B(n, p)$

$X$ binomial: $B(n, p)$
$D_X = \{0, 1, \dots, n\}$
$P_X(x) = P(X=x) = \begin{cases} \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x} & \text{si } x = 0, 1, \dots, n \\ 0 & \text{en otro caso.} \end{cases}$
$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i} & \text{si } k \leq x < k+1 \text{ para } k=0, 1, \dots, n \\ 1 & \text{si } x \geq n \end{cases}$
$E(X) = n \cdot p; \text{ Var}(X) = n \cdot p \cdot (1-p)$

## Cálculos binomial con R

Veamos los cálculos básicos con funciones de R para una v.a  $X$  con distribución binomial  $B(n = 10, p = 0.25)$ .

Si queremos calcular con R algún valor de la función de distribución como por ejemplo  $F_X(0) = P(X \leq 0)$ , tenemos que hacer:

```
pbinom(0,size=10,prob=0.25)
```

```
[1] 0.05631351
```

y si queremos por ejemplo  $F_X(4) = P(X \leq 4)$ , tenemos que hacer:

```
pbinom(4,size=10,prob=0.25)
```

```
[1] 0.9218731
```



## Cálculos binomial con R

Sin embargo, si queremos calcular algún valor de la función de probabilidad como por ejemplo  $P(X = 0)$ , tenemos que hacer:

```
dbinom(0,size=10,prob=0.25)
```

```
[1] 0.05631351
```

o por ejemplo para  $P(X = 4)$ :

```
dbinom(4,size=10,prob=0.25)
```

```
[1] 0.145998
```

## Generación de muestras aleatorias con R

Generaremos una muestra aleatoria de 100 valores de una población con distribución  $B(20, 0.5)$

```
set.seed(2019)
rbinom(100,size = 20,prob=0.5)
```

```
[1] 12 11  9 11  6  6 12  5  7 11 12 11  8  8 11 11  7 11  9 10  9 10 14  8
[26]  5 11 14 11 10 11  5 12  8  6  7  9 10  5 12 11  9 12 11 12 10 13 13  8
[51]  9  7  6  9 10  9 16 13  6  6  8  8 11  9 12 15  9  7 12 11  9  8  9  8
[76] 15  7 10  9 12  6 13 14  8 10  8 10 11 11  9 10 11 12  8 10 12  9 13  9
```

### Ejemplo

El ejemplo anterior correspondería a repetir 100 veces el experimento de lanzar una moneda 20 veces y contar el número de caras.

## Cálculos distribución binomial con python

Veamos los cálculos básicos con funciones de python para una v.a  $X$  con distribución binomial  $B(n = 10, p = 0.25)$ .

Primero importamos la función `binom` de la librería `scipy.stat`

```
from scipy.stats import binom
```

En general en el paquete `scipy`, la función de probabilidad se invocará con el método `pmf`, la de distribución con el método `cdf` mientras que una muestra aleatoria que siga esta distribución con el método `rvs`. En todos ellos aparecerá siempre el parámetro `loc` que se utiliza para desplazar el dominio de la variable aleatoria. Por ejemplo, en este caso

```
binom.pmf(k, n, p, loc) = binom.pmf(k - loc, n, p)
```

## Cálculos distribución binomial con python

Para calcular los valores de la función de distribución como por ejemplo  $F_X(0) = P(X \leq 0)$  y  $F_X(4) = P(X \leq 4)$  utilizamos la función `cdf`

```
binom.cdf(0,n=10,p=0.25)
```

0.056313514709472684

```
binom.cdf(4,n=10,p=0.25)
```

0.9218730926513672

Notemos que al no indicar el valor de `loc`, se le asume que toma el valor 0.

## Cálculos distribución binomial con python

Para calcular los valores de la función de probabilidad  $P(X = 0)$  y  $P(X = 4)$  utilizamos la función pmf:

```
binom.pmf(0,n=10,p=0.25)
```

0.056313514709472656

```
binom.pmf(4,n=10,p=0.25)
```

0.14599800109863284

Notemos que al no indicar el valor de loc, se le asume que toma el valor 0.

## Cálculos distribución binomial con python

Si queremos generar una muestras aleatorias que siga una distribución binomial, podemos usar la función `rvs`. En este caso, generaremos una muestra aleatoria de 100 valores de una población  $B(20, 0.5)$

```
binom.rvs(n=20,p=0.25,size = 100)
```

```
array([ 5,  5,  3,  7,  2,  4,  3,  3,  5,  2,  5,  6,  6,  3, 11,  3,  7,
        6,  4,  6,  3,  1,  2,  4,  7,  5,  6,  6,  8,  7,  3,  6,  3,  7,
        6,  5,  5,  4,  2,  1,  6,  4,  9,  0,  5,  3,  7,  2,  7, 11,  7,
        6,  7,  6,  3,  7,  4,  3,  6,  2,  5,  2,  4,  5,  3,  3,  3,  7,
        4,  9,  5, 12,  5,  6,  4,  6,  6,  2,  4,  7,  4,  6,  3,  5,  4,
        6,  4,  7,  3,  5,  7,  3,  5,  5,  5,  3,  4,  6,  5,  8],
      dtype=int64)
```

## Cálculos distribución binomial con python

Observación Notemos que la secuencia aleatoria generada no es la misma que con R. De hecho, si volvemos a ejecutar esta función obtendremos una muestra aleatoria distinta.

```
binom.rvs(n=20,p=0.25,size = 100)
```

```
array([ 5,  2,  9,  7,  4,  5,  8,  6,  4,  5,  2,  3,  6,  6,  4,  2,  4,
        6,  4,  7,  4,  2,  8,  6,  7,  2, 12,  6,  5,  6,  5,  6,  9,  5,
        3,  6,  2,  5,  5,  7,  4,  2,  5,  8, 10,  3,  6,  4,  7,  3,  6,
        3,  4,  8,  7,  7,  3, 11,  3,  5,  5,  6,  4,  6,  6,  5,  5,  6,
        6,  4,  5,  4,  2,  4,  3,  7,  7,  4,  5,  6,  5,  5,  4,  5,  5,
        8,  3,  4,  4,  2,  2,  4,  6,  5,  3,  6,  1,  3,  7,  5],
      dtype=int64)
```

## Cálculos binomial con python

Veamos algunos cálculos básicos con funciones de python para la binomial  $B(n = 10, p = 0.25)$ .

```
binom.cdf(5,n=10,p=0.25)
```

0.9802722930908203

```
binom.pmf(1,n=10,p=0.25)
```

0.1877117156982421

```
binom.rvs(n=20,p=0.25,size=10)
```

```
array([4, 4, 2, 6, 6, 4, 8, 3, 7, 3], dtype=int64)
```





## Gráficas de la distribución binomial con R

El siguiente código de R dibuja las función de probabilidad y la de distribución de una  $B(n = 10, p = 0.25)$

```
par(mfrow=c(1,2))
aux=rep(0,22)
aux[seq(2,22,2)]=dbinom(c(0:10),size=10,prob=0.25)
plot(x=c(0:10),y=dbinom(c(0:10),size=10,prob=0.25),
     ylim=c(0,1),xlim=c(-1,11),xlab="x",
     main="Función de probabilidad\n B(n=10,p=0.25)")
lines(x=rep(0:10,each=2),y=aux, type = "h", lty = 2,col="blue")
curve(pbinom(x,size=10,prob=0.25),
     xlim=c(-1,11),col="blue",
     main="Función de distribución\n B(n=10,p=0.25)")
par(mfrow=c(1,1))
```

# Gráficas de la distribución binomial con R

El siguiente código de R dibuja las función de probabilidad y la de distribución de una  $B(n = 10, p = 0.25)$



# Gráficos de la distribución binomial con python

## Ejercicio

Buscad en la documentación de python cómo se dibuja la función de probabilidad y de distribución de una binomial y recread los gráficos anteriores.

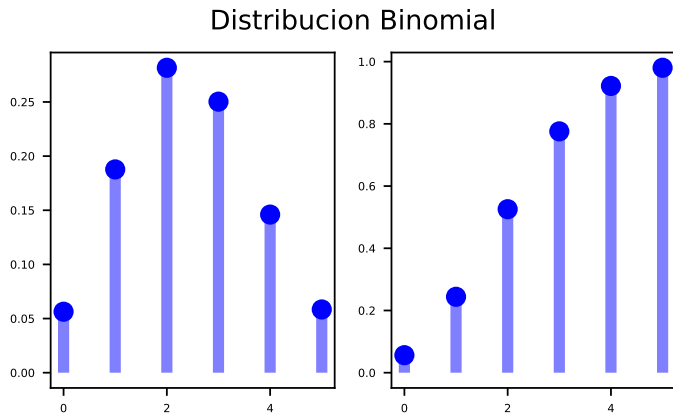
Pista: Necesitaremos investigar más librerías:

```
import numpy as np
import matplotlib.pyplot as plt
```

## Gráficos de la distribución binomial con python

```
n, p = 10, 0.25
x = np.arange(binom.ppf(0.01, n, p), binom.ppf(0.99, n, p))
fig = plt.figure(figsize=(5, 2.7))
ax = fig.add_subplot(1, 2, 1)
ax.plot(x, binom.pmf(x, n, p), 'bo', ms=8, label='binom pmf')
ax.vlines(x, 0, binom.pmf(x, n, p), colors='b', lw=5, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    tick.label.set_fontsize(5)
ax = fig.add_subplot(1, 2, 2)
ax.plot(x, binom.cdf(x, n, p), 'bo', ms=8, label='binom pmf')
ax.vlines(x, 0, binom.cdf(x, n, p), colors='b', lw=5, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
```

# Gráficos de la distribución binomial con python



## Ejemplo distribución binomial

### Ejemplo: número de bolas rojas extraídas de una urna con reposición

Tenemos una urna con 100 bolas de las cuales 40 son rojas y 60 son blancas. Extraemos al azar una bola, anotamos su color y la devolvemos a (reponemos en) la urna.

Supongamos que repetimos este proceso  $n = 10$  reponiendo en cada ocasión la bola extraída.

Consideremos la variable aleatoria  $X$  como el número de bolas rojas extraídas (con reposición) en  $n = 10$  repeticiones del mismo experimento de Bernoulli.

Bajo estas condiciones repetimos  $n = 10$  veces el mismo experimento de Bernoulli con probabilidad de éxito (sacar bola roja)

$$P(Roja) = P(xito) = p = \frac{40}{100} = 0.4.$$

Así que la variable  $X$  que es el número de bolas rojas extraídas de la urna (con reposición) en  $n = 10$  ocasiones sigue una ley binomial  $B(n = 10, p = 0.4)$ .

## Ejemplo $B(n = 10, p = 0.4)$ .

Nos preguntamos:

- ① ¿Cuál es la probabilidad de que saquemos exactamente 4 bolas rojas?
- ② ¿Cuál es la probabilidad de que saquemos al menos 4 bolas rojas?
- ③ ¿Cuál es la probabilidad de que saquemos menos de 3 bolas rojas?
- ④ ¿Cuál es el valor esperado del número de bolas rojas?
- ⑤ ¿Cuál es la desviación típica del número de bolas rojas?

Ejemplo  $B(n = 10, p = 0.4)$ .**Solución 1.** ¿Cuál es la probabilidad de que saquemos exactamente 4 rojas?

Utilizando la función de probabilidad, tenemos que:

$$\begin{aligned}
 P(X = 4) &= \binom{10}{4} \cdot 0.4^4 \cdot (1 - 0.4)^{10-4} = \frac{10!}{(10-4)! \cdot 4!} \cdot 0.4^4 \cdot 0.6^6 \\
 &= \frac{7 \cdot 8 \cdot 9 \cdot 10}{1 \cdot 2 \cdot 3 \cdot 4} \cdot 0.4^4 \cdot 0.6^6 = 0.2508227.
 \end{aligned}$$

Con R

```
dbinom(4,size=10,prob = 0.4)
```

```
[1] 0.2508227
```



## Ejemplo $B(n = 10, p = 0.4)$ .

**Solución 2.** ¿Cuál es la probabilidad de que saquemos al menos 4 bolas rojas?

La probabilidad de sacar al menos 4 rojas se expresa como

$$P(X \geq 4) = 1 - P(X < 4) = 1 - P(X \leq 3) :$$

$$\begin{aligned} P(x \leq 3) &= P(X = 0) + P(X = 1) + P(X = 2) + P(X = 3) \\ &= \binom{10}{0} \cdot 0.4^0 \cdot (1 - 0.4)^{10-0} + \binom{10}{1} \cdot 0.4^1 \cdot (1 - 0.4)^{10-1} \\ &\quad + \binom{10}{2} \cdot 0.4^2 \cdot (1 - 0.4)^{10-2} + \binom{10}{3} \cdot 0.4^3 \cdot (1 - 0.4)^{10-3} \\ &= 0.3822806. \end{aligned}$$

## Ejemplo $B(n = 10, p = 0.4)$ .

Con R

```
pbinom(3,10,0.4)
```

```
[1] 0.3822806
```

Así que

$$P(X \geq 4) = 1 - P(X < 4) = 1 - P(X \leq 3) = 1 - 0.3822806 = 0.6177194.$$

## Ejemplo $B(n = 10, p = 0.4)$ .

Otra manera usando R sería:

```
1-pbinom(3,10,0.4)
```

```
[1] 0.6177194
```

Aunque en estos casos el parámetro `lower.tail = FALSE` es sin duda nuestra mejor opción:

```
pbinom(3,10,0.4,lower.tail = FALSE)
```

```
[1] 0.6177194
```

Ejemplo  $B(n = 10, p = 0.4)$ .

**Solución 3.** ¿Cuál es la probabilidad de que saquemos menos de 3 bolas rojas?

$$\begin{aligned}
 P(X < 3) &= P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2) \\
 &= \binom{10}{0} \cdot 0.4^0 \cdot (1 - 0.4)^{10-0} + \binom{10}{1} \cdot 0.4^1 \cdot (1 - 0.4)^{10-1} \\
 &\quad + \binom{10}{2} \cdot 0.4^2 \cdot (1 - 0.4)^{10-2} \\
 &= 0.1672898.
 \end{aligned}$$

En R:

```
dbinom(0,10,0.4)+dbinom(1,10,0.4)+dbinom(2,10,0.4)
```

```
[1] 0.1672898
```

## Ejemplo $B(n = 10, p = 0.4)$ .

**Solución 4.** ¿Cuál es el valor esperado del número de bolas rojas?

Como  $X$  es una  $B(n = 10, p = 0.4)$  sabemos que

$$E(X) = n \cdot p = 10 \cdot 0.4 = 4.$$

Aunque en python tenemos la función `stats` que nos lo calcula directamente:

```
print("E(X) = {m}".format(m=binom.stats(n = 10, p = 0.4, moments='m')))
```

## Ejemplo $B(n = 10, p = 0.4)$ .

**Solución 5.** ¿Cuál es la desviación típica del número de bolas rojas?

La varianza es:

$$\text{Var}(X) = n \cdot p \cdot (1 - p) = 10 \cdot 0.4 \cdot 0.6 = 2.4.$$

Por lo tanto la desviación típica es

$$\sqrt{\text{Var}(X)} = \sqrt{2.4} = 1.5491933.$$

Aunque en python tenemos la función `stats` que nos lo calcula directamente:

```
print("Var(X) = {v}".format(v=binom.stats(n = 10, p = 0.4, moments='v')))
```

## Lección 4

### Distribución geométrica

---

# Distribución geométrica

- Todos hemos jugado a, por ejemplo, tirar una moneda hasta que obtengamos la primera cara.
- O también tirar una pelota a una canasta de baloncesto hasta obtener la primera canasta.
- Desde otro punto de vista también podemos intentar modelar el número de veces que accionamos una interruptor y la bombilla se ilumina hasta que falla.
- O también el número de veces que un cajero automático nos da dinero hasta que falla.

**La modelización de este tipo de problemas se consigue con la llamada distribución geométrica.**



# Distribución geométrica

## Distribución geométrica

- Repitamos un experimento Bernoulli, de parámetro  $p$ , de forma independiente hasta obtener el primer éxito.
- Sea  $X$  la v.a. que cuenta el número de fracasos antes del primer éxito. Por ejemplo que hayamos tenido  $x$  fracasos será una cadena de  $x$  fracasos culminada con un éxito. Más concretamente

$$P(\overbrace{FFF \dots F}^x E) = P(F)^x \cdot P(E) = (1 - p)^x \cdot p = q^x \cdot p.$$

# Distribución geométrica

Su función de probabilidad es

$$P_X(x) = P(X = x) = \begin{cases} (1-p)^x \cdot p & \text{si } x = 0, 1, 2, \dots \\ 0 & \text{en otro caso} \end{cases}.$$

- La v.a. definida anteriormente diremos que sigue una distribución geométrica de parámetro  $p$ .
- La denotaremos por  $Ge(p)$ .
- Su dominio es  $D_X = \{0, 1, 2, \dots\}$ .

## Función de distribución geométrica

Calculemos  $P(X \leq 3)$ .

Por la propiedad de la probabilidad del suceso complementario tenemos que

$$P(X \leq 3) = 1 - P(X > 3) = 1 - P(X \geq 4)$$

Efectivamente, el complementario del evento  $X \leq 3$  nos dice que hemos fracasado más de tres veces hasta conseguir el primer éxito, es decir, **hemos fracasado 4 o más veces**. Podemos simbolizar dicho evento de la forma siguiente:

$$\{X > 3\} = \{X \geq 4\} = \{FFFF\}$$

## Función de distribución geométrica

Ahora, al ser los intentos independientes, tenemos que:

$$\begin{aligned}P(X > 3) &= P(\{FFFF\}) = P(F) \cdot P(F) \cdot P(F) \cdot P(F) \\&= (1-p) \cdot (1-p) \cdot (1-p) \cdot (1-p) = (1-p)^{3+1} \\&= (1-p)^4.\end{aligned}$$

El valor de la función de distribución de  $X$  en  $x = 3$  será, pues:

$$F_X(3) = P(X \leq 3) = 1 - P(X > 3) = 1 - (1-p)^{3+1}.$$

Generalizando el resultado anterior a cualquier entero positivo  $k = 0, 1, 2, \dots$ , tenemos:

$$F_X(k) = P(X \leq k) = 1 - (1-p)^{k+1}, \text{ si } k = 0, 1, 2, \dots$$

# Función de distribución geométrica

En general, tendremos que:

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 0, \\ 1 - (1 - p), & \text{si } k = 0 \leq x < 1, \\ 1 - (1 - p)^2, & \text{si } k = 1 \leq x < 2, \\ 1 - (1 - p)^3, & \text{si } k = 2 \leq x < 3, \\ 1 - (1 - p)^{k+1}, & \text{si } \begin{cases} k \leq x < k + 1, \\ \text{para } k = 0, 1, 2, \dots \end{cases} \end{cases} .$$

## Función de distribución geométrica

De forma más compacta, tendremos que

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 0, \\ 1 - (1 - p)^{k+1}, & \text{si } \begin{cases} k \leq x < k + 1, \\ \text{para } k = 0, 1, 2, \dots \end{cases} \end{cases}.$$

Notemos que el límite de la función de distribución es:

$$\lim_{k \rightarrow +\infty} F_X(k) = \lim_{k \rightarrow +\infty} 1 - (1 - p)^{k+1} = 1,$$

ya que  $0 < 1 - p < 1$ .

# Sumas derivadas series geométricas

Recordemos del tema de variables aleatorias que

Propiedades

- Si  $|r| < 1$  también son convergentes las derivadas, respecto de  $r$ , de la serie geométrica y convergen a la derivada correspondiente. Así tenemos que

$$\begin{aligned} \left( \sum_{k=0}^{+\infty} r^k \right)' &= \sum_{k=1}^{+\infty} k \cdot r^{k-1} &= \left( \frac{1}{1-r} \right)' &= \frac{1}{(1-r)^2} \\ \left( \sum_{k=0}^{+\infty} r^k \right)'' &= \sum_{k=2}^{+\infty} k \cdot (k-1) \cdot r^{k-2} &= \left( \frac{1}{1-r} \right)'' &= \frac{2}{(1-r)^3} \end{aligned}$$

## Esperanza de una v.a. $Ge(p)$

Recordemos que  $P(X = x) = (1 - p)^x \cdot p$  si  $x = 0, 1, 2, \dots$  y aplicado la fórmula anterior con  $r = 1 - p$

$$\begin{aligned} E(X) &= \sum_{x=0}^{+\infty} x \cdot P_x(x) = \sum_{x=0}^{+\infty} x \cdot (1 - p)^x \cdot p \\ &= p \cdot (1 - p) \cdot \sum_{x=1}^{+\infty} x \cdot (1 - p)^{x-1} \\ &= p \cdot (1 - p) \cdot \frac{1}{(1 - (1 - p))^2} = p \cdot (1 - p) \cdot \frac{1}{p^2} = \frac{1 - p}{p} \end{aligned}$$



Valor  $E(X^2)$  de una v.a.  $Ge(p)$ 

$$\begin{aligned} E(X^2) &= \sum_{x=0}^{+\infty} x^2 \cdot P_X(x) = \sum_{x=1}^{+\infty} x^2 \cdot (1-p)^x \cdot p \\ &= \sum_{x=1}^{+\infty} (x \cdot (x-1) + x) \cdot (1-p)^x \cdot p \\ &= \sum_{x=1}^{+\infty} x \cdot (x-1) \cdot (1-p)^x \cdot p + \sum_{x=1}^{+\infty} x \cdot (1-p)^x \cdot p \\ &= (1-p)^2 \cdot p \cdot \sum_{x=2}^{+\infty} x \cdot (x-1) \cdot (1-p)^{x-2} \\ &+ (1-p) \cdot p \sum_{x=1}^{+\infty} x \cdot (1-p)^{x-1} = \dots \end{aligned}$$

# Valor $E(X^2)$ de una v.a. $Ge(p)$

$$\begin{aligned}
 E(X^2) &= \dots \\
 &= (1-p)^2 \cdot p \cdot \sum_{x=2}^{+\infty} x \cdot (x-1) \cdot (1-p)^{x-2} \\
 &+ (1-p) \cdot p \sum_{x=1}^{+\infty} x \cdot (1-p)^{x-1} \\
 &= p \cdot (1-p)^2 \frac{2}{(1-(1-p))^3} + (1-p) \cdot p \frac{1}{(1-(1-p))^2} \\
 &= p \cdot (1-p)^2 \frac{2}{p^3} + (1-p) \cdot p \frac{1}{p^2} \\
 &= \frac{2 \cdot (1-p)^2}{p^2} + \frac{1-p}{p}.
 \end{aligned}$$

## Varianza de una v.a. $Ge(p)$

$$\begin{aligned}
 Var(X) &= E(X^2) - E(X)^2 = \frac{2 \cdot (1-p)^2}{p^2} + \frac{1-p}{p} - \left(\frac{1-p}{p}\right)^2 \\
 &= \frac{2 \cdot (1-p)^2 + p \cdot (1-p) - (1-p)^2}{p^2} = \frac{(1-p)^2 + p \cdot (1-p)}{p^2} \\
 &= \frac{1 - 2 \cdot p + p^2 + p - p^2}{p^2} \\
 &= \frac{1-p}{p^2}.
 \end{aligned}$$

Y su desviación típica será

$$\sqrt{Var(X)} = \sqrt{\frac{1-p}{p^2}}.$$

Resumen distribución geométrica  $Ge(p)$  empezando en 0

$X = \text{Geométrica (empieza en 0) número de fracasos para conseguir el primer éxito}$

$$D_X = \{0, 1, \dots, n, \dots\}$$

$$P_X(x) = P(X = x) = \begin{cases} (1-p)^x \cdot p & \text{si } x = 0, 1, 2, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - (1-p)^{k+1} & \text{si } \begin{cases} k \leq x < k+1 \\ \text{para } k = 0, 1, 2, \dots \end{cases} \end{cases}$$

$$E(X) = \frac{1-p}{p}; \text{Var}(X) = \frac{1-p}{p^2}$$

La variable geométrica que cuenta los intentos para obtener el primer éxito.

- Supongamos que sólo estamos interesados en el **número de intentos** para obtener el primer éxito.
- Si definimos  $Y$  = número de intentos para obtener el primer éxito. Entonces  $Y = X + 1$  donde  $X \equiv Ge(p)$ .
- Su dominio es  $D_Y = \{1, 2, \dots\}$
- La media se incrementa en un intento debido al éxito  

$$E(Y) = E(X + 1) = E(X) + 1 = \frac{1-p}{p} + 1 = \frac{1}{p}.$$
- La varianza es la misma  $Var(Y) = Var(X + 1) = Var(X) = \frac{1-p}{p^2}.$

Resumen distribución geométrica  $Ge(p)$  empezando en 1.

$Y$  geométrica (que cuenta el éxito) número de **INTENTOS** para OBTENER el primer éxito

$$D_Y = \{1, 2, \dots, n, \dots\}$$

$$P_Y(y) = P(Y = y) = \begin{cases} (1-p)^{y-1} \cdot p & \text{si } y = 1, 2, 3, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

$$F_Y(y) = P(Y \leq y) = \begin{cases} 0 & \text{si } y < 1 \\ 1 - (1-p)^k & \text{si } \begin{cases} k \leq y < k+1 \\ \text{para } k = 1, 2, 3, \dots \end{cases} \end{cases}$$

$$E(X) = \frac{1}{p}; \text{Var}(X) = \frac{1-p}{p^2}$$

## Propiedad de la falta de memoria

Propiedad de la falta de memoria

Sea  $X$  una v.a. discreta con dominio  $D_X = \{0, 1, 2, \dots\}$ , con  $P(X = 0) = p$ .

Entonces  $X$  sigue una ley  $Ge(p)$  si, y sólo si,

$$P(X > k + j | X \geq j) = P(X > k)$$

para todo  $k, j = 0, 1, 2, 3, \dots$

# Propiedad de la falta de memoria

## Demostración

Si  $X$  es geométrica entonces el lado derecho de la igualdad es

$$P(X > k) = 1 - P(X \leq k) = 1 - (1 - (1 - p)^{k+1}) = (1 - p)^{k+1},$$

y el lado de izquierdo es

{

$$\begin{aligned} P(X > k + j | X \geq j) &= \frac{P(\{X > k + j\} \cap \{X \geq j\})}{P(X \geq j)} = \frac{P(X > k + j)}{P(X \geq j)} = \frac{1 - P(X \leq k + j)}{1 - P(X \leq j - 1)} \\ &= \frac{1 - (1 - (1 - p)^{k+j+1})}{1 - (1 - (1 - p)^{j-1+1})} = \frac{(1 - p)^{k+j+1}}{(1 - p)^j} = (1 - p)^{k+1}, \end{aligned}$$

}

lo que demuestra la igualdad.



## Propiedad de la falta de memoria

Para demostrar el recíproco, tomemos  $j = 1$  y  $k \geq 0$ . Entonces, por la propiedad de la pérdida de memoria:

$$P(X > k + 1 | X \geq 1) = P(X > k)$$

Como  $P(X = 0) = p$ , tenemos que  $P(X \geq 1) = 1 - P(X < 1) = 1 - P(X = 0) = 1 - p$ .

Combinado las igualdades, tenemos que:

$$P(X > k + 1 | X \geq 1) = \frac{P(X > k + 1, X \geq 1)}{P(X \geq 1)} = \frac{P(X > k + 1)}{P(X \geq 1)} = P(X > k).$$

Así podemos poner que

$$\begin{aligned} P(X > k + 1) &= P(X \geq 1) \cdot P(X > k) = (1 - P(X < 1)) \cdot P(X > k) \\ &= (1 - P(X = 0)) \cdot P(X > k) = (1 - p) \cdot P(X > k). \end{aligned}$$

## Propiedad de la falta de memoria

Es decir en general tenemos que

$$P(X > k + 1) = (1 - p) \cdot P(X > k)$$

Del mismo modo para  $j = 2$

$$P(X > k + 2) = (1 - p) \cdot P(X > k + 1)$$

Restando la primera igualdad de la última obtenemos.

$$P(X > k + 1) - P(X > k + 2) = (1 - p) \cdot P(X > k) - (1 - p) \cdot P(X > k + 1)$$

de donde operando en cada lado de la igualdad obtenemos la recurrencia

$$[1 - P(X \leq k + 1)] - [1 - P(X \leq k + 2)] = (1 - p) \cdot [P(X > k) - P(X > k + 1)]$$

## Propiedad de la falta de memoria

De forma similar obtenemos

$$P(X = k + 1) = (1 - p) \cdot P(X = k)$$

Utilizando la recurrencia anterior, podemos calcular todas las probabilidades  $P(X = k)$  a partir de la  $P(X = 0) = p$ :

$$\begin{aligned} P(X = 0) &= p, \\ P(X = 1) &= P(X = 0 + 1) = (1 - p) \cdot P(X = 0) = (1 - p) \cdot p, \\ P(X = 2) &= P(X = 1 + 1) = (1 - p) \cdot P(X = 1) = (1 - p) \cdot (1 - p) \cdot p = (1 - p)^2 \cdot p, \\ &\vdots \\ P(X = k) &= P(X = (k - 1) + 1) = (1 - p) \cdot P(X = k - 1) = (1 - p) \cdot (1 - p)^{k-1} \cdot p = (1 - p)^k \cdot p, \end{aligned}$$

lo que demuestra el recíproco, es decir, que  $X$  es  $Geom(p)$ .

## Falta de memoria

Observación: Interpretación de la propiedad

La propiedad de la falta de memoria

$$P(X > k + j | X \geq j) = P(X > k),$$

significa que, aunque **ya llevemos al menos  $j$  fracasos**, la probabilidad de **que fracasemos  $k$  veces más** no disminuye, es la misma que era cuando empezamos el experimento.

A este efecto se le suele etiquetar con la frase **el experimento carece de memoria** o es un **experimento sin memoria** (*Memoryless Property*).

## Ejemplo falta de memoria

Un ejemplo muy sencillo nos aclarará el alcance de esta propiedad

### Ejercicio: la llave que abre la puerta

Tenemos un llavero con 10 llaves, solo una de ellas abre una puerta. Cada vez que probamos una llave y falla olvidamos que llave hemos probado. ¿Cuál es la probabilidad de que si ya lo hemos intentado 5 veces necesitemos más de 4 intentos adicionales para abrir la puerta?

Tomemos  $k = 4, j = 5$ , aplicando la propiedad de la falta de memoria

$$P(X > 4 + 5 / X \geq 5) = P(X > 4)$$

Después de 5 fracasos no estamos “más cerca” de abrir la puerta. La propiedad de la falta de memoria nos dice que en **después de cada intento es como si empezásemos de nuevo a abrir la puerta**. Tras 5 fracasos la probabilidad de que fallemos más de 4 veces más es la misma que cuando lo intentamos la primera vez.

## Ejemplo falta de memoria

¿Cuál es el número esperado de fracasos hasta abrir la puerta?

$$E(X) = \frac{1-p}{p} = \frac{1-\frac{1}{10}}{\frac{1}{10}} = \frac{\frac{9}{10}}{\frac{1}{10}} = 9.$$

La varianza es

$$Var(X) = \frac{1-p}{p^2} = \frac{1-\frac{1}{10}}{\left(\frac{1}{10}\right)^2} = \frac{\frac{9}{10}}{\frac{1}{100}} = 90.$$

La desviación típica es  $\sqrt{90} = 9.486833$ .

## Ejemplo: El clásico del fútbol

### Ejemplo: partidos hasta que el Barça gana al Madrid

Los partidos Real Madrid vs FC Barcelona de **la liga** española se suelen denominar **El Clásico**, sean en el Bernabeu (estadio del Real Madrid) o en el Camp Nou (estadio del Barça)

Sea  $X$  la variable que cuenta el número de veces consecutivas que en un partido de fútbol de la liga el Barça no gana al Madrid sea en el Camp Nou o el Bernabeu.

Nuestra amiga Aina es muy culé (hinchas del Barça) y quiere averiguar cuántos partidos consecutivos de **El Clásico** tiene que ver hasta ver ganar al Barça por primera vez.

Le interesa estimar cuánto le va a costar este capricho. Tendrá que comprar las entradas y pagar los viajes de Barcelona a Madrid.

En [datos historicos de El clásico en la wikipedia](#) están los datos hasta el 3 de marzo de 2019: se han jugado en total 178 **Clásicos** donde el Real Madrid ganó en 72 ocasiones, el Barça, en 72 y empataron 34 veces.

## Ejemplo: El clásico del fútbol

Nos hacemos las siguientes preguntas:

- Si Aina solo tiene dinero para ir a ver 3 partidos, ¿cuál es la probabilidad de no ver ganar al Barça en al menos tres partidos consecutivos?
- ¿Cuántos partidos se tienen que jugar de media para ver ganar al Barça por primera vez?

Con los datos anteriores, podemos estimar que la probabilidad de que el Barça gane un clásico cualquiera es:

$$P(\text{Barça}) = \frac{72}{178} = 0.4045.$$

Por tanto, podemos modelar la variable  $X$ , que cuenta el número de veces consecutivas que en un partido de fútbol de la liga el Barça no gana al Madrid, con una ley geométrica empezando en cero con probabilidad de éxito  $p = P(\text{Barça}) = \frac{72}{178}$ ,



## Ejemplo: El clásico del fútbol

$$X = Ge\left(p = \frac{72}{178} = 0.4045\right)$$

Así que lo que nos pregunta Aina es la siguiente probabilidad

$$P(X \geq 3) = 1 - P(X \leq 2) = 1 - \left(1 - \frac{72}{178}\right)^{2+1} = 0.7888.$$

Así que Aina tiene una probabilidad del 78.88% de no ver ganar al Barça en al menos 3 partidos antes de ver uno en el sí que gane.

## Variable geométrica: El clásico

Para responder a la segunda pregunta, usando que la distribución de  $X$  es:

$$X = Ge\left(p = \frac{72}{178} = 0.4045\right)$$

entonces

$$E(X) = \frac{1-p}{p} = \frac{1-0.4045}{0.4045} = 1.4722$$

y

$$Var(X) = \frac{1-p}{p^2} = \frac{1-0.4045}{0.4045^2} = 3.6397$$

La desviación típica es

$$\sqrt{3.6397} = 1.9078$$

## Cálculos con R

Veamos los cálculos básicos con R para la distribución geométrica  $Ge(p = 0.25)$ . R implementa la geométrica que cuenta el número de fracasos.

$$P(X = 0) = (1 - 0.25)^0 \cdot 0.25^1 = 0.25$$

```
dgeom(0,prob=0.25)
```

```
[1] 0.25
```

$$P(X \leq 0) = 1 - (1 - 0.25)^{0+1} = 1 - 0.75 = 0.25$$

```
pgeom(0,prob=0.25)
```

```
[1] 0.25
```

## Cálculos con R

$$P(X \leq 4) = 1 - (1 - 0.25)^{4+1} = 1 - 0.75 = 1 - 0.75^5 = 0.7626953.$$

```
pgeom(4,prob=0.25)
```

```
[1] 0.7626953
```

Una muestra aleatoria de tamaño 25 de una  $Ge(0.25)$



```
rgeom(n=25,prob=0.25)
```

```
[1] 5 4 1 6 10 0 0 10 7 0 6 2 1 3 0 2 5 0 0 5 5 3 3 2
```

## Gráficos con R el código

```
par(mfrow=c(1,2))
x=c(0:10)
plot(x=x,y=dgeom(x,prob=0.25),
     ylim=c(0,1),xlim=c(-1,11),xlab="x",
     main="Función de probabilidad\n Ge(p=0.25)")
lines(x=rep(0:10,each=2),y=aux, type = "h", lty = 2,col="blue")
aux0=dgeom(c(0:10),prob=0.25)
ceros=rep(0,21)
ceros
aux=ceros
aux[2*(c(1:11))]<-aux0
curve(pgeom(x,prob=0.25),
     xlim=c(-1,10),col="blue",
     main="Función de distribución\n Ge(p=0.25)")
```

# Los gráficos con R



## Cálculos con python

Veamos los cálculos básicos con python para la distribución geométrica  $Ge(p = 0.25)$ .  
scipy.stats implementa la distribución geométrica que cuenta el número intentos así que empieza en 1

Cargamos la función de la librería

```
from scipy.stats import geom
```

## Cálculos con python

La función de probabilidad es `geom.pmf(x,p,loc=0)=geom.pmf(x,p)` es una geométrica que cuenta el número de intentos para obtener el primer éxito el valor por defecto del último parámetro es `loc=0`.

Si queremos la que cuenta el número de fracasos para obtener el primer éxito (la geométrica que empieza en 0) tenemos que usar `geom.pmf(x,p,loc=-1)`.

Es decir `geom.pmf(x,p,loc=-1)=geom.pmf(x-1,p,loc=0)`

Veamos pues los cálculos para la  $Ge(p)$  que empieza en 0.

$$P(X = 0) = (1 - 0.25)^0 \cdot 0.25^1 = 0.25$$

```
geom.pmf(0,p=0.25,loc=-1)
```



# Cálculos con python

## Ejercicio

Qué probabilidades son las que calcula el siguiente código y qué tipo de variables geométricas son?

```
geom.cdf(range(5),p=0.3,loc=0)  
geom.cdf(range(5),p=0.3,loc=-1)
```

## Cálculos con python esperanza y varianza

Con python también podemos calcular directamente algunos parámetros asociado a una función de distribución predefinida

```
geom.stats(p=0.25, loc=0, moments='mv')  
geom.stats(p=0.25, loc=-1, moments='mv')
```

# Cálculos con python esperanza y varianza

## Ejercicio

Comprobad que las medias y las varianzas calculadas en el código anterior, corresponden a una  $Ge(p = 0.3)$  empezando en 1 y a una  $Ge(p = 0.3)$  empezando en 0.


¿Son las varianzas siempre iguales?

# Gráficos con python

```
p = 0.25
x = np.arange(geom.ppf(0.01, p), geom.ppf(0.99, p))
fig = plt.figure(figsize=(5, 2.7))
ax = fig.add_subplot(1,2,1)
ax.plot(x, geom.pmf(x, p), 'bo', ms=5, label='geom pmf')
ax.vlines(x, 0, geom.pmf(x, p), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    tick.label.set_fontsize(5)
ax = fig.add_subplot(1,2,2)
ax.plot(x, geom.cdf(x, p), 'bo', ms=5, label='geom pmf')
ax.vlines(x, 0, geom.cdf(x, p), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
```

# Gráficos con python

## Distribucion Geometrica



## Lección 5

### Distribución binomial negativa

---

## El problema de la puerta con dos cerraduras

Supongamos que disponemos de 10 llaves distintas y tenemos que abrir una puerta con **dos cerraduras**.

Comenzamos por la primera cerradura, de tal forma que cada vez olvidamos qué llave hemos probado.

Una vez abierta la primera cerradura probamos de igual forma con la segunda hasta que también la abrimos.

Sea  $X$  = la v.a. que cuenta el número de fracasos hasta abrir la puerta.

Acertar una llave de la puerta es un experimento Bernoulli con probabilidad de éxito  $p = 0.1$ . Lo repetiremos hasta obtener 2 éxitos.

# Distribución binomial negativa

En general tendremos un experimento de Bernoulli con probabilidad de éxito  $0 < p < 1$  tal que:

- Repetimos el experimento hasta obtener el  $n$ -ésimo éxito ¡¡abrir la maldita puerta!!.
- Sea  $X$  la v.a. que cuenta el número fallos hasta abrir la puerta, es decir, hasta conseguir el  $n$ -ésimo éxito. Notemos que no contamos los éxitos, solo contamos los fracasos



## Distribución binomial negativa

Si representamos como es habitual un suceso como una cadena de F's y E's, para  $n = 2$ , algunos sucesos elementales serán:

$$\{EE, FEE, EFE, FFEE, FEF E, EFFE, FFFEE, FFEFE, FEFFE, EFFFFE\}.$$

Calculemos algunas probabilidades para  $n = 2$ :

$$P(X = 0) = P(\{EE\}) = p^2,$$

$$P(X = 1) = P(\{FEE, EFE\}) = 2 \cdot (1 - p) \cdot p^2,$$

$$P(X = 2) = P(\{FFEE, FEF E, EFFE\}) = 3 \cdot (1 - p)^2 \cdot p^2,$$

$$P(X = 3) = P(\{FFFEE, FFEFE, FEFFE, EFFFFE\}) = 4 \cdot (1 - p)^3 \cdot p^2.$$

# Distribución binomial negativa

En general su función de probabilidad es

$$P_X(k) = P(X = k) = \begin{cases} \binom{k+n-1}{n-1} \cdot (1-p)^k \cdot p^n & \text{si } k = 0, 1, \dots \\ 0 & \text{en otro caso} \end{cases}$$

# Distribución binomial negativa

Una v.a. con este tipo de distribución recibe el nombre de **binomial negativa** y la denotaremos por  $BN(n, p)$ .

Notemos que  $BN(1, p) = Ge(p)$ .

# Distribución binomial negativa

## Demostración

Justifiquemos el resultado. Sea  $X$  una  $BN(n, p)$  y sea  $k = 0, 1, 2, \dots$

$$P(X = k) = P(\text{Todas las cadenas de E's y F' con } k \text{ F, con } n \text{ E y acabadas en E})$$

$$\begin{array}{c} \overbrace{\hspace{10em}}^{k+n-1 \text{ posiciones}} \\ \overbrace{\hspace{4em}}^{n-1 \text{ Éxitos.}} \\ \overbrace{\hspace{10em}}^{k \text{ Fracazos}} \\ E F F F \dots E E F E \end{array}$$

De estas cadenas hay tantas como maneras de elegir de entre las  $k + n - 1$  primeras posiciones  $n - 1$  para colocar los éxitos. Esta cantidad es el número binomial  $\binom{k+n-1}{n-1}$ .

# Números binomiales negativos

## Números binomiales negativos

Dados dos enteros positivos  $n$  y  $k$  se define el número binomial negativo como

$$\binom{-n}{k} = \frac{(-n)(-n-1)\cdots(-n-k+1)}{k!}.$$

Los números binomiales negativos generalizan la fórmula de Newton para exponentes negativos:

$$(t+1)^{-n} = \sum_{k=0}^{+\infty} \binom{-n}{k} t^k$$

## Números binomiales negativos

R usa la función `choose` para calcular números binomiales, sean negativos o no. Veámoslo con un ejemplo:

$$\begin{aligned}
 \binom{-6}{4} &= \frac{-6 \cdot (-6-1) \cdot (-6-2) \cdot (-6-3)}{4!} \\
 &= \frac{-6 \cdot (-7) \cdot (-8) \cdot (-9)}{24} \\
 &= \frac{3024}{24} = 126.
 \end{aligned}$$

Si realizamos el cálculo con R obtenemos el mismo resultado:

```
choose(-6,4)
```

```
[1] 126
```

## Esperanza de una $BN(n, p)$

Su esperanza es

$$E(X) = \sum_{k=0}^{+\infty} k \cdot \binom{k+n-1}{n-1} \cdot (1-p)^k \cdot p^n = n \cdot \frac{1-p}{p}.$$

La esperanza de  $X^2$  es

$$E(X^2) = \sum_{k=0}^{+\infty} k^2 \cdot \binom{k+n-1}{n-1} \cdot (1-p)^k \cdot p^n = n \cdot \frac{1-p}{p^2} + \left( n \cdot \frac{1-p}{p} \right)^2.$$

## Varianza de una $BN(n, p)$

Por último la **varianza** es

$$\begin{aligned} Var(X) &= E(X^2) - E(X)^2 = \\ &= n \cdot \frac{1-p}{p^2} + \left(n \cdot \frac{1-p}{p}\right)^2 - \left(n \cdot \frac{1-p}{p}\right)^2 = n \cdot \frac{1-p}{p^2}. \end{aligned}$$

y por tanto la desviación típica es

$$\sqrt{Var(X)} = \frac{\sqrt{n(1-p)}}{p}$$



Resumen distribución Binomial Negativa  $BN(n, p)$ 

$X$  = Número de fracasos antes de conseguir el  $n$ -ésimo éxito,  $P(\text{Éxito}) = p$ .  $BN(n, p)$

$$D_X = \{0, 1, 2, 3 \dots\}$$

$$P_X(k) = P(X = k) = \begin{cases} \binom{k+n-1}{n-1} \cdot (1-p)^k \cdot p^n, & \text{si } k = 0, 1, \dots \\ 0, & \text{en otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 0 \\ \sum_{i=0}^k P(X = i) & \text{si } \begin{cases} k \leq x < k+1, \\ k = 0, 1, 2, \dots \end{cases} \end{cases}$$

$$E(X) = n \cdot \frac{1-p}{p}; \text{Var}(X) = n \cdot \frac{1-p}{p^2}.$$

## Ejemplo puerta dos cerraduras $BN(n = 2, p = 0.1)$ .

### Ejercicio: Puerta con dos cerraduras

Recordemos nuestra puerta con dos cerraduras que se abren secuencialmente. Tenemos un manajo de 10 llaves casi idénticas de manera que cada vez que probamos una llave olvidamos qué llave hemos usado.

Sea  $X$  la v.a que nos da el número de intentos fallidos hasta abrir la puerta.

## Ejemplo $BN(n, p)$

Estamos interesado en modelar este problema. Las preguntas son:

- 1 ¿Cuál es la distribución de probabilidad de  $X$  la v.a que nos da el número fallos hasta abrir la puerta?
- 2 ¿Cuál es la función de probabilidad y de distribución de  $X$ ?
- 3 ¿Cuál es la probabilidad de fallar exactamente 5 veces antes de abrir la puerta?
- 4 ¿Cuál es la probabilidad de fallar más de 4?
- 5 ¿Cuál es el número esperado de fallos? ¿Y su desviación típica?

## Ejemplo dos cerraduras $BN(n = 2, p = 0.1)$ .

**Solución 1.** ¿Cuál es la distribución de probabilidad de  $X$  la v.a que nos da el número fallos hasta abrir la puerta?

Bajo estas condiciones tenemos que la probabilidad de “éxito” de cada intento es  $p = \frac{1}{10} = 0.1$ . Como cada vez *olvidamos* qué llave hemos probado, cada intento será independiente del anterior.

Así que la variable  $X$  que queremos modelar cuenta el número fallos de repeticiones sucesivas e independientes de un experimento  $Ber(p = 0.1)$  hasta conseguir 2 éxitos en un experimento.

Por lo tanto podemos asegurar que  $X$  sigue una distribución  $BN(n = 2, p = 0.1)$ .

Ejemplo  $BN(n = 2, p = 0.1)$ 

**Solución 2.** ¿Cuál es la función de probabilidad y de distribución del  $X$ ?

En general la función de probabilidad de una  $BN(n, p)$  es

$$P_X(k) = P(X = k) = \begin{cases} \binom{k+n-1}{n-1} \cdot (1-p)^k \cdot p^n & \text{si } k = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

Si aplicamos la expresión anterior para  $n = 2$  y  $p = 0.1$ , obtenemos:

$$P_X(k) = P(X = k) = \begin{cases} \binom{k+2-1}{2-1} \cdot 0.9^k \cdot 0.1^2 & \text{si } k = 0, 1, 2, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

Ejemplo  $BN(n = 2, p = 0.1)$ 

Simplificando

$$P_X(X = k) = P(X = k) = \begin{cases} 0.01 \cdot (k + 1) \cdot 0.9^k, & \text{si } k = 0, 1, 2, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

La función de distribución en general es

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k \binom{i+n-1}{n-1} \cdot (1-p)^{i+n-1} \cdot p^n & \text{si } \begin{cases} k \leq x < k+1 \\ k = 0, 1, 2, \dots \end{cases} \end{cases}$$

Ejemplo  $BN(n = 2, p = 0.1)$ 

Simplificando para  $n = 2, p = 0.1$ .

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 0, \\ \sum_{i=0}^k 0.01 \cdot (i+1) \cdot 0.9^{i+1}, & \text{si } \begin{cases} k \leq x < k+1, \\ k = 0, 1, 2, \dots \end{cases} \end{cases}$$

**Solución 3.** ¿Cuál es la probabilidad de fallar exactamente 5 veces antes de abrir la puerta?

$$P(X = 5) = 0.01 \cdot (5 + 1) \cdot 0.9^5 = 0.06 \cdot 0.9^5 = 0.0354294.$$

Ejemplo  $BN(n = 2, p = 0.1)$ 

**Solución 4.** ¿Cuál es la probabilidad de fallar más de 4?

Nos piden que

$$P(X > 4) = 1 - P(X \leq 4).$$

Calculemos primero  $P(X \leq 4)$  :

$$\begin{aligned} P(X \leq 4) &= \sum_{x=0}^4 P(X = x) = P(X = 0) + P(X = 1) + P(X = 2) + P(X = 3) + P(X = 4) \\ &= 0.01 \cdot (0 + 1) \cdot 0.9^0 + 0.01 \cdot (1 + 1) \cdot 0.9^1 + 0.01 \cdot (2 + 1) \cdot 0.9^2 \\ &\quad + 0.01 \cdot (3 + 1) \cdot 0.9^3 + 0.01 \cdot (4 + 1) \cdot 0.9^4 \\ &= 0.01 + 0.018 + 0.0243 + 0.02916 + 0.032805 = 0.114265. \end{aligned}$$



Ejemplo  $BN(n = 2, p = 0.1)$ 

Por lo tanto

$$P(X > 4) = 1 - P(X \leq 4) = 1 - 0.114265 = 0.885735.$$

**Solución 5.** ¿Cuál es el número esperado de fallos? ¿Y su desviación típica?

Como  $X$  sigue una ley  $BN(n = 2, p = 0.1)$

$$E(X) = n \cdot \frac{1-p}{p} = 2 \cdot \frac{1-0.1}{0.1} = 18.$$

El número de fallos esperado es 18. La varianza es

$$Var(X) = n \cdot \frac{1-p}{p^2} = 2 \cdot \frac{1-0.1}{0.1^2} = 180,$$

## Cálculos con R

La función de R que calcula la función de probabilidad de la binomial negativa con sus parámetros básicos es:

```
dnbinom(x, size, prob,...)`
```

donde *size* ( $n$ ) es el número de éxitos y *prob* ( $p$ ), la probabilidad de éxito.

Así en el ejemplo de la puerta con dos cerraduras,  $X$  es una  $BN(n = size = 2, p = prob = 0.1)$ . Por ejemplo,  $P(X = 5)$  que hemos calculado en el ejemplo anterior, vale:

```
dnbinom(5,size=2,p=0.1)
```

```
[1] 0.0354294
```

## Cálculos con R

De forma similar calculamos  $P(X \leq 4)$ ,  $P(X > 4) = 1 - P(X \leq 4)$  y  $P(X > 4)$ .

```
pnbinom(4,size=2,p=0.1)
```

```
[1] 0.114265
```

```
1-pnbinom(4,size=2,p=0.1)
```

```
[1] 0.885735
```

```
pnbinom(4,size=2,p=0.1,lower.tail=FALSE)
```

```
[1] 0.885735
```

## Cálculos con python

La función con python es `nbinom.pmf(k, n, p, loc)`. Hay que cargarla desde `scipy.stats`

```
from scipy.stats import nbinom
```

Recordemos que de nuevo se cumple que

```
nbinom.pmf(k, n, p, loc) = nbinom.pmf(k-loc, n, p)`
```

## Cálculos $BN(n, p)$ con python

```
nbinom.pmf(k=5,n=2,p=0.1)
```

0.0354294

```
nbinom.pmf(k=5,n=2,p=0.1,loc=0)
```

0.0354294

```
nbinom.cdf(k=4,n=2,p=0.1)
```

0.11426500000000002

```
1-nbinom.cdf(k=4,n=2,p=0.1)
```

## Cálculos $BN(n, p)$ con python

Generemos 100 observaciones aleatorias de una  $BN(n = 2, 0.1)$ . Es decir serán las veces que hemos fallado hasta abrir la puerta 100 veces.

```
nbinom.rvs(n=2, p=0.1, size=100)
```

```
array([ 4, 17, 20, 41,  4, 40, 12, 49, 25, 14,  5,  8, 14, 18, 12, 12,  6,
        9, 11, 26, 19, 36, 24,  3,  8,  1, 11, 18, 35,  6, 26,  9,  4,  6,
        7, 25,  3, 44, 36, 17, 24,  5,  9,  4,  6,  4,  1, 17,  4,  2,  9,
        7, 14, 10, 19,  9,  8,  8, 12,  4, 18, 15, 30, 17, 44, 20, 32,  6,
       41,  3, 15, 16,  3, 17, 24,  4, 20, 18,  1, 12,  3, 11, 29, 18, 46,
       36, 35, 17, 25,  4, 30, 21, 18, 11, 25, 18, 29, 56, 10, 33],
      dtype=int64)
```

## Cálculos $BN(n, p)$ con python

La **esperanza** y la **varianza** de una  $BN(n = 2, 0.1)$  valen:

```
n, p=2,0.1
params = nbinom.stats(n,p,moments='mv')
print("E(X)={m}".format(m=params[0]))
```

$E(X)=18.0$

```
print("Var(X)={v}".format(v=params[1]))
```

$Var(X)=179.99999999999997$



## Gráficas de la binomial negativa con R

El siguiente código de R dibuja las función de probabilidad y la de distribución de una  $BN(n = 2, p = 0.1)$

```
par(mfrow=c(1,2))
aux=rep(0,22)
aux[seq(2,22,2)]=dnbinom(c(0:10),size=2,prob=0.1)
plot(x=c(0:10),y=dnbinom(c(0:10),size=2,prob=0.1),
     ylim=c(0,1),xlim=c(-1,11),xlab="x",
     main="Función de probabilidad\n BN(n=2,p=0.1)")
lines(x=rep(0:10,each=2),y=aux, type = "h", lty = 2,col="blue")
curve(pnbinom(x,size=2,prob=0.1),
     xlim=c(-1,11),col="blue",
     main="Función de distribución\n BN(n=2,p=0.1)")
par(mfrow=c(1,1))
```



# Gráficas de la binomial negativa con R



# Gráficos de la binomial negativa con python

## Ejercicio

Buscad en los manuales de python cómo se dibuja la función de probabilidad y de distribución de una binomial. negativa

Necesitamos de nuevo más librerías

```
import numpy as np
from scipy.stats import nbinom
import matplotlib.pyplot as plt
```

# Gráficos de la binomial negativa con python


```

n, p = 10, 0.25
x = np.arange(0, nbinom.ppf(0.99, n, p))
fig = plt.figure(figsize=(5, 2.7))
ax = fig.add_subplot(1, 2, 1)
ax.plot(x, nbinom.pmf(x, n, p), 'bo', ms=5, label='nbinom pmf')
ax.vlines(x, 0, nbinom.pmf(x, n, p), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    tick.label.set_fontsize(5)
ax = fig.add_subplot(1, 2, 2)
ax.plot(x, nbinom.cdf(x, n, p), 'bo', ms=5, label='nbinom pmf')
ax.vlines(x, 0, nbinom.cdf(x, n, p), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():

```

# Gráficos de la binomial negativa con python

## Distribucion Binomial Negativa



## Ejercicio: Acceso aleatorio a un sistema con triple clave.

### Sistema con tres claves de acceso

Supongamos que tenemos un sistema informático que tiene un programa de seguridad que genera accesos con claves de 3 dígitos 000, 001, ... 999. En total 1000 posibilidades.

Como una clave de tres dígitos es fácil de romper proponemos considerar tres claves consecutivas de acceso al sistema, cada una de 3 dígitos.

Para acceder al sistema hay que dar las tres claves de forma consecutiva y por orden.

Es decir hasta que no averiguamos la primera clave no pasamos a la segunda clave.

Supongamos que cada vez que ponemos las dos claves olvidamos el resultado y seguimos poniendo claves al azar hasta adivinar la contraseña.

Así hasta conseguir entrar en el sistema.

Sea  $X$  la v.a que nos da el número de fallos antes de entrar en el sistema.

## Ejercicio acceso aleatorio a un sistema con triple clave.

Estamos interesados en modelar este problema. La preguntas son:

- 1 ¿Cuál es la distribución de probabilidad de  $X$ , la v.a que nos da el número de fallos antes de acceder al sistema.
- 2 ¿Cuál es la función de probabilidad y de distribución del  $X$ ?
- 3 ¿Cuál es la probabilidad de fallar 150 veces antes de acceder en el sistema?
- 4 ¿Cuál es la probabilidad de fallar más de 150 veces antes de entrar en el sistema?
- 5 ¿Cuál es el número esperado de fallos antes de acceder al sistema? ¿Y su varianza?

## Ejemplo $BN(r, p)$

**Solución 1.** ¿Cuál es la distribución de probabilidad de  $X$ , la v.a que nos da el número de fallos antes de acceder al sistema?

Bajo estas condiciones tenemos que la probabilidad de “éxito” de cada intento es  $p = \frac{1}{1000} = 0.001$ . Y como cada vez *olvidamos* en los dígitos cada intento será independiente del anterior.

Así que la variable  $X$  cuenta el número de fracasos independientes hasta conseguir 3 éxitos en un experimento  $Ber(p = 0.001)$  por lo tanto  $X$  sigue una distribución  $BN(n = 3, p = 0.001)$ .

Ejemplo  $BN(r, p)$ 

**Solución 2.** ¿Cuál es la función de probabilidad y de distribución del  $X$

En general la función de probabilidad de una  $BN(n, p)$  es

$$P_X(X = x) = P(X = x) = \begin{cases} \binom{x+n-1}{n-1} \cdot (1-p)^x \cdot p^n & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

En particular la función de probabilidad de una  $BN(n = 3, p = 0.001)$  es

$$P_X(X = x) = P(X = x) = \begin{cases} \binom{x+2}{2} \cdot 0.999^x \cdot 0.001^3 & \text{si } x = 0, 1, 2, \dots \\ 0 & \text{en otro caso.} \end{cases}$$



## Solución ejemplo $BN(n = 3, p = 0.001)$

**Solución 3.** ¿Cuál es la probabilidad de fallar 150 veces antes de acceder en el sistema?

Nos piden

$$P(X = 150) = \binom{152}{2} \cdot 0.999^{150} \cdot 0.001^3.$$

Lo calcularemos operando con R

```
choose(152,2)*0.999^150*0.001^3
```

```
[1] 9.876743e-06
```

```
dnbinom(150,size=3,p=0.001)
```

```
[1] 9.876743e-06
```

## Solución ejemplo $BN(n = 3, p = 0.001)$

**Solución 3.** ¿Cuál es la probabilidad de fallar 150 veces antes de acceder en el sistema?

Nos piden, lo resolveremos con python

$$P(X = 150) = \binom{152}{2} \cdot 0.999^{150} \cdot 0.001^3$$

```
from scipy.special import binom
binom(152,2)*0.999**150*0.001**3
```

9.876743459670526e-06

```
nbinom.pmf(150,n=3,p=0.001)
```

9.876743459670532e-06

## Solución ejemplo $BN(n, p)$

**Solución 4.** ¿Cuál es la probabilidad de fallar más de 150 veces antes de entrar en el sistema?

$$P(X > 150) = 1 - P(X \leq 150)$$

Calculemos  $P(X \leq 150)$

$$\begin{aligned} P(X \leq 150) &= P(X = 0) + P(X = 1) + P(X = 2) + \dots + P(X = 150) \\ &= \sum_{k=0}^{150} \binom{k+3-1}{3-1} \cdot (0.999)^k \cdot 0.001^3 \dots = \dots = 5.2320035 \times 10^{-4} \end{aligned}$$

## Solución ejemplo $BN(n, p)$

Con R

```
pnbinom(150,3,0.001)
```

```
[1] 0.0005232003
```

Con python

```
nbinom.cdf(150,n=3,p=0.001)
```

```
0.0005232003490824064
```

## Solución ejemplo $BN(n, p)$

El valor pedido será pues:

$$P(X > 150) = 1 - P(X \leq 150) = 1 - 5.2320035 \times 10^{-4} = 0.9994768.$$

Vemos que es muy probable que fallemos más de 150 veces antes de entrar en el sistema.

## Solución ejemplo $BN(n, p)$

**Solución 5.** ¿Cuál es el número esperado de fallos antes de acceder al sistema? ¿Y su desviación típica?

$$E(X) = n \cdot \frac{1-p}{p} = 3 \cdot \frac{1-0.001}{0.001} = 2997.$$

$$Var(X) = n \cdot \frac{1-p}{p^2} = 3 \cdot \frac{1-0.001^2}{0.001^2} = 2.997 \times 10^6.$$

Con python

```
params = nbinom.stats(n=3,p=0.001,moments='mv')
print("E(X) = {m}".format(m=params[0]))
```

E(X) = 2997.0

## ¿Tres claves de tres dígitos o una de 9 dígitos?

### Ejercicio

Supongamos que ponemos una sola clave de 9 dígitos. Estudiemos en este caso la variable aleatoria que da el número de fallos antes de entrar en el sistema y comparemos los resultados.

Si seguimos suponiendo que cada vez ponemos la contraseña al azar pero esta vez con una clave de 9 dígitos. La probabilidad de éxito será ahora  $p = \frac{1}{10^9}$ .

Si llamamos  $X_9$  a la variable aleatoria que nos da el número de fallos antes de entra en el sistema seguirá una distribución  $Ge(p = \frac{1}{10^9} = 0.000000001)$ .

## Qué da más seguridad ¿tres claves de tres dígitos o una de 9 dígitos?

Su valor esperado es

$$E(X_9) = \frac{1-p}{p} = \frac{1-0.000000001}{0.000000001} = 10 \times 10^8.$$

1000000000 son 1000 millones de fallos esperados hasta abrir la puerta.

Recordemos que con tres contraseñas de 3 dígitos el valor esperado de fallos es

$$3 \cdot \frac{1-0.001}{0.001} = 2997.$$

Por lo tanto, desde el punto de vista de la seguridad, es mejor una clave larga de 9 dígitos que tres cortas si escribimos las contraseñas al azar.



## Lección 6

### Distribución de Poisson

---

# Distribución Poisson

Diremos que una v.a. discreta  $X$  con  $X(\Omega) = \mathbf{N}$  tiene distribución de Poisson con parámetro  $\lambda > 0$ , y lo denotaremos por  $Po(\lambda)$  si su función de probabilidad es:

$$P_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso} \end{cases}.$$

# Distribución Poisson

Usando que el desarrollo en serie de Taylor de la función exponencial es

$$e^{\lambda} = \sum_{x=0}^{+\infty} \frac{\lambda^x}{x!},$$

es fácil comprobar que la suma de la función de probabilidad en todos los valores del dominio de  $X$ , o sea, los enteros positivos, vale 1.

Además recordemos que dado  $x \in \mathbb{R} - \{0\}$  se tiene que

$$\lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n = e^x.$$

# Distribución Poisson

Usando la expresión anterior para  $x = -\lambda$ , tenemos:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = \lim_{n \rightarrow \infty} \left(1 + \frac{-\lambda}{n}\right)^n = e^{-\lambda}.$$

## La distribución de Poisson como “límite” de una binomial.

La distribución de Poisson ([Siméon Denis Poisson](#)) aparece en el conteo de determinados eventos que se producen en un intervalo de tiempo o en el espacio.

Supongamos que nuestra variable de interés es  $X$ , el número de eventos en el intervalo de tiempo  $(0, t]$ , como por ejemplo el número de llamadas a un *call center* en una hora donde suponemos que se cumplen las siguientes condiciones:

# La distribución Poisson como “límite” de una binomial.

- ① El número promedio de eventos en el intervalo  $(0, t]$  es  $\lambda > 0$ .
- ② Es posible dividir el intervalo de tiempo en un gran número de subintervalos (denotemos por  $n$  al número de intervalos) de forma que:
  - La probabilidad de que se produzcan dos o más eventos en un subintervalo es despreciable.
  - El número de ocurrencias de eventos en un intervalo es independiente del número de ocurrencias en otro intervalo.
  - La probabilidad de que un evento ocurra en un subintervalo es  $p_n = \frac{\lambda}{n}$ .

## La distribución Poisson como “límite” de una binomial.

Bajo estas condiciones, podemos considerar que el número de eventos en el intervalo  $(0, t]$  será el número de “éxitos” en  $n$  repeticiones independientes de un proceso Bernoulli de parámetro  $p_n$

Entonces si  $n \rightarrow \infty$  y  $p_n \cdot n$  se mantiene igual a  $\lambda$  resulta que la función de probabilidad de  $X$  se puede escribir como

# La distribución Poisson como “límite” de una binomial.

$$\begin{aligned}P(X_n = k) &= \binom{n}{k} \cdot p_n^k \cdot (1 - p_n)^{n-k} \\&= \binom{n}{k} \cdot \left(\frac{\lambda}{n}\right)^k \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k} \\&= \frac{\lambda^k}{k!} \cdot \frac{n!}{(n-k)! \cdot n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-k}.\end{aligned}$$



# La distribución Poisson como “límite” de una binomial.

Si hacemos tender  $n$  hacia  $\infty$ , obtenemos:

$$\lim_{n \rightarrow \infty} P(X_n = k) = \lim_{n \rightarrow \infty} \frac{\lambda^k}{k!} \cdot \frac{n!}{(n-k)! \cdot n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-k}.$$

Calculemos el límite de algunos de los factores de la expresión

$$\lim_{n \rightarrow \infty} \frac{n!}{(n-k)! \cdot n^k} = \lim_{n \rightarrow \infty} \frac{n \cdot (n-1) \cdots (n-k+1)}{n^k} = \lim_{n \rightarrow \infty} \frac{n^k + \cdots}{n^k} = 1.$$

## La distribución Poisson como “límite” de una binomial.

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

Y también teniendo en cuenta que  $k$  es constante.

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-k} = \lim_{n \rightarrow \infty} 1^{-k} = \lim_{n \rightarrow \infty} 1 = 1.$$

## La distribución Poisson como “límite” de una binomial.

Para acabar

$$\lim_{n \rightarrow \infty} P(X_n = k) = \lim_{n \rightarrow \infty} \binom{n}{k} \cdot p_n^k \cdot (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k}{k!} \cdot e^{-\lambda}.$$

Lo que confirma que límite de una serie de variables  $B(n, p_n = \frac{\lambda}{n})$  sigue una ley  $Po(\lambda)$ .

## Procesos de Poisson

Lo interesante de las variables Poisson es que podemos modificar (si el modelo lo permite) el intervalo de tiempo  $(0, t]$  en el que contamos los eventos.

Claro que esto no tiene que poder ser así.

Pero en general si la variable es poisson en  $(0, t]$  también lo será en cualquier subintervalo  $(0, t']$  para todo  $t'$  tal que  $0 < t' < t$ .

Así que podremos definir una serie de variables  $X_t$  de distribución  $Po(\lambda \cdot t)$ .

# Procesos de Poisson

## Definición procesos de Poisson

Consideremos un experimento *Poisson* con  $\lambda$  igual al promedio de eventos en una unidad de tiempo (u.t.).

Si  $t$  es una cantidad de tiempo en u.t., la v.a.  $X_t$ =numero de eventos en el intervalo  $(0, t]$  es una  $Po(\lambda \cdot t)$ .

El conjunto de variables  $\{X_t\}_{t>0}$  recibe el nombre de **proceso de Poisson**.

# Resumen distribución Poisson $X \equiv Po(\lambda)$

$X$  con distribución Poisson de media o promedio  $\lambda$ ,  $Po(\lambda)$

$$D_X = \{0, 1, \dots\}$$

$$P_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k P(X=i) = \sum_{i=0}^k \frac{\lambda^i}{i!} \cdot e^{-\lambda} & \text{si } \begin{cases} k \leq x < k+1 \\ k=0, 1, 2, \dots \end{cases} \end{cases}$$

$$E(X) = \lambda; \text{Var}(X) = \lambda$$

# Resumen proceso Poisson $X_t \equiv Po(\lambda \cdot t)$

$X_t$  = número de eventos en el intervalo  $(0, t]$   $Po(\lambda \cdot t)$  donde  $\lambda$  promedio por u.t.

$$D_X = \{0, 1, \dots\}$$

$$P_X(x) = P(X = x) = \begin{cases} \frac{(\lambda \cdot t)^x}{x!} e^{-\lambda \cdot t} & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k P(X=i) = \sum_{i=0}^k \frac{(\lambda \cdot t)^i}{i!} \cdot e^{-\lambda \cdot t} & \text{si } \begin{cases} k \leq x < k+1 \\ k=0, 1, 2, \dots \end{cases} \end{cases}$$

$$E(X) = \lambda \cdot t; \text{Var}(X) = \lambda \cdot t$$

## Aproximación de la distribución binomial por la Poisson

Bajo el punto de vista anterior y si  $p$  es pequeño y  $n$  suficientemente grande la distribución  $B(n, p)$  se aproxima a una  $Po(\lambda = n \cdot p)$ .

Existen distintos criterios (ninguno perfecto) de cuando la aproximación es buena.

Por ejemplo si

$$n \geq 20 \text{ o mejor } n \geq 30, n \cdot p < 10 \text{ y } p \leq 0.05,$$

la aproximación de una  $B(n, p)$  por una  $Po(n \cdot p)$  es buena. Sobre todo para los valores cercanos a  $E(X) = \lambda$ .

Condición deseable  $n \geq 20, n \cdot p < 10, p \leq 0.05$ .



## Ejemplo $Po(\lambda)$

**Ejemplo:** Trampa insectos.

La conocida **lámpara antiinsectos o insecticida eléctrico** atrae a los insectos voladores con una luz ultravioleta y los mata por electrocución.

Consideremos la v.a.  $X$  que cuenta el número de insectos caídos en la trampa en una hora. Supongamos que el número promedio de insectos que captura la trampa en una hora es  $E(X) = 20$  y que podemos admitir que  $X$  sigue una ley de probabilidad  $Po(\lambda = 20)$ .

Nos piden

- 1 Comentar de forma breve si se cumplen intuitivamente las condiciones para tener una distribución Poisson.
- 2 Escribir de forma explícita la función de probabilidad y de distribución de  $X$ .
- 3 Calculad la probabilidad de que en una hora caigan en la trampa exactamente 21 insectos.
- 4 Calculad la probabilidad de que en una hora caigan en la trampa al menos 6 insectos.
- 5 ¿Cuál es el valor esperando, la varianza y la desviación típica de  $X$ ?

## Ejemplo $Po(\lambda)$

**Solución 1.** Comentar de forma breve si se cumplen intuitivamente las condiciones para tener una distribución Poisson.

- ① El número promedio de eventos en el intervalo  $(0, 1]$ , una hora es  $\lambda = 20 > 0$ .
- ② Es posible dividir el intervalo de tiempo de una hora en un gran número de subintervalos (denotemos por  $n$  al número de intervalos) de forma que:
  - La probabilidad de que se produzcan dos o más electrocuciones un subintervalo es despreciable. No es posible que dos mosquitos se electrocuten al mismo tiempo.
  - El número de ocurrencias, electrocuciones de insectos, en un intervalo es independiente del número de electrocuciones en otro intervalo.
  - La probabilidad de que un evento ocurra en un subintervalo es  $p_n = \frac{\lambda}{n}$ . Podemos dividir los 20 insectos promedio entre los  $n$  intervalos (trozo de hora) de forma que  $p_n = \frac{\lambda}{n}$ .
  - Por ejemplo si  $n = 60$  tenemos que  $p_n = \frac{20}{60} = \frac{1}{3}$ . La probabilidad de que en un minuto la trampa chisporrotee es  $\frac{1}{3}$ .

## Ejemplo $Po(\lambda)$

**Solución 2.** Escribid de forma explícita la función de probabilidad y de distribución de  $X$ .

La distribución de probabilidad de un  $Po(\lambda)$  es

$$P_X(x) = P(X = x) = \begin{cases} \frac{\lambda^x}{x!} e^{-\lambda} & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

En nuestro caso,  $\lambda = 20$ :

$$P_X(x) = P(X = x) = \begin{cases} \frac{20^x}{x!} e^{-20} & \text{si } x = 0, 1, \dots \\ 0 & \text{en otro caso.} \end{cases}$$

## Ejemplo $Po(\lambda)$

La función de distribución es

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k P(X = i) = \sum_{i=0}^k \frac{\lambda^i}{i!} \cdot e^{-\lambda} & \text{si } \begin{cases} k \leq x < k+1 \\ k = 0, 1, 2, \dots \end{cases} \end{cases}$$

En nuestro caso

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x < 0 \\ \sum_{i=0}^k P(X = i) = \sum_{i=0}^k \frac{20^i}{i!} \cdot e^{-20} & \text{si } \begin{cases} k \leq x < k+1 \\ k = 0, 1, 2, \dots \end{cases} \end{cases}$$

## Ejemplo $Po(\lambda)$

**Solución 3.** Calculad la probabilidad de que en una hora caigan en la trampa exactamente 21 insectos.

Nos piden la probabilidad siguiente:

$$P(X = 21) = \frac{20^{21}}{21!} e^{-20} = 0.0846051.$$

Para realizar el cálculo anterior, podemos usar R como calculadora o usar la función `dpois` que nos calcula la función de distribución de la variable de Poisson:

```
20^21/factorial(21)*exp(-20)
```

```
[1] 0.08460506
```

```
dpois(21,lambda = 20)
```

Ejemplo  $Po(\lambda)$ 

**Solución 4.** Calculad la probabilidad de que en una hora caigan en la trampa al menos 6 insectos.

Nos piden la probabilidad siguiente:

$$\begin{aligned}
 P(X \geq 6) &= 1 - P(X < 6) = 1 - P(X \leq 5) = 1 - F_X(5) = 1 - \sum_{x=0}^5 \frac{20^x}{x!} \cdot e^{-20} \\
 &= 1 - \left( \frac{20^0}{0!} \cdot e^{-20} + \frac{20^1}{1!} \cdot e^{-20} + \frac{20^2}{2!} \cdot e^{-20} + \frac{20^3}{3!} \cdot e^{-20} + \frac{20^4}{4!} \cdot e^{-20} + \frac{20^5}{5!} \cdot e^{-20} \right) \\
 &= 1 - e^{-20} \cdot \left( 1 + 20 + \frac{400}{2} + \frac{8000}{6} + \frac{160000}{24} + \frac{3200000}{120} \right) \\
 &= 1 - e^{-20} \cdot \left( \frac{1 \cdot 120 + 20 \cdot 120 + 400 \cdot 30 + 8000 \cdot 20 + 160000 \cdot 5 + 3200000 \cdot 1}{120} \right) \\
 &= 1 - e^{-20} \cdot \left( \frac{4186520}{120} \right) = 1 - 7.1908841 \times 10^{-5} = 0.9999281.
 \end{aligned}$$

## Ejemplo $Po(\lambda)$

**Solución 5.** ¿Cuál es el valor esperado, la varianza y la desviación típica de  $X$ ?

El valor esperado del número de insectos caídos en la trampa en una hora es

$$E(X) = \lambda = 20$$

Su varianza es

$$Var(X) = \lambda = 20$$

y su desviación típica vale

$$\sqrt{Var(X)} = +\sqrt{\lambda} = +\sqrt{20} = 4.47214.$$

## Cálculos con R

Consideremos por ejemplo una v.a.  $X$  con distribución  $Po(\lambda = 3)$ . Calculemos  $P_X(0) = P(X = 0)$ ,  $P_X(1) = P(X = 1)$  con R:

```
dpois(0,lambda = 3)
```

```
[1] 0.04978707
```

```
dpois(1,lambda = 3)
```

```
[1] 0.1493612
```



## Cálculos con R

Si quisiéramos hallar la función de distribución en los mismos valores anteriores,  $F_X(0) = P(X \leq 0)$ ,  $F_X(1) = P(X \leq 1)$ , haríamos lo siguiente:

```
ppois(0,lambda = 3)
```

```
[1] 0.04978707
```

```
ppois(1,lambda = 3)
```

```
[1] 0.1991483
```

```
dpois(0,lambda = 3)+dpois(1,lambda = 3) ## es igual a ppois(1,lambda=3)
```

```
[1] 0.1991483
```

## Cálculos con R

A continuación, comprobemos que  $F_X(10) = \sum_{x=0}^{10} P_X(x)$ :

```
dpois(0:10,3)
```

```
[1] 0.0497870684 0.1493612051 0.2240418077 0.2240418077 0.1680313557  
[6] 0.1008188134 0.0504094067 0.0216040315 0.0081015118 0.0027005039  
[11] 0.0008101512
```

```
sum(dpois(0:10,3))
```

```
[1] 0.9997077
```

```
ppois(10,3)
```

## Cálculos distribución Poisson con R

Si quisiéramos generar una secuencia de 100 observaciones para una distribución de Poisson de parámetro  $\lambda = 3$ ,  $Po(3)$ , tendríamos que hacer:

```
rpois(n=100, lambda = 3)
```

```
[1] 2 5 3 3 2 2 5 2 4 4 2 3 2 2 2 2 2 3 3 5 3 3 2 4 2 3 2 1 1 3 4 6 2 5 3 4
[38] 1 6 3 4 1 4 3 4 3 0 2 1 4 3 0 2 4 2 3 5 2 1 3 3 4 2 5 0 3 1 1 4 6 4 5 0
[75] 0 3 3 3 4 1 2 6 2 2 2 2 1 2 5 2 5 3 7 3 5 2 3 2 1 3
```

## Cálculos con R

### Ejercicio de la trampa para insectos (continuación)

En el ejercicio de la trampa para insectos teníamos que  $X$  es una  $Po(20)$ . Responded con R a la preguntas 3 y 4 de este ejercicio

**Pregunta 3.** Calculad la probabilidad de que en una hora caigan en la trampa exactamente 21 insectos.

Recordemos que la probabilidad pedida es  $P(X = 21)$ :

```
dpois(21,lambda=20)# P(X=21)
```

```
[1] 0.08460506
```

## Cálculos con R

**Pregunta 4.** Calculad la probabilidad de que en una hora caigan en la trampa al menos 6 insectos.

Recordemos que la probabilidad pedida es  $P(X \geq 6) = 1 - P(X < 6) = 1 - P(X \leq 5)$ :

```
ppois(5,lambda=20)
```

```
[1] 7.190884e-05
```

```
1-ppois(5,lambda=20) # es 1-P(X<=5)=P(X>=6)
```

```
[1] 0.9999281
```

```
ppois(5,lambda=20,lower.tail =FALSE ) # acumula hacia arriba
```



# Gráficos de la distribución Poisson con R

```

lambda=20; par(mfrow=c(1,2)); n=qpois(0.99,lambda=lambda)
aux=rep(0,(n+1)*2); aux[seq(2,(n+1)*2,2)]=dpois(c(0:n),lambda=lambda)
ymax=max(ppois(0:n,lambda=lambda))
plot(x=c(0:n),y=dpois(c(0:n),lambda=lambda),
      ylim=c(0,ymax),xlim=c(-1,n+1),xlab="x", ylab="Función de probabilidad",
      main=paste0(c("Función de probabilidad\n Po(lambda=",lambda,")"),
                  collapse = ""))
lines(x=rep(0:n,each=2),y=aux,pch=21, type = "h", lty = 2,col="blue")
curve(ppois(x,lambda=lambda),
      xlim=c(-1,n+1),col="blue",ylab="Función de Distribución",
      main=paste0(c("Función de distribución \n Po(lambda=",lambda,")"),
                  collapse = ""))
par(mfrow=c(1,1))

```

# Gráficos de la distribución Poisson con R



## Cálculos con python

Sea  $X$  una v.a.  $Po(\lambda = 3)$ . Entonces

$P_X(0) = P(X = 0)$ ,  $P_X(1) = P(X = 1)$  en este orden son

```
from scipy.stats import poisson  
poisson.pmf(0,mu = 3)
```

0.049787068367863944

```
poisson.pmf(1,mu = 3)
```

0.14936120510359185



## Cálculos con python

Sea  $X$  una v.a.  $Po(\lambda = 3)$ . Entonces

$F_X(0) = P(X \leq 0)$ ,  $F_X(1) = P(X \leq 1)$  en este orden son

```
poisson.cdf(0,mu = 3)
```

0.04978706836786395

```
poisson.cdf(1,mu = 3)
```

0.1991482734714558

```
poisson.pmf(0,mu = 3)+poisson.pmf(1,mu= 3)
```

0.1991482734714558

## Cálculos con python

Por ejemplo podemos comprobar que  $F_X(10) = \sum_0^{10} P_X(x)$

```
poisson.pmf(range(0,10),mu=3)
```

```
array([0.04978707, 0.14936121, 0.22404181, 0.22404181, 0.16803136,  
       0.10081881, 0.05040941, 0.02160403, 0.00810151, 0.0027005 ])
```

```
sum(poisson.pmf(range(0,10),mu=3))
```

```
0.9988975118698846
```

```
poisson.cdf(10,mu=3)
```

## Cálculos con python

En el ejercicio de la trampa para insectos teníamos que  $X$  es una  $Po(20)$ . Responded con python a la preguntas 3 y 4 de este ejercicio

**Pregunta 3.** Calculad la probabilidad de que en una hora caigan en la trampa exactamente 21 insectos.

La respuesta a la pregunta 3 es calcular  $P(X = 21)$

```
poisson.pmf(21,mu=20)
```

0.08460506418293791

```
# P(X=21)
```

## Cálculos con python

**Pregunta 4.** Calculad la probabilidad de que en una hora caigan en la trampa al menos 6 insectos.

La pregunta 4 nos pide calcular  $P(X \geq 6) = 1 - P(X \leq 5)$

```
1-poisson.cdf(5,mu=20)
```

0.9999280911594716

```
# es 1-P(X<=5)=P(X>=6)
```

## Cálculos con python

Como ya hemos visto con `scipy.stats` podemos pedir los momentos de una variable aleatoria  $Po(3)$

```
poisson.stats(mu=3, moments='mv')
```

(3.0, 3.0)

Y también generar secuencias de observaciones aleatorias de una población  $Po(3)$

```
poisson.rvs(mu=3,size=40)
```

```
array([6, 1, 2, 1, 6, 0, 6, 2, 1, 2, 1, 0, 4, 3, 2, 5, 2, 3, 2, 2, 4, 4,  
       3, 5, 4, 4, 2, 2, 3, 3, 1, 2, 4, 5, 1, 1, 2, 3, 2, 2], dtype=int64)
```

## Gráficos con python


```
from scipy.stats import poisson
mu = 10 # mu = lambda
x = np.arange(poisson.ppf(0.01, mu), poisson.ppf(0.99, mu))
fig = plt.figure(figsize=(5, 2.7))
ax = fig.add_subplot(1, 2, 1)
ax.plot(x, poisson.pmf(x, mu), 'bo', ms=5, label='poisson pmf')
ax.vlines(x, 0, poisson.pmf(x, mu), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    tick.label.set_fontsize(5)
```

## Gráficos con python

```
ax = fig.add_subplot(1,2,2)
ax.plot(x, poisson.cdf(x, mu), 'bo', ms=5, label='poisson cdf')
ax.vlines(x, 0, poisson.cdf(x, mu), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    tick.label.set_fontsize(5)
fig.suptitle('Distribucion de Poisson')
plt.show()
```

# Gráficos con python

## Distribucion de Poisson





## Ejemplo proceso Poisson

### Número de impactos de insectos en la visera de un casco

Un colega de trabajo, al que llamaremos JG, es muy aficionado a los grandes premios de velocidad tanto en coches como en motos.

Como es tan aficionado está obsesionado con muchas de las más extravagantes estadísticas de estos deportes. En particular le propusimos que estudiara el número de insectos que chocan contra la visera de un casco de un motorista GP o de un conductor de fórmula 1 .

## Ejemplo proceso Poisson

La idea es que el número de insectos está igualmente repartido por todo el circuito y de promedio impactan  $\lambda > 0$  insectos por minuto. También es razonable suponer que:

- podemos dividir la superficie de la visera en cuadrados suficientemente pequeños de forma que la probabilidad de que caigan dos insectos en la misma zona es prácticamente 0.
- la probabilidad de que un insecto impacte en un cuadrado cualquiera de la visera es independiente de cualquier otro cuadrado.
- si hemos dividido la visera en  $n$  cuadrados la probabilidad  $p_n$  de impacto de un cuadrado vale  $p_n = \frac{\lambda}{n}$ .

Bajo estas condiciones, si denotamos por  $X_t$  como el número de insectos que ha impactado en la visera en el intervalo  $(0, t]$  (en  $t$  minutos), podemos afirmar que  $X_t$  es un proceso de Poisson  $Po(\lambda \cdot t)$ .

## Ejemplo proceso Poisson

Supongamos que nos dicen que  $\lambda = 3$  insectos por minuto. Entonces el proceso de poisson  $X_t$  seguirá un ley  $Po(3 \cdot t)$ .

Ahora estamos en condiciones de preguntar al proceso de Poisson.

¿Cuál es la probabilidad de que en 10 minutos impacten más de 25 insectos?

En este caso  $t = 10$   $X_{10}$  = número de insectos que impactan en 10 minutos, el intervalo  $[0, 10)$  que sigue una  $P(3 \cdot 10 = 30)$ . Por lo tanto

$$P(X > 25) = 1 - P(X \leq 25)$$

lo resolvemos con R

```
1-ppois(25,lambda=30)
```

```
[1] 0.7916426
```

## Ejemplo proceso Poisson

Otra pregunta interesante es que tengamos que esperar más de 2 minutos para observar el primer impacto

$$P(X_2 = 0) = \frac{(3 \cdot 2)^0}{0!} \cdot e^{-3 \cdot 2} = e^{-6} = 0.002479.$$

Con R

```
6^0/factorial(0)*exp(-6)
```

```
[1] 0.002478752
```

```
ppois(0,lambda=3*2)
```

```
[1] 0.002478752
```

## Lección 7

### Distribución hipergeométrica

---

## Modelo de la distribución hipergeométrica

Supongamos que disponemos de una urna de sorteos que contiene  $m$  bolas blancas y  $n$  bolas rojas.

En total en esta urna hay  $m + n$  bolas,  $m$  blancas y  $n$  rojas. Si extraemos dos bolas de la urna lo podemos hacer de dos formas:

- Extraer una anotar su color y reponerla. Sacar otra y anotar su color. Hemos extraído la bola con reposición.
- Extraer simultáneamente dos bolas (sin reposición) y contar el número de bolas blancas.

# Modelo de la distribución hipergeométrica

Sea  $X$  es la v.a. que cuenta el número de bolas blancas extraídas.

- En el primer caso,  $X$  es una  $B(n = 2, p = \frac{m}{m+n})$  ya que consiste en repetir dos veces el mismo experimento de Bernoulli.
- En el segundo caso,  $X$  sigue una distribución hipergeométrica que estudiaremos en esta sección.

# Modelo de la distribución hipergeométrica

## Distribución hipergeométrica

Sean  $n$ ,  $m$  y  $k$  tres números enteros positivos y tales que  $k < m + n$ .

Consideremos una urna que contiene  $m + n$  bolas de las que  $m$  son blancas y las restantes  $n$  no (son no blancas).

El número total de bolas es  $m + n$ . Extraemos de forma aleatoria  $k$  bolas de la urna sin reemplazarlas.



## Modelo de la distribución hipergeométrica

Sea  $X$  la v.a. que cuenta el número de bolas blancas extraídas. Diremos que la distribución de  $X$  es hipergeométrica de parámetros  $m$ ,  $n$  y  $k$  y la denotaremos por  $H(m, n, k)$ .

Su dominio es

$$D_X = \{x \in \mathbf{N} \mid \max\{0, k - n\} \leq x \leq \min\{m, k\}\}$$

Para explicarlo, veamos varios ejemplos:

- $H(m = 5, n = 2, k = 3)$ . Tenemos  $m = 5$  bolas blancas,  $n = 2$  no blancas y sacamos  $k = 3$  bolas sin reposición.
  - En este caso el mínimo de bolas blancas extraídas es  $1 = k - n = 3 - 2$ , ya que sólo hay dos no blancas.
  - En cambio, el máximo si es  $k = 3$ , ya que tenemos bolas blancas de “sobra”.

# Modelo de la distribución hipergeométrica

$$D_X = \{x \in \mathbf{N} \mid \max\{0, k - n\} \leq x \leq \min\{m, k\}\}$$

- $H(m = 2, n = 5, k = 3)$ . Tenemos  $m = 2$  bolas blancas,  $n = 5$  no blancas y sacamos  $k = 3$  bolas sin reposición.
  - En este caso el mínimo de bolas blancas es 0 ya que puedo sacar 3 no blancas.
  - En cambio, el máximo si es  $m = 2$ , ya que aunque saquemos  $k = 3$  bolas, al llegar a 2 ya hemos extraído todas las bolas blancas de la urna.
- $H(m = 10, n = 10, k = 3)$ . Tenemos  $m = 10$  bolas blancas,  $n = 10$  no blancas y sacamos  $k = 3$  bolas sin reposición.
  - En este caso podemos obtener desde 0 blancas hasta  $k = 3$  blancas.

# Modelo de la distribución hipergeométrica

Su función de probabilidad es:

Su función de probabilidad es:

$$P_X(x) = \begin{cases} \frac{\binom{m}{x} \cdot \binom{n}{k-x}}{\binom{m+n}{k}}, & \text{si } \max\{0, k-n\} \leq x \leq \min\{m, k\}, \text{ para } x \in \mathbf{N}, \\ 0, & \text{en otro caso.} \end{cases}$$

# Distribución hipergeométrica

## Observación: otras parametrizaciones

En ocasiones se parametriza una v.a. hipergeométrica mediante  $N = m + n$ , número total de bolas,  $k$ , número de extracciones y  $p$ , probabilidad de extraer una bola blanca.

Así podemos **parametrizar alternativamente** la distribución hipergeométrica así

$$H(N, k, p) \text{ donde } p = \frac{m}{N}.$$

Resumen distribución Hipergeométrica  $H(m, n, k)$ .

$$X = \begin{cases} \text{número de bolas blancas en } k \text{ extracciones} \\ \text{sin reposición de una urna con } m \text{ bolas blancas y } n \text{ negras.} \end{cases} ; H(m, n, k)$$

$$D_X = \{x \in \mathbb{N} \mid \max\{0, k - n\} \leq x \leq \min\{m, k\}\}$$

$$P_X(x) = P(X = x) = \begin{cases} \frac{\binom{m}{x} \cdot \binom{n}{k-x}}{\binom{m+n}{k}}, & \text{si } \max\{0, k - n\} \leq x \leq \min\{m, k\}, \\ 0, & \text{en otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x).$$

$$E(X) = \frac{k \cdot m}{m+n}; \text{Var}(X) = k \cdot \frac{m}{m+n} \cdot \left(1 - \frac{m}{m+n}\right) \cdot \frac{m+n-k}{m+n-1}$$

Ejemplo clásico urna  $m = 15$  blancas,  $n = 10$  rojas y  $k = 3$  extracciones sin reposición.

### Urna con bolas blancas y rojas

Tenemos una urna con 15 bolas blancas y 10 bolas rojas. Extraemos al azar tres bolas de la urna sin reposición. Sea  $X$  el número de bolas **blancas** extraídas. Bajo esta condiciones, la v.a.  $X$  sigue una ley de distribución  $H(m = 15, n = 10, k = 3)$ .

La función de probabilidad es

$$P_X(x) = P(X = x) = \begin{cases} \frac{\binom{m}{x} \cdot \binom{n}{k-x}}{\binom{m+n}{k}} & \text{si } \max\{0, k - n\} \leq x \leq \min\{m, k\} \text{ para } x \in \mathbf{N} \\ 0 & \text{en otro caso} \end{cases},$$

$$\text{sustituyendo } P_X(x) = P(X = x) = \begin{cases} \frac{\binom{15}{x} \cdot \binom{10}{3-x}}{\binom{25}{3}} & \text{si } 0 \leq x \leq 3 \text{ para } x \in \mathbf{N} \\ 0 & \text{en otro caso} \end{cases}$$

Ejemplo clásico urna  $m = 15$  blancas,  $n = 10$  rojas y  $k = 3$  extracciones sin reposición.

La probabilidad de sacar 2 blancas será

$$P(X = 2) = \frac{\binom{15}{2} \cdot \binom{10}{3-2}}{\binom{25}{3}}$$

```
c(choose(15,2), choose(10,1), choose(25,3))
```

```
[1] 105 10 2300
```

$$P(X = 2) = \frac{105 \cdot 10}{2300} = 0.4565217.$$

Ejemplo clásico urna  $m = 15$  blancas,  $n = 10$  rojas y  $k = 3$  extracciones sin reposición.

La probabilidad de que saquemos más de 1 bola blanca es

$$\begin{aligned} P(X > 1) &= 1 - P(X \leq 1) = 1 - (P(X = 0) + P(X = 1)) \\ &= 1 - \left( \frac{\binom{15}{0} \cdot \binom{10}{3}}{\binom{25}{3}} + \frac{\binom{15}{1} \cdot \binom{10}{2}}{\binom{25}{3}} \right) \\ &= 1 - \left( \frac{1 \cdot 120}{2300} + \frac{15 \cdot 45}{2300} \right) = 1 - \frac{120 + 15 \cdot 45}{2300} = 0.6543478. \end{aligned}$$



Ejemplo clásico urna  $m = 15$  blancas,  $n = 10$  rojas y  $k = 3$  extracciones sin reposición.

El número esperado de bolas blancas extraídas para una v.a.  $X \sim H(m = 15, n = 10, k = 3)$  es

$$E(X) = \frac{k \cdot m}{m + n} = \frac{3 \cdot 15}{15 + 10} = \frac{45}{25} = 1.8.$$

La varianza vale:

$$\begin{aligned} \text{Var}(X) &= k \cdot \frac{m}{m+n} \cdot \left(1 - \frac{m}{m+n}\right) \cdot \frac{m+n-k}{m+n-1} \\ &= 3 \cdot \frac{15}{25} \cdot \left(1 - \frac{15}{25}\right) \cdot \frac{25-3}{25-1} \\ &= 3 \cdot \frac{15}{25} \cdot \left(1 - \frac{15}{25}\right) \cdot \frac{22}{24} = 3 \cdot \frac{15}{25} \cdot \frac{25-15}{25} \cdot \frac{22}{24} \\ &= 3 \cdot \frac{15}{25} \cdot \frac{10}{25} \cdot \frac{22}{24} = 0.66. \end{aligned}$$

Y por lo tanto su desviación típica es

$$+\sqrt{\text{Var}(X)} = +\sqrt{0.66} = 0.812404.$$

## Cálculos con R

Sea  $X$  una v.a.  $H(m, n, k)$ . La función de R para calcular la función de probabilidad en un valor  $x$ ,  $P(X = x)$ , es `dhyper(x,m,n,k)` y para calcular la función de distribución en un valor  $q$ ,  $P(X \leq q)$ , es `phyper(q,m,n,k)`. Para generar una muestra de valores que siga la distribución  $H(m, n, k)$ , hay que usar la función `rhyper(nn,m,n,k)` donde `nn` es el número de observaciones aleatorias deseado de la muestra.

Por ejemplo, si  $X$  es una  $H(m = 15, n = 10, k = 3)$ , los valores de  $P(X = 2)$  y que  $P(X > 1) = 1 - P(X \leq 1)$  son:

## Cálculos con R

```
dhyper(x=2,m=15,10,k=3)
```

```
[1] 0.4565217
```

```
phyper(q=1,m=15,n=10,k=3)# sí, le han puesto q ya veremos el porqué
```

```
[1] 0.3456522
```

```
1-phyper(q=1,m=15,n=10,k=3)
```

```
[1] 0.6543478
```



# Cálculos con R

Una muestra aleatoria de este experimento de tamaño 200 sería:

```
rhyper(nn=200,m=15,n=10,k=3)
```

```
[1] 2 3 1 3 1 2 2 3 2 2 1 2 1 2 2 3 3 1 1 1 1 0 2 3 2 1 3 2 2 2 2 3 2 3 3 2
[38] 1 2 1 3 2 2 3 2 3 2 2 3 2 3 1 2 2 2 2 3 2 2 1 3 2 2 3 1 2 2 2 2 2 3 0 2
[75] 3 2 2 2 1 2 2 3 1 1 1 2 2 2 2 1 1 3 2 2 3 2 2 1 1 1 3 3 2 2 2 1 3 2 2 2
[112] 1 2 3 2 2 1 2 2 2 2 2 2 3 1 2 3 3 1 1 2 2 1 1 3 2 1 1 2 2 3 1 1 1 2 1 1
[149] 1 2 2 3 3 2 3 1 2 1 2 2 2 1 2 3 1 3 3 3 2 2 1 3 3 1 1 2 2 2 2 2 3 2 1 2
[186] 1 1 1 2 1 1 2 2 2 2 3 3 1 0 2
```

# Gráficas con R



# Cálculos con python

Sea  $X$  una  $H(m, n, k)$ , las funciones de `scipy.stats` cambian los parámetros

- $M$  es el número total de bolas. Con nuestra parametrización  $M = m + n$ .
- $n$  es el número de bolas blancas. Con nuestra parametrización  $n = m$ .
- $N$  es el número de extracciones. Con nuestra parametrización  $N = k$ .

```
from scipy.stats import hypergeom
```

# Cálculos con python

```
hypergeom.pmf(1,M=15+10,n=15,N=3)
```

0.2934782608695652

```
hypergeom.cdf(1,M=15+10,n=15,N=3)
```

0.3456521739130434

```
1-hypergeom.cdf(1,M=15+10,n=15,N=3)
```

0.6543478260869566

# Cálculos con python

Una muestra aleatoria de este experimento sería...

```
hypergeom.rvs(M=15+10,n=15,N=3,size=100)
```

```
array([1, 2, 2, 0, 2, 2, 3, 1, 1, 1, 0, 1, 2, 2, 3, 0, 2, 1, 2, 2, 1, 0,
       2, 2, 2, 1, 3, 2, 3, 1, 2, 2, 2, 1, 1, 3, 2, 2, 2, 1, 2, 1, 3, 2,
       2, 3, 1, 2, 2, 2, 1, 2, 1, 2, 2, 2, 3, 1, 1, 2, 2, 2, 1, 2, 1, 3,
       2, 2, 3, 0, 2, 1, 1, 1, 2, 2, 1, 1, 3, 3, 2, 3, 3, 2, 2, 3, 2, 3,
       1, 1, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2], dtype=int64)
```



## Gráficos con python


```
from scipy.stats import hypergeom
[M, n, N] = [20, 7, 12] ##20 elementos, 7 del tipo, extraemos 12
x = np.arange(max(0, N-M+n), min(n, N))
fig = plt.figure(figsize=(5, 2.7))
= ax = fig.add_subplot(1,2,1)
= ax.plot(x, hypergeom.pmf(x, M, n, N), 'bo', ms=5, label='hypergeom pmf')
= ax.vlines(x, 0, hypergeom.pmf(x, M, n, N), colors='b', lw=2, alpha=0.5)
= ax.set_ylim([0, max(hypergeom.pmf(x, M, n, N))*1.1])
```

## Gráficos con python

```
for tick in ax.xaxis.get_major_ticks():
    =tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    =tick.label.set_fontsize(5)
ax = fig.add_subplot(1,2,2)
    =ax.plot(x, hypergeom.cdf(x, M, n, N), 'bo', ms=5, label='hypergeom cdf')
    =ax.vlines(x, 0, hypergeom.cdf(x, M, n, N), colors='b', lw=2, alpha=0.5)
for tick in ax.xaxis.get_major_ticks():
    =tick.label.set_fontsize(5)
for tick in ax.yaxis.get_major_ticks():
    =tick.label.set_fontsize(5)
=fig.suptitle('Distribucion Hipergeometrica')
=plt.show()
```

# Gráficos con python

## Distribucion Hipergeometrica



# Tema 3: Distribuciones Notables Continuas, Cuantiles

Parte 1: Probabilidad con R y python

septiembre 2023

# Lección 1

## Distribución uniforme

# Distribución uniforme

Una v.a. continua  $X$  tiene una distribución uniforme sobre el intervalo real  $(a, b)$ , con  $a < b$ , si su función de densidad es

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{si } a < x < b, \\ 0, & \text{en cualquier otro caso.} \end{cases}$$

# Distribución uniforme

## Ejercicio

Comprobar que el área comprendida entre  $f_X$  y la horizontal vale 1.

$$\int_{-\infty}^{+\infty} f_x(x) \cdot dx = \int_a^b \frac{1}{b-a} \cdot dx = \left. \frac{x}{b-a} \right]_{x=a}^{x=b} = \frac{b}{b-a} - \frac{a}{b-a} = \frac{b-a}{b-a} = 1.$$

## Función de distribución uniforme.

Su función de distribución es

$$F_X(x) = \begin{cases} 0, & \text{si } x \leq a, \\ \frac{x-a}{b-a}, & \text{si } a < x < b, \\ 1, & \text{si } b \leq x. \end{cases}$$



# Función de distribución uniforme: cálculo.

Efectivamente:

- Si  $x \leq a$ , entonces

$$F_X(x) = \int_{-\infty}^x f(t) \cdot dt = \int_{-\infty}^x 0 \cdot dt.$$

- Si  $a < x < b$  entonces ,

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f(t) \cdot dt = \int_{-\infty}^a 0 \cdot dt + \int_a^x \frac{1}{b-a} \cdot dt \\ &= 0 + \left. \frac{t}{b-a} \right]_{t=a}^{t=x} = \frac{x}{b-a} - \frac{a}{b-a} = \frac{x-a}{b-a}. \end{aligned}$$

## Función de distribución uniforme: cálculo.

- Por último si  $x \geq b$  entonces,

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f(t)dt = \int_a^b \frac{1}{b-a} dt = \left. \frac{t}{b-a} \right]_{t=a}^{t=b} \\ &= \frac{b}{b-a} - \frac{a}{b-a} = \frac{b-a}{b-a} = 1. \end{aligned}$$

Denotaremos a la v.a.  $X$  uniforme en el intervalo  $(a, b)$  por  $U(a, b)$ .

## Esperanza y varianza para una v.a. $X \sim U(a, b)$

Calculemos la esperanza de  $X$

$$\begin{aligned}
 E(X) &= \int_{-\infty}^{+\infty} x \cdot f_X(x) dx = \int_a^b x \cdot \frac{1}{b-a} dx = \left. \frac{x^2}{2 \cdot (b-a)} \right]_{x=a}^{x=b} \\
 &= \frac{b^2}{2 \cdot (b-a)} - \frac{a^2}{2 \cdot (b-a)} = \frac{b^2 - a^2}{2 \cdot (b-a)} \\
 &= \frac{(b+a) \cdot (b-a)}{2 \cdot (b-a)} = \frac{b+a}{2}.
 \end{aligned}$$

## Esperanza y varianza para una v.a. $X \sim U(a, b)$

De cara a calcular su varianza, calculemos primero la esperanza de  $X^2$ :

$$\begin{aligned} E(X^2) &= \int_{-\infty}^{+\infty} x^2 f_X(x) dx = \int_a^b x^2 \frac{1}{b-a} dx = \frac{x^3}{3 \cdot (b-a)} \Bigg|_{x=a}^{x=b} \\ &= \frac{b^3 - a^3}{3 \cdot (b-a)} = \frac{b^2 + ab + a^2}{3}. \end{aligned}$$

### Ejercicio

- Demostrad que la igualdad  $b^3 - a^3 = (b-a) \cdot (b^2 + ab + a^2)$  es cierta.
- Utilizadla para el cálculo final del valor de  $E(X^2)$ .

## Esperanza y varianza para una v.a. $X \sim U(a, b)$ .

Calculemos  $Var(X)$ .



$$\begin{aligned}
 Var(X) &= E(X^2) - (E(X))^2 = \frac{b^2 + ab + a^2}{3} - \left(\frac{b+a}{2}\right)^2 \\
 &= \frac{b^2 + ab + a^2}{3} - \frac{b^2 + 2ab + a^2}{4} \\
 &= \frac{4 \cdot (b^2 + ab + a^2) - 3 \cdot (b^2 + 2ab + a^2)}{12} \\
 &= \frac{b^2 - 2ab + a^2}{12} = \frac{(b-a)^2}{12}.
 \end{aligned}$$

## Gráficas $U(0, 1)$

El código en R para dibujar la función de densidad y la función de distribución de una distribución  $U(0, 1)$  es el siguiente:

```
par(mfrow=c(1,2))
a=0;b=1
curve(dunif(x,a,b),xlim=c(a-0.25,b+0.25),ylim=c(0,max(1/(b-a)+0.05,0.1)),
      col="blue",main=paste0("Función densidad  U(",a,",","b,")"),
      ylab=paste0("dunif(x","a,","b,")")
)
curve(punif(x,a,b),xlim=c(a-1,b+1),ylim=c(0,1.1),
      col="blue",main=paste0("Función de distribución U(",a,",","b,")"),
      ylab=paste0("punif(x","a,","b,")",cex.axis=0.8)
)
par(mfrow=c(1,1))
```

# Gráficas $U(0, 1)$

Función densidad  $U(0,1)$ Función de distribución  $U(0,1)$ 

## Transformación lineal de la v.a. uniforme

Si  $X$  sigue una distribución  $U(a, b)$  entonces  $Z = \frac{X-a}{b-a}$  sigue una distribución  $U(0, 1)$ .

### Propiedad: Transformación lineal de la v.a. uniforme

Sea  $X$  una v.a  $U(a, b)$

Si  $scale \neq 0$  y  $loc$  son dos constantes reales entonces

- si  $scale > 0$ ,  $T = scale \cdot X + loc$  sigue una ley  $U(scale \cdot a + loc, scale \cdot b + loc)$
- si  $scale < 0$ ,  $T = scale \cdot X + loc$  sigue una ley  $U(scale \cdot b + loc, scale \cdot a + loc)$



## Cambio lineal v.a. uniforme.

### Demostración

Supongamos que  $X$  sigue una ley  $U(a, b)$ , que  $scale > 0$  y que  $T = scale \cdot X + loc$ . Dejamos el caso  $scale < 0$  como ejercicio.

La función de distribución de  $X$  es:

$$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq a \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } b \leq x \end{cases}$$

## Cambio lineal v.a. uniforme.

Si  $T$  vale  $T = scale \cdot X + loc$ , su función de distribución será:

$$\begin{aligned}
 F_T(t) &= P(T \leq t) = P(scale \cdot X + loc \leq t) = P\left(X \leq \frac{t-loc}{scale}\right) = F_X\left(\frac{t-loc}{scale}\right) \\
 &= \begin{cases} 0, & \text{si } \frac{t-loc}{scale} \leq a \\ \frac{\frac{t-loc}{scale} - a}{b-a}, & \text{si } a \leq \frac{t-loc}{scale} \leq b, \\ 1, & \text{si } b \leq \frac{t-loc}{scale}, \end{cases} = \begin{cases} 0, & \text{si } t \leq scale \cdot a + loc, \\ \frac{t - (scale \cdot a + loc)}{scale \cdot (b-a)}, & \text{si } scale \cdot a + loc \leq t \leq scale \cdot b + loc, \\ 1, & \text{si } scale \cdot b + loc \leq t, \end{cases} \\
 &= \begin{cases} 0, & \text{si } t \leq scale \cdot a + loc, \\ \frac{t - (scale \cdot a + loc)}{scale \cdot b + loc - (scale \cdot a + loc)}, & \text{si } scale \cdot a + loc \leq t \leq scale \cdot b + loc, \\ 1, & \text{si } scale \cdot b + loc \leq t, \end{cases}
 \end{aligned}$$

función que corresponde a la función de distribución de una v.a.  $U(scale \cdot a + loc, scale \cdot b + loc)$ , como queríamos demostrar.

## Cambio lineal v.a. uniforme.

### Ejercicio

Sea  $X$  una variable  $U(0, 1)$  y sea  $T = scale \cdot X + loc$ :

- Si  $T$  es  $U(-5, 5)$  ¿qué valores toman  $scale$  y  $loc$ ?
- Si  $loc = -10$  y  $scale = 10$  ¿qué distribución de probabilidad sigue  $T$ ?
- Si  $loc = 0$  y  $scale = -1$  ¿qué distribución probabilidad sigue  $T$ ?

Resumen v.a con distribución uniforme,  $U(a, b)$ Distribución uniforme  $U(a, b)$ Dominio  $D_X = (a, b)$ 

$$f_X(x) \begin{cases} \frac{1}{b-a}, & \text{si } a < x < b, \\ 0, & \text{en cualquier otro caso.} \end{cases}$$

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x \leq a \\ \frac{x-a}{b-a}, & \text{si } a \leq x \leq b, \\ 1, & \text{si } b \leq x. \end{cases}$$

$$E(X) = \frac{a+b}{2}; \text{Var}(X) = \frac{(b-a)^2}{12}$$

## Cálculos con R

Sea  $X$  una *v.a.*  $U(a, b)$ . Las funciones `dunif(x,a,b)` y `punif(x,a,b)` calculan la función de densidad y de distribución de  $X$  en el valor  $X$ . Por ejemplo, para  $a = -1$ ,  $b = 1$  y  $x = 0.5$ , los valores  $f_X(x)$  y  $F_X(x)$  valen:

```
dunif(x=0.5, min=-1,max=1)
```

```
[1] 0.5
```

```
punif(q=0.5,min=-1,max=1)
```

```
[1] 0.75
```

## Cálculos con R

La función `runif(n,a,b)` calcula un muestra de observaciones de tamaño  $n$  que sigan la distribución  $U(a,b)$ :

```
runif(n=5,min=-1,max=1)
```

```
[1] -0.4958983  0.4456505  0.2689126  0.7824123 -0.6942988
```

## Cálculos con R

Por defecto, el valor de los parámetros  $a$  y  $b$  son 0 y 1, respectivamente:

```
dunif(x=0.5)
```

```
[1] 1
```

```
punif(q=0.5)
```

```
[1] 0.5
```

```
runif(n=5)
```

```
[1] 0.06143565 0.61640005 0.04626174 0.60812813 0.74004997
```

## Cálculos con python

Sea  $X$  una v.a.  $U(-1, 1)$ . Tomando como “base” la v.a.  $U(0, 1)$ , los parámetros *loc* y *scale* valen:  $loc = -1$  y  $scale = 2$ , ya que como hemos visto  $X = 2 * U(0, 1) - 1 = U(-1, 1)$ .

En python, hay que usar dichos parámetros para calcular la función de densidad y de distribución:

```
from scipy.stats import uniform  
uniform.pdf(0.5, loc=-1, scale=2)
```

0.5

```
uniform.ppf(0.5, loc=-1, scale=2)
```

0.0



# Cálculos con python

Para generar una muestra de valores aleatorios, hay que usar la función `uniform.rvs`:

```
uniform.rvs(size=30,loc=-1,scale=2)
```

```
array([-0.01383861, -0.61091586,  0.14038545,  0.12019527, -0.15229503,  
       -0.41600228, -0.08753864, -0.53873757,  0.1038596 , -0.77763352,  
        0.03853392,  0.21356813,  0.70737469, -0.63003556, -0.63651971,  
       -0.47075844,  0.08263636, -0.87974899, -0.01933118,  0.13257765,  
       -0.8911663 ,  0.70320879, -0.93461405,  0.9471647 ,  0.30422265,  
        0.25580688,  0.11806499,  0.8911389 ,  0.80244457, -0.46070991])
```

## Cálculos con python

Los valores de los parámetros por defecto son `loc=0`, `scale=1`:

```
uniform.pdf(0.5)
```

1.0

```
uniform.ppf(0.5)
```

0.5

```
uniform.rvs(size=5)
```

```
array([0.69830532, 0.245794 , 0.0268237 , 0.32153811, 0.53619263])
```

## Lección 2

### Cuantiles de variables aleatorias

# Cuantiles

## Cuantiles

Si  $X$  es una v.a. con dominio  $D_X$  y  $0 < p < 1$  llamaremos cuantil de orden  $p$  al menor valor perteneciente al dominio  $x_p \in D_X$  tal que

$$P(X \leq x_p) \geq p.$$

En R, cada distribución  $X$  tiene la función  $qX(p, \dots)$  que devuelve precisamente el cuantil  $x_p$  tal que  $P(X \leq x_p) \geq p$ .

# Cuantiles

Consideremos una v.a.  $X$  de distribución  $B(5, 0.5)$ .

Los cuantiles  $x_{0.3}$ ,  $x_{0.6}$  y  $x_{0.8}$  son los siguientes:

```
qbinom(c(0.3,0.6,0.8),5,0.5)
```

```
[1] 2 3 3
```

# Cuantiles

Calculemos a mano, el valor  $x_{0.3}$  y verifiquemos que da el mismo resultado que nos ha dado R.

La función de distribución de  $X$  es:

$$F_x(x) = P(X \leq x) = \begin{cases} 0, & x < 0, \\ 0.03125, & \text{si } 0 \leq x < 1, \\ 0.18750, & \text{si } 1 \leq x < 2, \\ 0.50000, & \text{si } 2 \leq x < 3, \\ 0.81250, & \text{si } 3 \leq x < 4, \\ 0.96875, & \text{si } 4 \leq x < 5, \\ 1.00000, & \text{si } 5 \leq x. \end{cases}$$

# Cuantiles

El cuantil  $p = 0.3$  es el primer valor  $x \in D_X$  tal que  $F_X(x) = P(X \leq x_{0.3}) \geq 0.3$ . Mirando la expresión anterior, comprobamos que  $x_{0.3} = 2$  ya que  $F_X(2) = P(X \leq 2) = 0.5 \geq 0.3$ .

## Ejercicio

Calcular los cuantiles de 0.6 y 0.8 de una  $B(5, 0.5)$ .

# Cuantiles

Dada una variable aleatoria  $X$ , si existe la inversa de la función de distribución de  $X$ ,  $F_X^{-1}$ , el cuantil de orden  $p$  sería el valor que tiene la función  $F_X^{-1}$  en  $p$ :  $x_p = F_X^{-1}(p)$ .

En caso de no existir la inversa, dado  $p$ , definimos el conjunto  $A_p$  como:

$$A_p = \{x \in \mathbb{R}, \mid F_X(x) \geq p\}.$$

Entonces el cuantil  $p$  es el mínimo del conjunto  $A_p$  considerando sólo valores del dominio de la variable:  $x_p = \min_{x \in D_X} (A_p)$ . Este mínimo siempre existirá y nos da una fórmula explícita para calcular los cuantiles de cualquier variable aleatoria.



# Cuantiles

## Ejemplo: variable aleatoria que nos da el resultado del lanzamiento de un dado

Sea  $X$  la variable aleatoria uniforme discreta que nos da el número de puntos obtenidos en el lanzamiento de un dado (seis caras numeradas del 1 al 6).

Su dominio es  $D_X = \{1, 2, 3, 4, 5, 6\}$  y su función de probabilidad es

$$P_X(x) = P(X = x) = \begin{cases} \frac{1}{6}, & \text{si } x = 1, 2, 3, 4, 5, 6, \\ 0, & \text{en otro caso.} \end{cases}$$

Su función de distribución es:

$$F_X(x) = P(X \leq x) = \begin{cases} 0, & \text{si } x < 1, \\ \frac{k}{6} & \text{si } k \leq x < k + 1 \text{ para } x = 1, 2, 3, 4, 5, \\ 1, & \text{si } x \geq 6. \end{cases}$$

# Cuantiles

La función siguiente llamada `ddado` nos define la función de probabilidad de  $X$  para un dado de  $n$  caras:

```
ddado=function(x,n=6) {  
  sapply(x,FUN=function(x) {  
    if( x %in% c(1:n)){return(1/n)} else {return(0)}})  
}
```

# Cuantiles

Por ejemplo, el valor de  $P_X(0.5)$  sería:

```
ddado(1.5,n=6)
```

```
[1] 0
```

y los valores de  $P_X(i)$  para  $i = 1, \dots, 10$  sería:

```
ddado(1:10,n=6)
```

```
[1] 0.1666667 0.1666667 0.1666667 0.1666667 0.1666667 0.1666667 0.0000000  
[8] 0.0000000 0.0000000 0.0000000
```

# Cuantiles

La función `pdado` nos da la función de distribución de  $X$ :

```
pdado=function(x,n=6)
{
  sapply(x,FUN=function(y){ if (y<1){ return(0)}else{if(y>=n){return(1)} el
  {return(sum(ddado(c(1:(floor(y))),n=n))))}}})
}
```

Los valores de  $F_X(i)$  para  $i = 0, \dots, 11$  serían:

```
pdado(0:11,6)
```

```
[1] 0.0000000 0.1666667 0.3333333 0.5000000 0.6666667 0.8333333 1.0000000
[8] 1.0000000 1.0000000 1.0000000 1.0000000 1.0000000
```

# Cuantiles

A continuación, construimos la función `q dado` que nos calcula el cuantil  $p$ , para  $0 \leq p \leq 1$ , de la variable  $X$  como el mínimo de la antiimagen de  $p$  mediante la función de distribución  $F_X^{-1}(p)$

```
q dado=function(p,n=6){
  sapply(p,FUN=function(pp=p,nn=n)
    {
      if(pp<0 | pp>1) {return(NA)}
      else {
        aux=pp>=pdado(1:n,nn)
        aux
        ifelse(all(!aux),return(1),return(max(which(pp>=pdado(1:n,nn))))))}
    }
  )
}
```

# Cuantiles

Efectivamente los cuantiles del dado  $X$  son

```
qddado(1.5)
```

```
[1] NA
```

```
qddado(-1)
```

```
[1] NA
```

```
qddado(c(0.1,0.5,0.6,1,1.01,2))
```

```
[1] 1 3 3 6 NA NA
```

# Cuantiles

Por ejemplo si  $X$  es una  $B(n = 10, p = 0.3)$

```
set.seed(2222)
(q=runif(10,0,1))
```

```
[1] 0.36765818 0.18187591 0.82617679 0.58497444 0.95886983 0.10179894
[7] 0.75688767 0.24369144 0.67806543 0.06275295
```

```
qbinom(q,10,0.3)
```

```
[1] 2 2 4 3 6 1 4 2 4 1
```

```
set.seed(2222)
rbinom(10,10,0.3)
```

# Cuantiles

Por ejemplo si  $X$  es una  $BN(n = 3, p = 0.1)$

```
set.seed(2222)
(q=runif(10,0,1))
```

```
[1] 0.36765818 0.18187591 0.82617679 0.58497444 0.95886983 0.10179894
[7] 0.75688767 0.24369144 0.67806543 0.06275295
```

```
qnbinom(q,3,0.1)
```

```
[1] 19 12 41 27 61  9 36 15 32  7
```

```
set.seed(2222)
rnbinom(10,3,0.1)
```



## Lección 3

### Distribución exponencial

---

## Distribución del tiempo entre dos eventos Poisson

Supongamos que tenemos un proceso Poisson con parámetro  $\lambda$  en una unidad de tiempo.

Dado un tiempo  $t$ , definimos  $N_t$  como el número de eventos en el intervalo de tiempo  $(0, t]$ . La distribución de  $N_t$  es una  $Po(\lambda \cdot t)$ . Consideremos la v.a.  $T$  como el tiempo transcurrido entre dos eventos Poisson consecutivos.

Sea  $t > 0$ , entonces

$$\begin{aligned} P(T > t) &= P(\text{Cero eventos en el intervalo}(0, t]) \\ &= P(N_t = 0) = \frac{(\lambda t)^0}{0!} e^{-\lambda t} = e^{-\lambda t}. \end{aligned}$$

## Distribución del tiempo entre dos eventos Poisson

Tomando complementarios, la función de distribución de  $T$  será:

$$F_T(t) = P(T \leq t) = 1 - P(T > t) = \begin{cases} 0, & \text{si } t \leq 0, \\ 1 - e^{-\lambda t}, & \text{si } t > 0, \end{cases}$$

Para hallar la función de densidad de  $T$ , basta derivar la expresión anterior:

$$f_T(t) = \begin{cases} \lambda \cdot e^{-\lambda t}, & \text{si } t > 0, \\ 0, & \text{si } t \leq 0. \end{cases}$$

Llamaremos a la variable  $T$  exponencial de parámetro  $\lambda$  y la denotaremos por  $Exp(\lambda)$ .

## Propiedad de la falta de memoria

Sea  $X$  una v.a.  $Exp(\lambda)$  entonces

$$P(X > s + t | X > s) = P(X > t) \text{ para todo } s, t \in \mathbb{R}$$

### Demostración

Si  $X$  es una v.a.  $Exp(\lambda)$  tenemos que

$$P(X > x) = 1 - P(X \leq x) = 1 - (1 - e^{-\lambda \cdot x}) = e^{-\lambda \cdot x} \text{ para todo } x > 0$$

Por tanto,

$$\begin{aligned} P(X > s + t | X > s) &= \frac{P(\{X > s+t\} \cap \{X > s\})}{P(X > s)} = \frac{P(X > s+t)}{P(X > s)} = \frac{e^{-\lambda \cdot (s+t)}}{e^{-\lambda \cdot s}} = \frac{e^{-\lambda \cdot s} \cdot e^{-\lambda \cdot t}}{e^{-\lambda \cdot s}} \\ &= e^{-\lambda \cdot t} = P(X > t). \end{aligned}$$

## Ejemplo distribución exponencial

### El clásico problema del peluquero.

Una pequeña peluquería es regentada por un único peluquero. El peluquero está esperando al próximo cliente mientras lee el periódico.

Supongamos que  $N_T$  = número de clientes que llegan en el intervalo  $[0, t)$  es una  $Po(\lambda \cdot t)$  entonces la variable  $T$  = tiempo entre dos clientes consecutivos sigue una ley  $Exp(\lambda)$ .

Supongamos que  $t$  se mide en horas y que  $\lambda = 4$  es el promedio de clientes por hora.

En este ejemplo la propiedad de la pérdida de memoria significa que si el peluquero lleva ya esperando más de  $s > 0.25$  un cuarto de hora la probabilidad de que espere  $t = 1/6$  de hora más (10 minutos) no cambia sigue siendo  $P(T > 0.25 + 1/6 | T > 0.25) = P(T > 1/6)$ .

## Ejemplo distribución exponencial

El tiempo esperado (en horas) hasta el siguiente cliente es

$$E(X) = \frac{1}{\lambda} = \frac{1}{4} = 0.25.$$

y la varianza es

$$Var(X) = \frac{1}{\lambda^2} = \frac{1}{4^2} = 0.0625.$$

Por último ¿Cuál es la probabilidad de que nuestro peluquero esté sin clientes (leyendo el periódico) más de 30 minutos (0.5 horas)?

$$P(X > 0.5) = 1 - P(X \leq 0.5) = 1 - (1 - e^{-4 \cdot 0.5}) = e^{-2} = 0.1353353.$$

## Ejemplo distribución exponencial

Si queremos hacer los cálculos con R,

```
pexp(0.5,rate=3)
```

```
[1] 0.7768698
```

```
1-pexp(0.5,rate=3)
```

```
[1] 0.2231302
```

```
pexp(0.5,rate=3,lower.tail = FALSE)
```

```
[1] 0.2231302
```

## Cálculos con R

La función de densidad, de distribución y la generación aleatoria de valores de una exponencial, se pueden obtener en R con:

```
dexp(0.001,rate=3)# no es una probabilidad es una densidad y puede ser >1
```

```
[1] 2.991013
```

```
pexp(0.5,rate=3) #  $P(X < 0.5)$ 
```

```
[1] 0.7768698
```

```
rexp(8,3)# ocho tiempos de una exponencial
```

```
[1] 0.5069426 0.4497573 0.2876943 0.5514840 1.0552252 0.3168070 0.2488148
```

```
[8] 0.2377065
```



# Cálculos con python

Y en python con:

```
from scipy.stats import expon  
expon.pdf(0.0001,scale= 1./3)
```

2.9991001349865014

```
expon.cdf(0.5,scale= 1./3)
```

0.7768698398515702

```
expon.rvs(scale=1./3,size=10)
```

```
array([0.8408124 , 0.30060921, 0.41673604, 0.55732782, 0.72758815,  
       0.04027662, 0.0500577 , 0.11608099, 0.2047343 , 0.26394764])
```



Resumen v.a con distribución exponencial,  $Exp(\lambda)$ 

$X$ sigue una distribución $Exp(\lambda)$
$D_X = (0, +\infty)$
$f_X(x) = \begin{cases} \lambda \cdot e^{-\lambda x} & \text{si } x > 0 \\ 0 & \text{si } x \leq 0 \end{cases}$
$F_X(x) = P(X \leq x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\lambda x} & \text{si } x > 0 \end{cases}$
$E(X) = \frac{1}{\lambda}; Var(X) = \frac{1}{\lambda^2}$

## Gráficas densidad y distribución $Exp(\lambda = 10)$

```
lambda=10
par(mfrow=c(1,2))
curve(dexp(x,rate=lambda)
      xlim=c(-0.05,round(qexp(0.99,rate=lambda,2),2)+0.25),
      ylim=c(0,dexp(0,lambda)+0.1),col="blue",
      main=paste0("Función densidad Exp(",lambda,")"),
      ylab=paste0("dexp(x,rate=",lambda,")"))
curve(pexp(x,rate=lambda),xlim=c(-0.05,qexp(0.999,10)),
      ylim=c(0,1.1),col="blue",
      main=paste0("Función de distribución Exp(",lambda,")"),
      ylab=paste0("pexp(x,rate=",lambda,")"))
par(mfrow=c(1,1))
```

# Gráficas densidad y distribución $Exp(\lambda = 10)$



# Gráficas densidad y distribución $Exp(\lambda = 10)$

## Ejercicio

Consultad en el manual de python [scipy.stats](#).

Dibujad la función de densidad y de distribución de una  $Exp(10)$ .

## Ejercicio: las bombillas que no envejecen.

### Ejercicio

Supongamos que compramos una bombilla led que promete un **valor esperado** de duración de 10000 (1.14 años) horas de funcionamiento continuo. Además, nos aseguran que la distribución de  $X$ , el número de horas de funcionamiento continuo de una bombilla led, sigue una ley exponencial.

- Si  $X$  es  $Exp(\lambda)$  ¿cuál es el valor del parámetro  $\lambda$ ?
- ¿Cuál es la probabilidad de que una bombilla led ilumine más de 2 años?
- Supongamos que ya tengo una bombilla led funcionando 1 año ¿Cuál es la probabilidad de que dure dos años más?
- ¿Cuál es la varianza de la duración en horas de este tipo de bombillas?

## Lección 4

# Distribución normal o Gaussiana

# Distribución normal o Gaussiana

Una de las variables aleatorias continua más populares es la llamada distribución normal o **Gaussiana**.

Distribución normal o de Gauss Diremos que una v.a.  $X$  sigue una ley normal de parámetros  $\mu$  y  $\sigma$  y la denotaremos por  $N(\mu, \sigma)$  si tiene por función de densidad:

$$f_X(x) = \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} e^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2},$$

para todo  $x \in \mathbb{R}$ .



# Distribución normal o Gaussiana


La gráfica de esta función de densidad es conocida como **campana de Gauss**.

La v.a. normal con  $\mu = 0$  y  $\sigma = 1$  recibe el nombre de normal estándar y se suele denotar por la letra  $Z$  normal  $N(0, 1)$ . El siguiente código la dibuja.

```
curve(dnorm(x),  
      main="Función de densidad de una normal estándar",  
      xlim=c(-3.9,3.9))
```

# Distribución normal o Gaussiana

Función de densidad de una normal estándar



# Propiedades de la función de densidad de la distribución normal

## Propiedades de la función de densidad de la distribución normal

Sea  $X$  una v.a.  $N(\mu, \sigma)$  y sea  $f_X$  su función de densidad. Entonces:

- La función  $f_X$  verifica todas las propiedades de las funciones de densidad:  $f_X(x) > 0$ , para todo  $x \in \mathbb{R}$  y  $\int_{-\infty}^{\infty} f_X(x) dx = 1$ .
- La función  $f_X(x)$  es simétrica respecto de la recta  $x = \mu$ :  $f_X(\mu - x) = f_X(\mu + x)$ , para todo  $x \in \mathbb{R}$ .
- $f_X$  tiene un único máximo absoluto en  $x = \mu$  que vale  $f_X(\mu) = \frac{1}{\sqrt{2\pi\sigma^2}}$ .

# Propiedades de la función de densidad de la distribución normal

- Si  $F_X$  es la función de distribución de  $X$ , entonces  $F_X(\mu + x) = 1 - F_X(\mu - x)$ , para todo  $x \in \mathbb{R}$ .
- En particular si  $Z$  es una  $N(0, 1)$  entonces  $F_Z(-x) = 1 - F_Z(x)$ , para todo  $x \in \mathbb{R}$ .
- $Z = \frac{X - \mu}{\sigma}$  es una v.a.  $N(0, 1)$  y  $X = \sigma \cdot Z + \mu$  es una  $N(\mu, \sigma)$  donde  $Z$  es la normal estándar.

## Función de distribución $N(0,1)$

Su función de distribución es, como sabemos :

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} e^{-\frac{1}{2} \left( \frac{t-\mu}{\sigma} \right)^2} dt.$$

La función  $F(x)$  no tiene ninguna expresión algebraica “decente”. Es por esta razón, y por comodidad, que esta función está tabulada o hay que calcularla usando un software estadístico.

Resumen v.a con distribución normal,  $N(\mu, \sigma)$ 

$X$  sigue una distribución  $N(\mu, \sigma)$

$$D_X = \mathbb{R} = (-\infty, +\infty)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi \cdot \sigma^2}} \cdot e^{\frac{-(x-\mu)^2}{2 \cdot \sigma^2}} \text{ para todo } x \in \mathbb{R}.$$

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dt.$$

$$E(X) = \mu; \text{ Var}(X) = \sigma^2.$$

## Cálculos con R

Las funciones que calculan la función de densidad y de distribución de una variable  $N(\mu, \sigma)$  en un valor  $x$  son `dnorm(x, mean=mu, sd=sigma)` y `pnorm(x, mean=mu, sd=sigma)`, respectivamente. Por ejemplo, para una variable  $X \sim N(\mu = 1, \sigma = 2)$  la función de densidad  $f_X(2)$  se puede calcular de la forma siguiente:

```
dnorm(2, mean=1, sd=2)
```

```
[1] 0.1760327
```

y la función de distribución  $F_X(2) = P(X \leq 2)$  de la forma siguiente:

```
pnorm(2, mean=1, sd=2)
```

```
[1] 0.6914625
```

## Cálculos con R

El cuantil  $x_{0.95}$  es el valor que cumple  $P(X \leq x_{0.95}) = 0.95$  como

```
qnorm(0.95,mean=1,sd=2)
```

```
[1] 4.289707
```

Y la generación aleatoria de valores según  $X$  como

```
rnorm(n=5,mean=1,sd=2)
```

```
[1] 0.9806747 5.5415845 2.8174087 -2.4085639 0.8920435
```



## Cálculos con python

De forma la forma habitual importaremos `norm` de `scipy.stats` los parámetros son `loc` y `scale` la media  $\mu$  y la desviación estándar  $\sigma$ .

```
from scipy.stats import norm
```

Por ejemplo para una  $X \sim N(\mu = 1, \sigma = 2)$ , la función de densidad  $f_X(2)$ :

```
norm.pdf(2, loc=1, scale=2)
```

0.17603266338214976

y la función de distribución  $F_X(2) = P(X \leq 2)$ :

```
norm.cdf(2, loc=1, scale=2)
```

## Cálculos con python

El cuantil  $x_{0.95}$  es el valor que cumple  $P(X \leq x_{0.95}) = 0.95$  como

```
norm.ppf(0.95,loc=1,scale=2)
```

4.289707253902945

Y la generación aleatoria de valores según  $X$  como

```
norm.rvs(loc=1,scale=2,size=5)
```

```
array([ 3.87994542, -0.46483669,  1.4015392 ,  3.44997153,  2.25066713])
```

Consultad [SciPy.org](https://docs.scipy.org/doc/scipy/) para dibujar las funciones de densidad y de distribución con python.


# Propiedades de la distribución normal.

## Propiedades

La función de densidad de la distribución normal tiene las siguientes **propiedades**:

- La función  $f_X$  es continua.
- $\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} \cdot e^{-\frac{1}{2} \cdot \left(\frac{x-\mu}{\sigma}\right)^2} dx = 1$ . (propiedad de todas las densidades).
- $f(\mu + x) = f(\mu - x)$ .
- $F(\mu - x) = 1 - F(\mu + x)$ .



# Propiedades de la distribución normal.



# Propiedades de la distribución normal

- $\lim_{x \rightarrow +\infty} f(x) = \lim_{x \rightarrow -\infty} f(x) = 0$  es decir tiene asíntota horizontal a derecha e izquierda.
- $f$  es estrictamente creciente si  $x < \mu$  y decreciente si  $x > \mu$ .
- Alcanza el máximo en  $x = \mu$  y en este punto vale  $f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$
- Tiene dos puntos de inflexión en  $x = \mu + \sigma$  y en  $x = \mu - \sigma$ .

# Propiedades de la distribución normal.



# Transformaciones lineales de variables aleatorias normales

Propiedad: transformación lineal la distribución normal

Sea  $X$  una variable  $N(\mu, \sigma)$  entonces la variable  $Y = aX + b$  con  $a \neq 0, b \in \mathbb{R}$  tiene distribución  $N(a\mu + b, |a|\sigma)$

En particular si  $X$  sigue una  $N(\mu, \sigma)$ , tomando  $a = \frac{1}{\sigma}$  y  $b = \frac{-\mu}{\sigma}$  obtenemos la tipificación o estandarización de la v.a.

$$Z = \frac{X - \mu}{\sigma}$$

se distribuye  $N(0, 1)$ , es decir  $E(X) = 0$  y  $Var(X) = 1$ .

# Transformaciones lineales de variables aleatorias normales

Esta propiedad es muy útil, ya que utilizándola sólo necesitaremos tabular la  $N(0, 1)$ .

Si  $Z$  sigue una distribución  $N(0, 1)$  diremos que  $Z$  sigue una distribución normal estándar.

Por lo tanto podemos calcular cualquier distribución normal desde la distribución normal estándar:

$$F_X(x) = F_Z\left(\frac{x - \mu}{\sigma}\right).$$



# Propiedades de la distribución normal estándar

Sea  $Z$  una  $N(0, 1)$ .

En este caso,  $\mu = 0$  y  $\sigma = 1$ . Podemos escribir algunas de las propiedades vistas para una distribución normal cualquiera de la forma siguiente:

- La propiedad  $f_X(\mu - x) = f_X(\mu + x)$  se traduce a  $f_Z(-x) = f_Z(x)$
- La propiedad  $F_X(\mu - x) = 1 - F_X(\mu + x)$  se traduce a  $F_Z(-x) = 1 - F_Z(x)$ .
- Dado  $\delta > 0$ ,

$$P(-\delta \leq Z \leq \delta) = F_Z(\delta) - F_Z(-\delta) = F_Z(\delta) - (1 - F_Z(\delta)) = 2 \cdot F_Z(\delta) - 1.$$

# Cálculos con la distribución normal

## Ejercicio Cálculos con la distribución normal estándar

Sea  $Z$  una distribución  $N(0, 1)$ , calcular las siguientes probabilidades en función de  $F_Z$ .

- $P(-4 \leq Z \leq 4)$ .
- $P(-2 \leq Z \leq 2)$ .
- $P(Z \leq -2)$ .
- $P(Z \leq 2)$ .
- $P(Z \geq 2)$ .
- $P(Z > 2)$ .
- $P(Z = 2)$ .
- $P(Z \geq -2)$ .

# Cálculos con la distribución normal

Resolución:

- $P(-4 \leq Z \leq 4) = F_Z(4) - F_Z(-4) = 2 \cdot F_Z(4) - 1.$
- $P(-2 \leq Z \leq 2) = F_Z(2) - F_Z(-2) = 2 \cdot F_Z(2) - 1.$
- $P(Z \leq -2) = F_Z(-2) = 1 - F_Z(2).$
- $P(Z \leq 2) = F_Z(2).$
- $P(Z \geq 2) = 1 - P(Z < 2) = 1 - F_Z(2).$
- $P(Z > 2) = 1 - P(Z \leq 2) = 1 - F_Z(2).$
- $P(Z = 2) = 0$  ya que es una distribución continua.
- $P(Z \geq -2) = 1 - P(Z < -2) = 1 - F_Z(-2) = 1 - (1 - F_Z(2)) = F_Z(2).$

## Relación entre una distribución normal y la normal estándar.

Para hallar la probabilidad de que  $X$  esté en un intervalo  $(a, b)$  cualquiera, podemos usar la función de distribución de  $Z$  de la siguiente manera:

$$\begin{aligned} P(a < X < b) &= P\left(\frac{a-\mu}{\sigma} < \frac{X-\mu}{\sigma} < \frac{b-\mu}{\sigma}\right) = \\ &= P\left(\frac{a-\mu}{\sigma} < Z < \frac{b-\mu}{\sigma}\right) = F_Z\left(\frac{b-\mu}{\sigma}\right) - F_Z\left(\frac{a-\mu}{\sigma}\right). \end{aligned}$$

Para el caso particular en que el intervalo esté centrado en la media  $\mu$ , o sea existe un valor  $\delta > 0$  tal que  $(a, b) = (\mu - \delta, \mu + \delta)$ , obtenemos:

$$P(\mu - \delta \leq X \leq \mu + \delta) = 2 \cdot F_Z\left(\frac{\delta}{\sigma}\right) - 1.$$

# Ejemplo cálculo probabilidades normal

## Ejercicio

Sea  $X$  una normal con media 2 y varianza 4. Calcular

- $P(1 < X < 2)$ .
- $P(X > 3)$ .

## Ejemplo cálculo probabilidades normal

### Solución

La primera probabilidad se calcula de la forma siguiente:

$$\begin{aligned} P(1 < X < 2) &= P\left(\frac{1-2}{2} < \frac{X-2}{2} < \frac{2-2}{2}\right) = P\left(\frac{-1}{2} < Z < 0\right) \\ &= F_Z(0) - F_Z(-0.5) = \frac{1}{2} - 1 + F_Z(0.5) = -\frac{1}{2} + F_Z(0.5). \end{aligned}$$

La segunda probabilidad se calcular de la forma siguiente:

$$P(X > 3) = P\left(\frac{X-2}{2} > \frac{3-2}{2}\right) = P(Z > 0.5) = 1 - F_Z(0.5).$$

# Ejemplo normal con R y python

## Ejercicio

Sea  $X$  una normal con media 2 y varianza 4. Calcular con R y con python las probabilidades

- $P(1 < X < 2)$ .
- $P(X > 3)$ .

# Ejemplo normal con R y python

## Solución con R

```
pnorm(2,mean=2,sd=2)-pnorm(1,mean=2,sd=2) #P(1< X< 2)
```

```
[1] 0.1914625
```

```
pnorm(3,mean=2,sd=2,lower.tail =FALSE) #P(X>3)
```

```
[1] 0.3085375
```

```
1-pnorm(3,mean=2,sd=2,lower.tail=TRUE) #P(X>3) = 1-P(X<=3)
```

```
[1] 0.3085375
```



# Ejemplo normal con R y python

## Solución con python

```
norm.cdf(2,loc=2,scale=2)-norm.cdf(1,loc=2,scale=2) #P(1< X< 2)
```

0.19146246127401312

```
1-norm.cdf(3,loc=2,scale=2) #P(X>3) = 1-P(X<=3)
```

0.3085375387259869

# La distribución normal aproxima otras distribuciones

En los temas que siguen veremos como, bajo determinadas condiciones,

- la distribución normal puede aproximar la distribución binomial,
- la distribución normal puede aproximar la distribución Poisson
- la distribución normal es la distribución límite de la media aritmética de una muestra de variables aleatorias.